دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده‌ی مهندسی کامپیوتر

عنوان:

تمرین سری سوم

دفاع خصمانه، عدالت و هوش مصنوعی توضیح‌پذیر (پیاده‌سازی)

درس:

یادگیری ماشین قابل اعتماد

دانشجو:

امید طرب آور (۴۰۴۱۳۱۰۹۷)

استاد:

دکتر امیرمزلقانی

فهرست مطالب

عنوان **صفحه**

۱- ارزیابی مقاومت خصمانه و دفاع مدل‌های طبقه‌بندی تصویر ۵

۱-۱- طراحی آزمایش و پروتکل ارزیابی ۵

۱-۱-۱- مجموعه‌داده‌ها و نحوه تقسیم داده ۵

۱-۱-۲- معماری مدل‌ها و تنظیمات آموزش ۶

۱-۱-۳- معیارها و اصول ارزیابی ۸

۱-۲- آموزش و ارزیابی مدل‌های پایه ۹

۱-۲-۱- روند همگرایی آموزش ۹

۱-۲-۲- عملکرد نهایی و ماتریس درهم‌ریختگی ۱۲

۱-۳- ارزیابی حملات FGSM و PGD ۱۵

۱-۳-۱- حمله FGSM و اثر شدت اختلال ۱۵

۱-۳-۲- حمله PGD و انتخاب تنظیمات ۲۱

۱-۳-۳- مقایسه تحلیلی FGSM و PGD ۲۷

۱-۴- دفاع‌های مبتنی بر آموزش خصمانه ۲۸

۱-۴-۱- روش‌های FGSM-AT و PGD-AT ۲۸

۱-۴-۲- مقایسه عملکرد تمیز و مقاوم ۲۹

۱-۴-۳- هزینه محاسباتی دفاع‌ها ۳۱

۱-۴-۴- تحلیل مصالحه دقت-مقاومت ۳۲

۱-۵- ارزیابی پوشاندن گرادیان ۳۳

۱-۵-۱- افزایش گام‌ها و Random Restartهای PGD ۳۳

۱-۵-۲- حمله انتقالی و مقایسه White-box و Black-box ۳۴

۱-۵-۳- ارزیابی EOT و AutoAttack ۳۶

۱-۵-۴- حکم نهایی درباره مقاومت واقعی ۳۷

۱-۶- تحلیل تکمیلی توضیح‌پذیری مبتنی بر مفهوم ۳۸
۱-۶-۱- طراحی آزمایش TCAV ۳۸
۱-۶-۲- نتایج TCAV و مقایسه مدل پایه با PGD-AT ۴۰
۱-۷- نکات پیاده‌سازی و ملاحظات عملی ۴۵
۱-۷-۱- پیاده‌سازی حملات و آموزش خصمانه ۴۶
۱-۷-۲- ارزیابی حملات قوی و مدیریت هزینه اجرا ۵۰
۱-۷-۳- پیاده‌سازی تحلیل TCAV و ثبت خروجی‌ها ۵۸
۱-۸- نتیجه‌گیری و تصمیم نهایی ۵۹
۲- تحلیل عدالت، توضیح‌پذیری و کاهش سوگیری در طبقه‌بندی درآمد ۶۰
۲-۱- معرفی مسئله و طراحی آزمایش ۶۰
۲-۱-۱- معرفی مجموعه‌داده و تعریف مسئله ۶۰
۲-۱-۲- آماده‌سازی و تقسیم‌بندی داده‌ها ۶۲
۲-۱-۳- ترکیب گروه‌ها و نرخ‌های پایه ۶۳
۲-۲- آموزش و ارزیابی مدل‌ها ۶۵
۲-۲-۱- مدل‌ها و تنظیمات آموزش ۶۵
۲-۲-۲- معیارهای ارزیابی عملکرد ۶۶
۲-۲-۳- نتایج و مقایسه مدل‌ها ۶۷
۲-۳- ارزیابی عدالت گروهی و کالیبراسیون ۶۹
۲-۳-۱- معیارهای عدالت و قرارداد محاسبه شکاف‌ها ۶۹
۲-۳-۲- تحلیل عدالت بر اساس جنسیت ۷۰
۲-۳-۳- تحلیل عدالت بر اساس نژاد و گروه‌های تقاطعی ۷۱
۲-۳-۴- ارزیابی کالیبراسیون گروهی ۷۴
۲-۳-۵- گروه آسیب‌دیده و هزینه انواع خطا ۷۸
۲-۳-۶- حذف ویژگی‌های حساس و باقی‌ماندن ویژگی‌های جانشین ۷۹
۲-۴- توضیح‌پذیری سراسری مدل ۸۰

۲-۴-۱- اهمیت ویژگی بر اساس درهم‌ریزی ۸۱
۲-۴-۲- Partial Dependence Plot (PDP) ۸۳
۲-۴-۳- تحلیل سراسری SHAP ۸۵
۲-۴-۴- جمع‌بندی توضیح‌های سراسری ۸۸
۲-۵- توضیح‌پذیری محلی و امکان اقدام ۸۸
۲-۵-۱- روش انتخاب نمونه‌ها و تولید توضیح محلی ۸۸
۲-۵-۲- نمونه زن با خروجی مثبت ۸۹
۲-۵-۳- نمونه زن با خروجی منفی ۹۰
۲-۵-۴- نمونه مرد با خروجی منفی ۹۲
۲-۵-۵- ارزیابی عملی و اخلاقی Recourseها ۹۳
۲-۶- کاهش سوگیری و تحلیل مبادله‌ها ۹۳
۲-۶-۱- پروتکل ارزیابی روش‌های کاهش سوگیری ۹۴
۲-۶-۲- روش Reweighing ۹۴
۲-۶-۳- تنظیم آستانه به تفکیک جنسیت ۹۵
۲-۶-۴- مقایسه عملکرد، عدالت و کالیبراسیون ۹۶
۲-۶-۵- تحلیل Trade-off و Leveling Down ۹۹
۲-۷- نکات پیاده‌سازی و ملاحظات عملی ۱۰۰
۲-۷-۱- ساخت پیش‌پردازش و Pipeline مدل‌ها ۱۰۰
۲-۷-۲- حفظ سازگاری و تولید Counterfactual ۱۰۲
۲-۷-۳- محاسبه وزن‌های Reweighing ۱۰۴
۲-۷-۴- اعمال و انتخاب آستانه‌های گروهی ۱۰۵
۲-۸- نتیجه‌گیری ۱۰۸

فصل اول

ارزیابی مقاومت خصمانه و دفاع مدل‌های طبقه‌بندی تصویر

در این فصل، مدل‌های طبقه‌بندی تصویر روی دو مجموعه‌داده Fashion-MNIST و CIFAR-10 آموزش داده شده و عملکرد آن‌ها در شرایط عادی و تحت حملات خصمانه FGSM و PGD ارزیابی می‌شود. سپس اثر دو روش آموزش خصمانه، هزینه محاسباتی آن‌ها، احتمال وقوع پوشاندن گرادیان و نتایج تحلیل تکمیلی مبتنی بر مفهوم بررسی خواهد شد.

۱-۱- طراحی آزمایش و پروتکل ارزیابی

برای ارزیابی معتبر مقاومت خصمانه، لازم است مراحل آموزش، انتخاب تنظیمات و ارزیابی نهایی از یکدیگر تفکیک شوند. بر همین اساس، آزمایش‌ها در حالت اجرای کامل و با بذر تصادفی ثابت انجام شدند و مجموعه آزمون رسمی در هیچ‌یک از تصمیم‌های آموزشی یا انتخاب تنظیمات حمله دخالت نداشت. اگرچه اجرای آزمایش روی یکی از دو مجموعه‌داده برای پاسخ‌گویی به سؤال کافی بود، آزمایش‌ها روی هر دو مجموعه Fashion-MNIST و CIFAR-10 انجام شدند تا رفتار حملات و دفاع‌ها در دو سطح متفاوت از پیچیدگی بصری مقایسه شود. الزامات تمرین نیز شامل آموزش مدل پایه، ارزیابی FGSM و PGD، مقایسه حداقل دو دفاع و بررسی صریح احتمال پوشاندن گرادیان است.

۱-۱-۱- مجموعه‌داده‌ها و نحوه تقسیم داده

مجموعه Fashion-MNIST شامل تصاویر خاکستری ۲۸ × ۲۸ از ده گروه پوشاک و مجموعه CIFAR-10 شامل تصاویر رنگی ۳۲ × ۳۲ از ده گروه شیء و حیوان است. هر دو مجموعه‌داده دارای تقسیم رسمی آموزش و آزمون هستند، اما مجموعه اعتبارسنجی مستقلی ارائه نمی‌کنند. ازاین‌رو، بخشی از تقسیم رسمی آموزش با استفاده از تفکیک طبقه‌بندی‌شده و قطعی کنار گذاشته شد تا توزیع کلاس‌ها در مجموعه‌های آموزش و اعتبارسنجی حفظ شود.

جدول ۱–۱: مشخصات مجموعه‌داده‌ها و نحوه تقسیم نمونه‌ها

مجموعه‌داده	ابعاد ورودی	تعداد کلاس	اندازه تقسیم رسمی آموزش	آموزش مدل	اعتبارسنجی	آزمون رسمی
Fashion-MNIST	$1 \times 28 \times 28$	۱۰	۶۰۰۰۰	۵۰۰۰۰	۱۰۰۰۰	۱۰۰۰۰
CIFAR-10	$3 \times 32 \times 32$	۱۰	۵۰۰۰۰	۴۹۴۸۸	۵۱۲	۱۰۰۰۰

تفکیک داده با مقدار بذر ۴۲ و به‌صورت Stratified انجام شد و اندیس‌های حاصل برای بازتولید آزمایش ذخیره شدند. مجموعه اعتبارسنجی برای پایش روند آموزش و اجرای شبکه کامل تنظیمات PGD استفاده شد؛ در مقابل، مجموعه آزمون رسمی در انتخاب مدل، انتخاب نقطه توقف، تنظیم نرخ یادگیری، انتخاب checkpoint یا انتخاب پارامترهای حمله نقشی نداشت. دقت و خطای آزمون پس از هر دوره آموزش مدل پایه صرفاً برای تولید منحنی‌های خواسته‌شده در صورت تمرین محاسبه شدند. بنابراین، مشاهده مقادیر آزمون در طول آموزش به تغییر هیچ تصمیم محاسباتی منجر نشده است.

در حالت اجرای کامل، هیچ محدودیت اختیاری بر تعداد نمونه‌های آموزش یا آزمون اعمال نشد و تمام ارزیابی‌های اصلی مقاومت روی کل ۱۰۰۰۰ نمونه آزمون صورت گرفتند. همچنین، گزینه drop_last=False در تمام DataLoaderها فعال بود؛ بنابراین حتی در صورت بخش‌پذیرنبودن اندازه داده بر اندازه دسته، نمونه‌های دسته پایانی حذف نشدند.

برای Fashion-MNIST فقط تبدیل تصویر به Tensor انجام شد. در CIFAR-10، به‌منظور کاهش بیش‌برازش، تصاویر مجموعه آموزش با برش تصادفی ۳۲×۳۲ پس از padding چهارپیکسلی و وارونگی افقی تصادفی افزایش داده شدند. این تبدیلات فقط در مسیر آموزش اعمال شدند و مجموعه‌های اعتبارسنجی و آزمون بدون افزایش داده ارزیابی شدند.

تمام توابع حمله تصاویر را در دامنه اصلی پیکسل، یعنی بازه $[0,1]$، دریافت می‌کنند. نرمال‌سازی به‌جای قرارگرفتن در DataLoader به‌عنوان نخستین لایه مدل پیاده‌سازی شد. در نتیجه، مقادیر ϵ و α مستقیماً در فضای پیکسلی تعریف می‌شوند و تبدیل نادرست کران حمله میان فضای نرمال‌شده و فضای تصویر رخ نمی‌دهد.

۱-۱-۲- معماری مدل‌ها و تنظیمات آموزش

مطابق صورت تمرین، برای Fashion-MNIST از یک شبکه کانولوشنی کوچک مبتنی بر ساختار LeNet و برای CIFAR-10 از ResNet-18 استفاده شد. مدل CIFAR-10 بدون وزن‌های ازپیش‌آموزش‌دیده ساخته شد و برای سازگاری با تصاویر کوچک، کانولوشن ورودی آن به فیلتر 3×3 با گام یک تغییر یافت و لایه Max Pooling ابتدایی حذف شد. در هر دو مدل، لایه نرمال‌سازی ورودی بخشی از خود شبکه است.

جدول ۱–۲: معماری مدل‌های پایه

مجموعه‌داده	معماری	اجزای اصلی	تعداد پارامتر قابل آموزش
Fashion-MNIST	CNN مبتنی بر LeNet	دو لایه کانولوشن با ۳۲ و ۶۴ کانال، دو Max Pooling، لایه کاملاً متصل ۱۲۸بعدی و طبقه‌بند ده‌کلاسه	۴۵۴۹۲۲
CIFAR-10	ResNet-18 اصلاح‌شده	بلوک‌های باقیمانده ResNet-18، کانولوشن ابتدایی 3×3، حذف Max Pooling ابتدایی و طبقه‌بند ده‌کلاسه	۱۱۱۷۳۹۶۲

تفاوت ظرفیت دو مدل متناسب با دشواری داده‌ها در نظر گرفته شد. تصاویر Fashion-MNIST تک‌کاناله، هم‌اندازه و دارای ساختار نسبتاً ساده‌ای هستند؛ ازاین‌رو، یک CNN کوچک برای استخراج الگوهای محلی آن‌ها کفایت می‌کند. در مقابل، CIFAR-10 شامل تغییرات بیشتر در رنگ، پس‌زمینه، بافت و زاویه دید است و مدل باقیمانده عمیق‌تر امکان استخراج نمایش‌های سلسله‌مراتبی غنی‌تری را فراهم می‌کند.

برای حمله انتقالی، از معماری‌هایی مستقل از مدل‌های هدف استفاده شد. مدل جانشین Fashion-MNIST یک CNN سه‌مرحله‌ای با کانال‌های ۲۴، ۴۸ و ۹۶ و Global Average Pooling بود. مدل جانشین CIFAR-10 نیز از یک شبکه کانولوشنی سبک VGGمانند با کانال‌های ۶۴، ۱۲۸ و ۲۵۶ تشکیل شد. این مدل‌ها از مقداردهی تصادفی آموزش داده شدند و هیچ وزن یا checkpoint از مدل‌های هدف دریافت نکردند؛ بنابراین ارزیابی انتقال حمله به اشتراک مستقیم وزن‌ها متکی نیست.

جدول ۱–۳: تنظیمات اصلی آموزش

مجموعه‌داده	تعداد دوره مدل پایه	تعداد دوره ریزتنظیم دفاع‌ها	اندازه دسته	بهینه‌ساز مدل پایه	نرخ یادگیری اولیه	Weight Decay	Momentum	زمان‌بند
Fashion-MNIST	۸	۶	۲۰۴۸	Adam	3×10^{-3}	10^{-4}	–	Cosine Annealing
CIFAR-10	۲۵	۱۲	۱۰۲۴	SGD با Nesterov	0.30	5×10^{-4}	0.9	Cosine Annealing

نرخ یادگیری در طول آموزش با زمان‌بند Cosine Annealing کاهش یافت. تعداد دوره‌ها از پیش ثابت بود و از Early Stopping یا انتخاب checkpoint بر اساس مجموعه آزمون استفاده نشد. نرخ‌های یادگیری دفاع‌ها به‌طور مستقل و متناسب با نوع آموزش خصمانه تعیین شدند که جزئیات آن‌ها در بخش ۱.۴ ارائه خواهد شد.

تمام مؤلفه‌های تصادفی شامل Python، NumPy، PyTorch، CUDA، ترتیب نمونه‌های آموزشی و Workerهای DataLoader با بذر ۴۲ مقداردهی شدند. علاوه بر این، حالت deterministic در cuDNN فعال و benchmark غیرفعال شد. این تنظیمات اثر تفاوت‌های ناشی از مقداردهی اولیه، ترتیب دسته‌ها و پردازش موازی داده را کاهش می‌دهند؛ هرچند در محاسبات GPU همچنان نمی‌توان برابری بیتی نتایج را در تمام نسخه‌های سخت‌افزاری و نرم‌افزاری تضمین کرد.

آزمایش‌ها در حالت full روی کارت گرافیک NVIDIA GeForce RTX 3090 با حدود ۲۳.۵۷ گیبی‌بایت حافظه و چهار Worker برای بارگذاری داده اجرا شدند. محیط نرم‌افزاری اصلی شامل Python 3.12.9، PyTorch 2.6.0، TorchVision 0.21.0، torchattacks 3.5.1 و Captum 0.9.0 بود. مشخصات محیط، بذر تصادفی و مسیر خروجی‌ها نیز به‌صورت فایل ماشین‌خوان ذخیره شدند.

۱-۱-۳- معیارها و اصول ارزیابی

عملکرد مدل در شرایط عادی با Cross-Entropy Loss، دقت طبقه‌بندی و ماتریس درهم‌ریختگی سنجیده شد. برای مجموعه‌ای شامل N نمونه، بردار logit مدل $f_\theta(x_i)$ و برچسب صحیح y_i، معیارهای اصلی به‌صورت زیر تعریف می‌شوند:

$$\mathcal{L}_{CE} = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp\left(f_\theta(x_i)_{y_i}\right)}{\sum_{c=1}^{C}\exp(f_\theta(x_i)_c)}$$

$$Accuracy_{clean} = \frac{1}{N}\sum_{i=1}^{N}1[\operatorname{argmax}_c f_\theta(x_i)_c = y_i]$$

Cross-Entropy Loss میزان اطمینان مدل نسبت به برچسب صحیح را نیز منعکس می‌کند؛ بنابراین ممکن است حتی در شرایطی که تغییر دقت محدود است، افزایش Loss نشان‌دهنده کاهش حاشیه اطمینان پیش‌بینی‌ها باشد. ماتریس درهم‌ریختگی نیز برای تشخیص ساختار خطاهای کلاس‌به‌کلاس استفاده شد، زیرا دقت کلی مشخص نمی‌کند کدام گروه‌های تصویری بیشتر با یکدیگر اشتباه شده‌اند.

برای ارزیابی خصمانه، نمونه حمله‌شده به‌صورت $x_i^{adv} = x_i + \delta_i$ در نظر گرفته شد و تمام حملات اصلی تحت کران L_∞ اجرا شدند:

$$||\delta_i||_\infty \le \epsilon$$

$$x_i^{adv} \in [0,1]^d$$

$$Accuracy_{robust}(\mathcal{A}) = \frac{1}{N}\sum_{i=1}^{N}1[\operatorname{argmax}_c f_\theta\left(\mathcal{A}(x_i, y_i)\right)_c = y_i]$$

که در آن $\mathcal{A}$ الگوریتم حمله است. Robust Accuracy تنها نسبت نمونه‌هایی را اندازه می‌گیرد که پس از اعمال همان حمله مشخص همچنان درست طبقه‌بندی شده‌اند؛ بنابراین مقدار آن به قدرت، تعداد گام‌ها، اندازه گام، تعداد شروع‌های تصادفی و نوع دسترسی مهاجم وابسته است. به همین دلیل، دقت مقاوم تحت یک حمله منفرد به‌عنوان اثبات قطعی مقاومت در نظر گرفته نشد.

در ارزیابی White-box، نمونه خصمانه با استفاده مستقیم از گرادیان مدل هدف ساخته شد. در ارزیابی Transfer Black-box، نمونه ابتدا روی مدل جانشین مستقل تولید و سپس بدون استفاده از گرادیان مدل هدف روی آن ارزیابی شد. این دو حالت، دو سطح متفاوت از دانش مهاجم را نشان می‌دهند و مقایسه آن‌ها برای بررسی انتقال‌پذیری نمونه‌های خصمانه و تشخیص برخی رفتارهای غیرعادی گرادیان استفاده شد.

معیار نهایی مقاومت بر مجموعه‌ای از شواهد شامل FGSM، شبکه تنظیمات PGD، PGD قوی با گام‌ها و restartهای بیشتر، حمله انتقالی، EOT-PGD و AutoAttack مبتنی بود. FGSM به دلیل تک‌مرحله‌ای‌بودن، بیشتر به‌عنوان سنجه اولیه حساسیت مدل استفاده شد؛ درحالی‌که نتیجه‌گیری نهایی به حملات تکرارشونده و مجموعه استاندارد AutoAttack متکی است. این طراحی مانع از آن می‌شود که افزایش دقت تحت یک حمله ضعیف یا تنظیم‌نشده به‌اشتباه به‌عنوان مقاومت عمومی تفسیر شود.

هزینه دفاع‌ها نیز فقط با دقت مقایسه نشد. زمان مرحله آموزش یا ریزتنظیم، زمان کل خط لوله، تعداد محاسبات گرادیان خصمانه در هر دسته و حافظه GPU ثبت شدند. برای یک مدل دفاعی، زمان کل خط لوله مطابق رابطه زیر محاسبه شد:

$$T_{pipeline}^{defense} = T_{baseline} + T_{fine-tuning}^{defense}$$

$$M_{estimated} = M_{model} + (M_{peak,allocated} - M_{allocated,start})$$

عبارت دوم، «حافظه بیشینه تخمینی ایزوله» است و از مجموع حافظه پارامترها و bufferهای مدل و افزایش بیشینه تخصیص CUDA در مرحله آموزش حاصل می‌شود. این معیار برای مقایسه منصفانه‌تر دفاع‌ها به کار رفت، زیرا Peak خام فرایند ممکن است حافظه مدل‌هایی را که از مراحل قبلی روی GPU باقی مانده‌اند نیز شامل شود. بااین‌حال، این مقدار یک تخمین مقایسه‌ای است و معادل اندازه‌گیری حافظه یک فرایند کاملاً مستقل نیست.

در مجموع، پروتکل حاضر انتخاب تنظیمات را از ارزیابی نهایی جدا می‌کند، تمام معیارهای اصلی را روی مجموعه آزمون کامل می‌سنجد و قضاوت درباره مقاومت را به سازگاری چند حمله مستقل وابسته می‌سازد. این اصول مبنای تحلیل نتایج مدل پایه، دفاع‌ها و آزمون‌های پوشاندن گرادیان در بخش‌های بعدی خواهند بود.

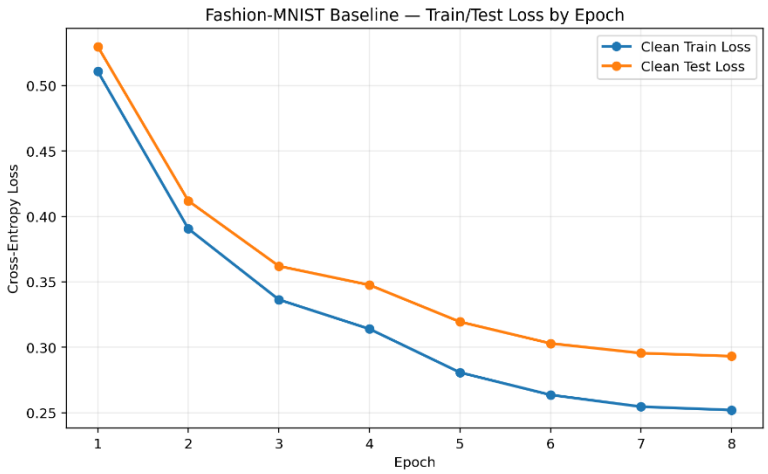
۱-۲- آموزش و ارزیابی مدل‌های پایه

پیش از بررسی حملات و دفاع‌های خصمانه، عملکرد مدل‌های پایه روی داده‌های پاک ارزیابی شد تا یک نقطه مرجع برای مقایسه‌های بعدی فراهم شود. مطابق خواسته تمرین، دقت و خطای پاک مجموعه‌های آموزش و آزمون در پایان هر دوره ثبت شد و ماتریس درهم‌ریختگی مدل نهایی نیز روی کل مجموعه آزمون رسمی محاسبه گردید. مقادیر آزمون در طول آموزش فقط برای تولید نمودارهای گزارش ثبت شدند و در محاسبه گرادیان، انتخاب مدل، تنظیم نرخ یادگیری یا انتخاب checkpoint دخالتی نداشتند.

۱-۲-۱- روند همگرایی آموزش

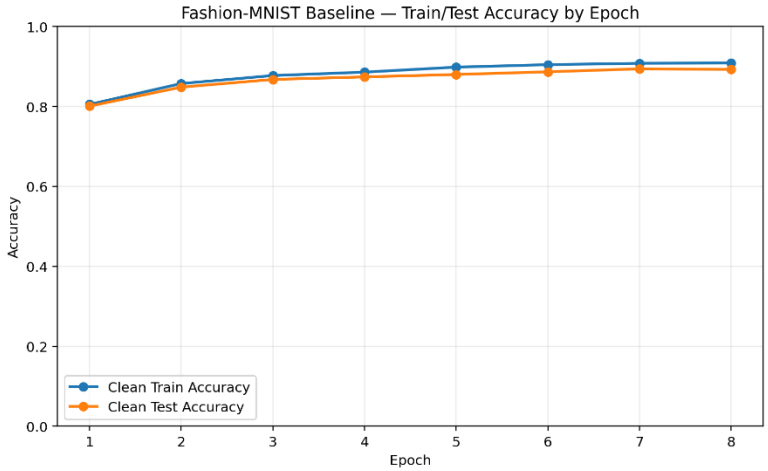
برای ارزیابی روند یادگیری، پس از هر دوره مدل در حالت ارزیابی روی نسخه پاک مجموعه آموزش و کل مجموعه آزمون اجرا شد. بنابراین، Train Loss و Train Accuracy گزارش‌شده به عملکرد مدل روی داده‌های آموزشی بدون افزایش داده اشاره دارند و با مقدار تابع هدف محاسبه‌شده روی mini-batchهای افزوده‌شده یکسان نیستند.

در Fashion-MNIST، کاهش خطای آموزش و آزمون از نخستین دوره آغاز شد و تا انتهای هشت دوره ادامه یافت. نزدیک‌بودن دو منحنی نشان می‌دهد که بهبود مدل روی داده آموزش با بهبود مشابهی روی داده‌های دیده‌نشده همراه بوده و فاصله تعمیم در این بازه محدود باقی مانده است.



شکل ۱–۱: تغییرات ***Cross-Entropy Loss*** *مدل پایه* ***Fashion-MNIST*** *روی مجموعه‌های آموزش و آزمون برحسب دوره آموزش.*

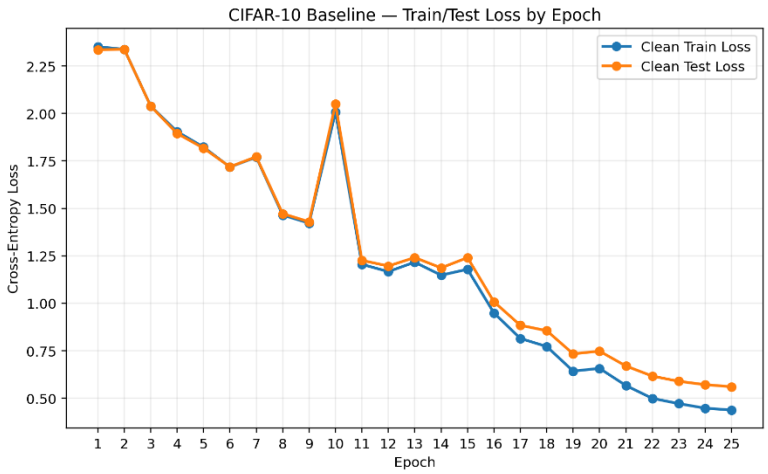
کاهش هم‌زمان دو منحنی نشان می‌دهد که افزایش عملکرد مدل صرفاً ناشی از حفظ نمونه‌های آموزشی نبوده است. در دوره پایانی، خطای آزمون همچنان نسبت به دوره قبل کاهش یافته است؛ ازاین‌رو، در محدوده تعداد دوره‌های اجراشده نشانه‌ای از افزایش خطای تعمیم مشاهده نمی‌شود.



شکل ۱–۲: تغییرات دقت پاک مدل پایه ***Fashion-MNIST*** *روی مجموعه‌های آموزش و آزمون برحسب دوره آموزش.*

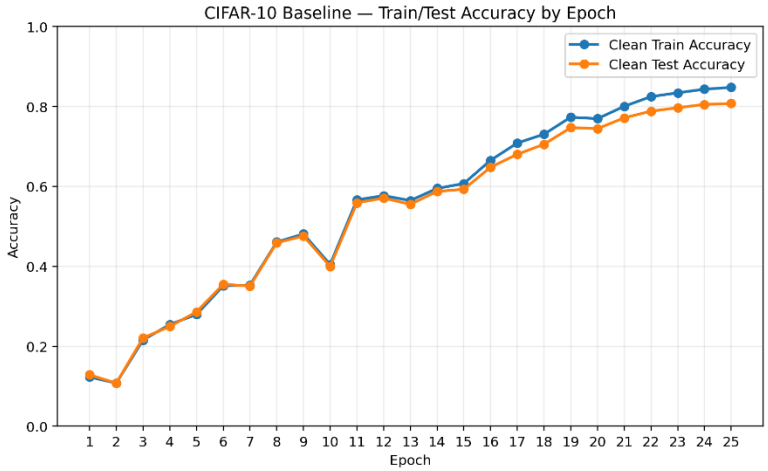
دقت آزمون تا دوره هفتم افزایش یافته و در دوره هشتم کاهش بسیار محدودی داشته است. بااین‌حال، هم‌زمان خطای آزمون در دوره پایانی کاهش یافته است. این تفاوت از آنجا ناشی می‌شود که Accuracy فقط تغییر برچسب نهایی را ثبت می‌کند، درحالی‌که Cross-Entropy به تغییر اطمینان مدل نسبت به تمام کلاس‌ها نیز حساس است. در نتیجه، افت جزئی Accuracy به‌تنهایی نشانه شروع بیش‌برازش محسوب نمی‌شود.

روند آموزش CIFAR-10 در دوره‌های ابتدایی نوسان بیشتری داشت. این نوسان در هر دو معیار پاک آموزش و آزمون مشاهده شد، اما از نیمه دوم آموزش، مسیر بهبود پایدارتر شد. به‌ویژه از دوره بیست‌ویکم تا دوره بیست‌وپنجم، خطای آزمون در هر دوره کاهش و دقت آزمون در هر دوره افزایش یافته است.



شکل ۱–۳: تغییرات ***Cross-Entropy Loss*** *مدل پایه* ***CIFAR-10*** *روی مجموعه‌های آموزش و آزمون برحسب دوره آموزش.*

وجود نوسان در بخش ابتدایی منحنی باعث نمی‌شود که فرایند آموزش ناموفق تلقی شود؛ زیرا روند نهایی معیارها باید در کنار رفتار کل دوره‌ها بررسی شود. کاهش پیوسته خطای آزمون در پنج دوره پایانی نشان می‌دهد که مدل در پایان آموزش هنوز در حال بهبود تعمیم بوده و افزایش ممتد خطای آزمون، که معمولاً یکی از نشانه‌های بیش‌برازش است، رخ نداده است.



شکل ۱–۴: تغییرات دقت پاک مدل پایه ***CIFAR-10*** *روی مجموعه‌های آموزش و آزمون برحسب دوره آموزش.*

فاصله میان دقت آموزش و آزمون در CIFAR-10 از Fashion-MNIST بیشتر است. این موضوع نشان می‌دهد که مدل عمیق‌تر CIFAR-10 بخشی از الگوهای مجموعه آموزش را بهتر از داده آزمون مدل کرده است. بااین‌حال، از آنجا که دقت آزمون تا آخرین دوره افزایش یافته، شواهد موجود از وقوع بیش‌برازش شدید یا ضرورت توقف زودهنگام پیش از دوره نهایی حمایت نمی‌کنند.

جدول ۱-۴: عملکرد نهایی مدل‌های پایه روی داده‌های پاک

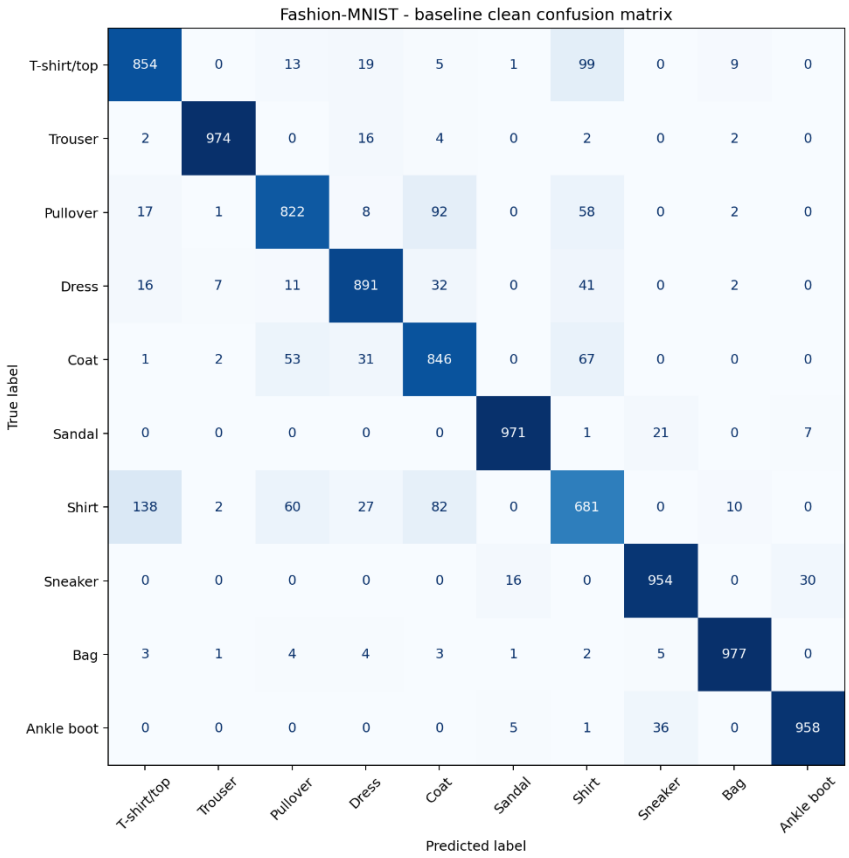
مجموعه‌داده	تعداد دوره	Train Loss	Test Loss	Train Accuracy	Test Accuracy	فاصله دقت آموزش و آزمون
Fashion-MNIST	۸	۰.۲۵۲۱	۰.۲۹۳۲	۹۰.۸۷٪	۸۹.۲۸٪	۱.۵۹ واحد درصد
CIFAR-10	۲۵	۰.۴۳۷۴	۰.۵۶۰۴	۸۴.۷۷٪	۸۰.۷۶٪	۴.۰۱ واحد درصد

در Fashion-MNIST، فاصله محدود دقت آموزش و آزمون با نزدیکی منحنی‌های Loss سازگار است و نشان می‌دهد ظرفیت مدل برای این مسئله متناسب بوده است. در CIFAR-10، شکاف بزرگ‌تر و خطای آزمون بالاتر بیانگر دشواری بیشتر تعمیم است، اما عملکرد نهایی همچنان برای ایجاد یک baseline معنادار جهت ارزیابی حملات مناسب است. در این مرحله، مقادیر بالای دقت پاک نباید به‌عنوان نشانه مقاومت خصمانه تعبیر شوند؛ مقاومت مدل در بخش‌های بعدی و تحت حملات صریح بررسی خواهد شد.

۱-۲-۲- عملکرد نهایی و ماتریس درهم‌ریختگی

Accuracy کلی به‌تنهایی توزیع خطا میان کلاس‌ها را نشان نمی‌دهد. به همین دلیل، برای هر مدل پایه ماتریس درهم‌ریختگی روی کل ۱۰۰۰۰ نمونه آزمون محاسبه شد. هر سطر ماتریس نشان‌دهنده کلاس واقعی و هر ستون نشان‌دهنده پیش‌بینی مدل است؛ بنابراین مقادیر قطر اصلی تعداد طبقه‌بندی‌های صحیح هر کلاس را نمایش می‌دهند.

در Fashion-MNIST، بیشتر جرم ماتریس روی قطر اصلی متمرکز است و مدل کلاس‌هایی مانند Trouser، Sandal، Sneaker، Bag و Ankle boot را با خطای نسبتاً کمی تفکیک کرده است. در مقابل، خطاها عمدتاً میان کلاس‌های بالاپوش متمرکز شده‌اند.

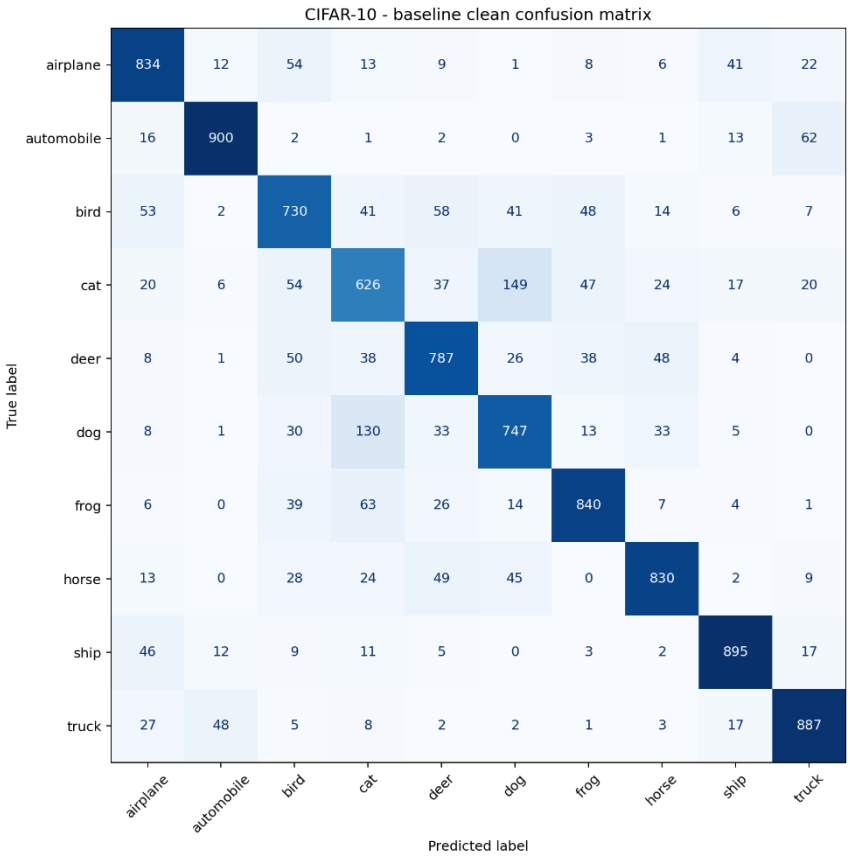


*شکل ۱–۵: ماتریس درهم‌ریختگی مدل پایه **Fashion-MNIST** روی کل مجموعه آزمون پاک.*

کلاس Shirt دشوارترین کلاس این مدل است و فقط ۶۸۱ نمونه از ۱۰۰۰ نمونه آن به‌درستی شناسایی شده‌اند. بخش قابل‌توجهی از نمونه‌های این کلاس به‌صورت T-shirt/top، Coat یا Pullover پیش‌بینی شده‌اند. این رابطه دوطرفه است؛ برای مثال، تعدادی از نمونه‌های T-shirt/top نیز به‌صورت Shirt طبقه‌بندی شده‌اند. چنین الگویی نشان می‌دهد که مدل مرز میان دسته‌هایی با شکل کلی مشابه را به‌خوبی کلاس‌های دارای ساختار متمایز، مانند کیف یا کفش، فرا نگرفته است.

میان کلاس‌های کفش نیز خطاهایی مانند اشتباه Sneaker با Ankle boot مشاهده می‌شود، اما شدت آن‌ها از خطاهای میان بالاپوش‌ها کمتر است. بنابراین ضعف اصلی مدل Fashion-MNIST به تشخیص کلی پوشاک مربوط نیست، بلکه بیشتر به تفکیک زیرگروه‌های بصری نزدیک در یک گروه معنایی مشترک مربوط می‌شود.

ماتریس CIFAR-10 پراکندگی بیشتری در خارج از قطر اصلی دارد. این نتیجه با دقت کلی پایین‌تر مدل سازگار است و نشان می‌دهد که پیچیدگی پس‌زمینه، تنوع وضعیت اشیا و شباهت میان برخی کلاس‌ها مسئله تفکیک را دشوارتر کرده است.



*شکل ۱–۶: ماتریس درهم‌ریختگی مدل پایه **CIFAR-10** روی کل مجموعه آزمون پاک.*

بیشترین تراکم خطا میان کلاس‌های حیوانی دیده می‌شود. کلاس cat با ۶۲۶ پیش‌بینی صحیح، پایین‌ترین بازیابی کلاسی را دارد و بخش قابل‌توجهی از نمونه‌های آن به‌صورت dog پیش‌بینی شده‌اند. جهت معکوس نیز مشاهده می‌شود و تعداد زیادی از تصاویر dog به کلاس cat نسبت داده شده‌اند. علاوه بر این، خطاهایی میان bird، deer، frog و سایر کلاس‌های حیوانی وجود دارد که نشان می‌دهد نمایش آموخته‌شده در تفکیک تفاوت‌های ظریف این گروه‌ها محدودیت دارد.

کلاس‌های وسایل نقلیه عموماً عملکرد بهتری دارند، اما خطاهای ساختاری همچنان قابل مشاهده‌اند. برای مثال، automobile و truck با یکدیگر اشتباه می‌شوند و تعدادی از تصاویر airplane به bird یا ship نسبت داده شده‌اند. بنابراین مدل برخی الگوهای سطح‌بالای مشترک، مانند شکل کلی وسیله یا پس‌زمینه آسمان و آب، را فرا گرفته است، اما این ویژگی‌ها همیشه برای جداسازی دقیق کلاس کافی نیستند.

مقایسه دو ماتریس نشان می‌دهد که تفاوت دقت کلی دو مدل فقط حاصل افزایش یکنواخت خطا در تمام کلاس‌ها نیست. در Fashion-MNIST خطاها عمدتاً در چند خانواده مشخص متمرکزند، درحالی‌که در CIFAR-10 چندین کلاس حیوانی و برخی زوج‌های وسایل نقلیه هم‌زمان درگیر هستند. ازاین‌رو، ارزیابی‌های خصمانه بعدی باید نه‌تنها کاهش Accuracy کلی، بلکه احتمال تشدید همین مرزهای تصمیم ضعیف را نیز در نظر بگیرند.

در مجموع، هر دو مدل پایه روی داده پاک به سطحی از عملکرد رسیده‌اند که امکان تحلیل معنادار آسیب‌پذیری خصمانه را فراهم می‌کند. Fashion-MNIST تعمیم پایدارتر و خطاهای متمرکزتری دارد، درحالی‌که CIFAR-10 با وجود بهبود مستمر در پایان آموزش، فاصله تعمیم و تنوع خطای بیشتری نشان می‌دهد. این دو وضعیت، مبنای مناسبی برای بررسی اثر شدت حمله و مقایسه دفاع‌های خصمانه در بخش‌های بعدی فراهم می‌کنند.

۱-۳- ارزیابی حملات FGSM و PGD

پس از تعیین عملکرد مدل‌های پایه روی داده‌های پاک، آسیب‌پذیری آن‌ها در برابر اختلال‌های کران‌دار L_∞ بررسی شد. ابتدا حمله تک‌مرحله‌ای FGSM برای شدت‌های مختلف اجرا گردید و سپس حمله تکرارشونده PGD با ترکیب‌های مختلف اندازه گام و تعداد تکرار ارزیابی شد. تمام حملات در فضای اصلی پیکسل و بازه $[۰,۱]$ تولید شدند و نتایج عددی روی کل مجموعه آزمون رسمی محاسبه شدند؛ تنها انتخاب تنظیمات PGD بر اساس مجموعه اعتبارسنجی انجام گرفت.

۱-۳-۱- حمله FGSM و اثر شدت اختلال

حمله FGSM یک حمله White-box و بدون هدف مشخص است که با استفاده از علامت گرادیان تابع خطا نسبت به ورودی، تصویر را در جهتی تغییر می‌دهد که Cross-Entropy Loss افزایش یابد. برای تصویر x، برچسب صحیح y، مدل f_θ و کران اختلال ϵ، نمونه خصمانه به‌صورت زیر ساخته می‌شود:

$$g = \nabla_x \mathcal{L}_{CE}(f_\theta(x), y)$$
$$\delta_{FGSM} = \epsilon sign(g)$$
$$x^{adv} = clip_{[0,1]}(x + \delta_{FGSM})$$

تابع پیاده‌سازی‌شده با نام FGSM مدل، تصویر، برچسب و مقدار ϵ را دریافت می‌کند و سه خروجی شامل تصویر خصمانه، اختلال اعمال‌شده و خروجی مدل روی تصویر خصمانه را بازمی‌گرداند. پس از اعمال اختلال، تصویر در بازه معتبر پیکسل محدود می‌شود؛ بنابراین شرط زیر برای تمام نمونه‌ها برقرار است:

$$\left|\left|x^{adv} - x\right|\right|_\infty \leq \epsilon$$

حمله برای مقادیر تعیین‌شده در صورت تمرین اجرا شد:

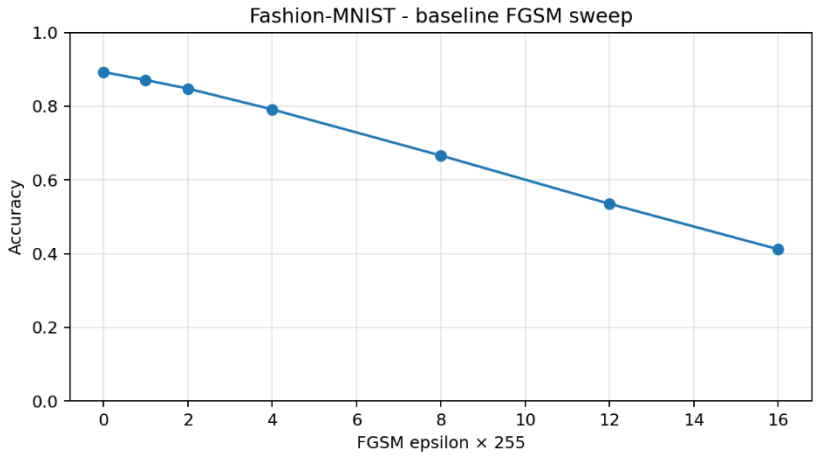
$$\epsilon \in \left\{0, \frac{1}{255}, \frac{2}{255}, \frac{4}{255}, \frac{8}{255}, \frac{12}{255}, \frac{16}{255}\right\}$$

نتایج حاصل از اجرای FGSM روی مدل‌های پایه در جدول ۱-۵ ارائه شده‌اند.

*جدول ۱–۵: دقت مدل‌های پایه تحت حمله **FGSM** برای شدت‌های مختلف اختلال*

ϵ	$\epsilon \times 255$	Fashion-MNIST	CIFAR-10
0	۰	۸۹.۲۸٪	۸۰.۷۶٪
$\frac{1}{255}$	۱	۸۷.۱۱٪	۵۲.۷۷٪
$\frac{2}{255}$	۲	۸۴.۷۸٪	۳۱.۳۲٪
$\frac{4}{255}$	۴	۷۹.۱۲٪	۱۲.۷۳٪
$\frac{8}{255}$	۸	۶۶.۶۰٪	۴.۲۳٪
$\frac{12}{255}$	۱۲	۵۳.۵۰٪	۳.۴۸٪
$\frac{16}{255}$	۱۶	۴۱.۱۶٪	۳.۸۸٪

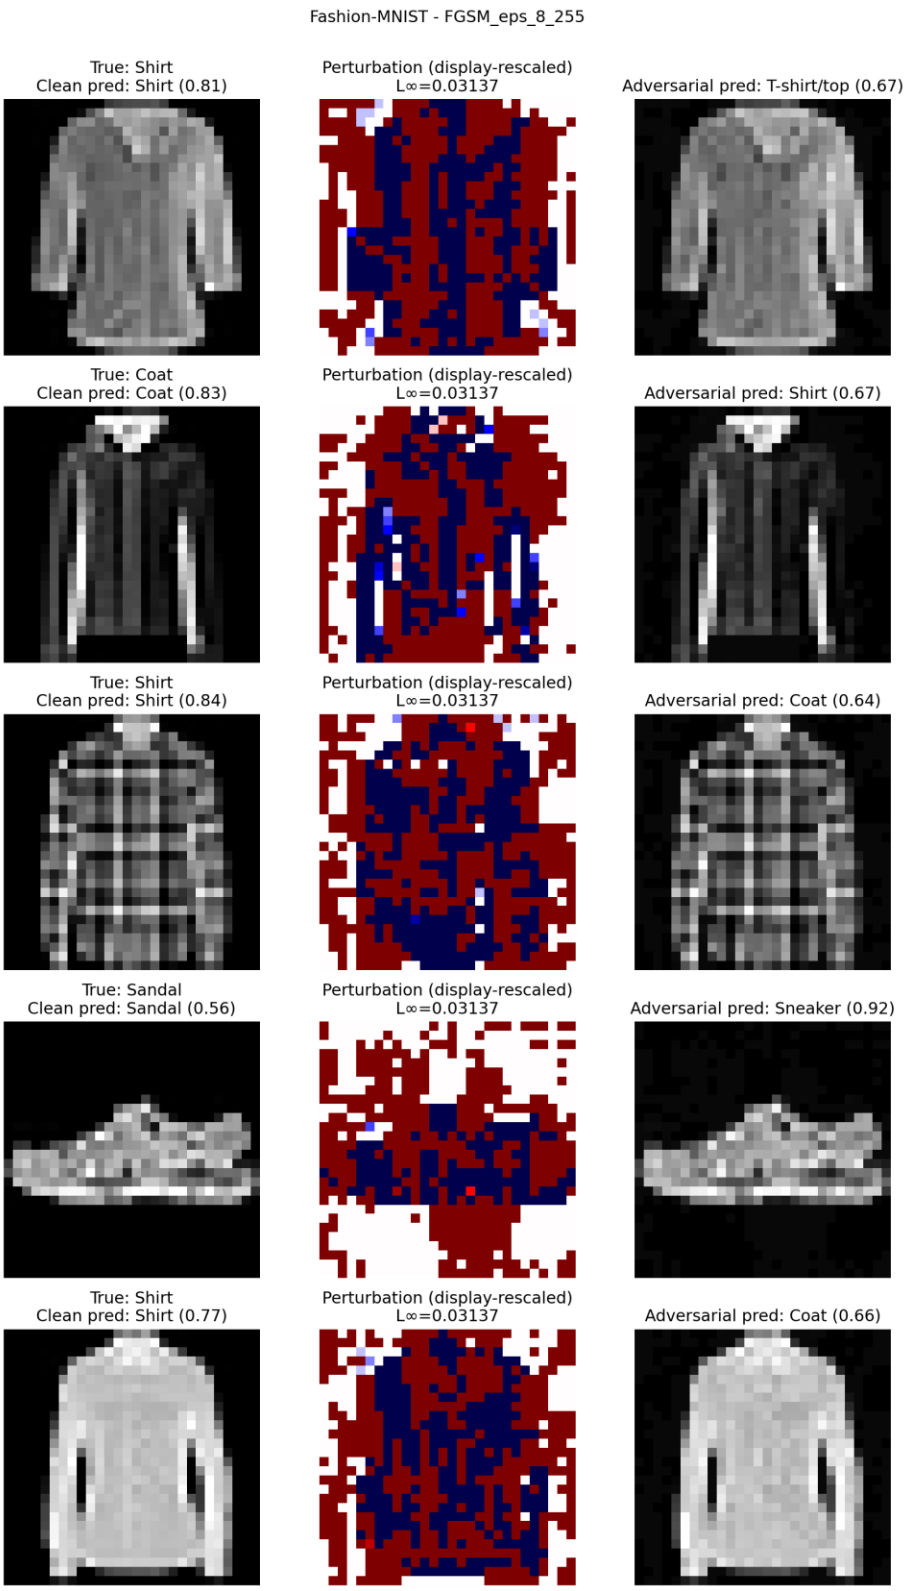
برابری دقت در $\epsilon = 0$ با دقت پاک مدل‌ها یک کنترل اولیه برای صحت پیاده‌سازی است؛ زیرا در این حالت هیچ تغییری در ورودی ایجاد نمی‌شود. در Fashion-MNIST با افزایش شدت اختلال، دقت به‌صورت منظم کاهش می‌یابد. این رفتار نشان می‌دهد که حتی اختلال تک‌مرحله‌ای نیز می‌تواند با حرکت در جهت گرادیان، تعداد قابل‌توجهی از نمونه‌ها را از مرز تصمیم عبور دهد.



*شکل ۱–۷: تغییرات دقت مدل پایه **Fashion-MNIST** تحت حمله **FGSM** برحسب مقدار $\epsilon \times 255$.*

کاهش تدریجی منحنی Fashion-MNIST نشان می‌دهد که آسیب‌پذیری مدل فقط به یک مقدار خاص از ϵ محدود نیست. بااین‌حال، باقی‌ماندن بخشی از دقت مدل در کران‌های بزرگ‌تر به‌تنهایی به معنی مقاومت آن نیست؛ زیرا FGSM تنها یک گام گرادیانی اجرا می‌کند و ممکن است قوی‌ترین نمونه موجود در کره مجاز را پیدا نکند.

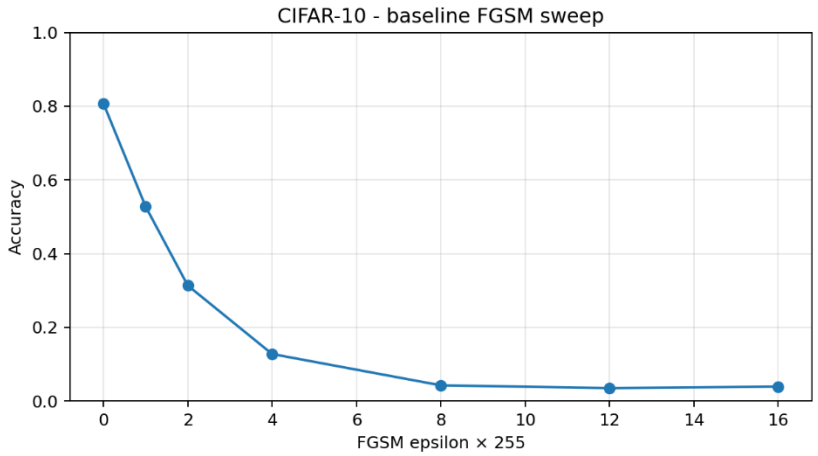
برای بررسی کیفی، پنج نمونه‌ای انتخاب شدند که مدل آن‌ها را در حالت پاک درست طبقه‌بندی کرده، اما پس از اعمال FGSM با $\epsilon = \frac{8}{255}$ پیش‌بینی آن‌ها تغییر کرده است.



*شکل ۱–۸: نمونه‌های موفق حملهٔ **FGSM** با $\epsilon = \frac{8}{255}$ روی مدل پایه **Fashion-MNIST**. هر ردیف از چپ به راست شامل تصویر پاک، اختلال با مقیاس بصری بازتنظیم‌شده و تصویر خصمانه است. عنوان هر تصویر برچسب واقعی، پیش‌بینی مدل و اطمینان پیش‌بینی را نشان می‌دهد.*

اختلال نمایش‌داده‌شده در ستون میانی برای قابل‌مشاهده‌شدن مقیاس‌دهی شده است و شدت بصری آن نباید با اندازه واقعی تغییر پیکسل اشتباه گرفته شود. مقدار واقعی نرم L_∞ در عنوان هر نمونه ثبت شده و از $\frac{8}{255}$ تجاوز نمی‌کند. این نمونه‌ها صرفاً برای نمایش سازوکار حمله انتخاب شده‌اند و برآورد کمی موفقیت حمله بر اساس کل ۱۰۰۰۰ نمونه آزمون انجام شده است.

مدل پایه CIFAR-10 نسبت به FGSM حساسیت بسیار بیشتری نشان می‌دهد. بخش عمده افت دقت در مقادیر کوچک ϵ رخ می‌دهد و در $\epsilon = \frac{8}{255}$ تنها بخش اندکی از نمونه‌ها درست طبقه‌بندی می‌شوند.



*شکل ۱–۹: تغییرات دقت مدل پایه **CIFAR-10** تحت حمله **FGSM** برحسب مقدار $\epsilon \times 255$.*

رفتار منحنی نشان می‌دهد که عملکرد مناسب مدل روی تصاویر پاک به پایداری مرز تصمیم در همسایگی ورودی‌ها منجر نشده است. تفاوت شدید میان دقت پاک و دقت خصمانه بیانگر آن است که نمایش‌های آموخته‌شده مدل CIFAR-10 در راستاهایی با اندازه کوچک اما هم‌جهت با گرادیان، به‌شدت حساس هستند.

افزایش جزئی دقت از $\epsilon = \frac{12}{255}$ به $\frac{16}{255}$ نباید به‌عنوان افزایش مقاومت در اختلال بزرگ‌تر تفسیر شود. FGSM جهت گرادیان را فقط در نقطه پاک محاسبه می‌کند و سپس یک گام با طول ϵ برمی‌دارد. در یک مرز تصمیم غیرخطی، افزایش طول این گام ممکن است برخی نمونه‌ها را از یک ناحیه اشتباه عبور داده و دوباره وارد ناحیه برچسب صحیح کند. این رفتار غیرتک‌نوا یکی از دلایلی است که ارزیابی FGSM به‌تنهایی برای سنجش مقاومت کافی نیست.



*شکل ۱–۱۰: نمونه‌های موفق حمله **FGSM** با $\epsilon = \frac{8}{255}$ روی مدل پایه **CIFAR-10**. هر ردیف شامل تصویر پاک، اختلال نمایش‌مقیاس‌شده و تصویر خصمانه به همراه برچسب واقعی و پیش‌بینی‌های مدل است.*

در تصاویر CIFAR-10 نیز تغییر ظاهری نمونه خصمانه محدود است، اما پیش‌بینی مدل تغییر می‌کند. این مشاهده نشان می‌دهد که خطای خصمانه الزاماً به تخریب معنایی تصویر برای مشاهده‌گر انسانی نیاز ندارد؛ کافی است تغییر ورودی در جهتی اعمال شود که نمایش داخلی مدل را از مرز تصمیم عبور دهد.

در مجموع، آزمایش FGSM نشان داد هر دو مدل پایه در برابر اختلال White-box آسیب‌پذیرند، اما شدت این آسیب‌پذیری در CIFAR-10 بسیار بیشتر است. با توجه به تک‌مرحله‌ای‌بودن FGSM و رفتار غیرتک‌نوای آن در کران‌های بزرگ‌تر، برای برآورد دقیق‌تر مقاومت از حمله تکرارشونده PGD استفاده شد.

۱-۳-۲- حمله PGD و انتخاب تنظیمات

حمله PGD نسخه تکرارشونده‌ای از بهینه‌سازی ورودی خصمانه است. این حمله از یک نقطه تصادفی در کره L_∞ آغاز می‌شود، در هر مرحله در جهت افزایش تابع خطا حرکت می‌کند و سپس نتیجه را مجدداً به ناحیه مجاز تصویر می‌افکند. برای شروع تصادفی u^r و تکرار t، فرایند تولید نمونه خصمانه در restart شماره r به‌صورت زیر تعریف می‌شود:

$$u^r \sim Uniform([-\epsilon, \epsilon]^d)$$

$$x_0^r = clip_{[0,1]}(x + u^r)$$

$$x_{t+1}^r = \prod_{\mathcal{B}_\infty(x,\epsilon)\cap[0,1]^d} \left[x_t^r + \alpha sign\left(\nabla_{x_t^r} \mathcal{L}_{CE}(f_\theta(x_t^r), y) \right) \right]$$

در پیاده‌سازی حاضر، پس از پایان هر restart، مقدار Cross-Entropy Loss برای هر نمونه به‌صورت مستقل محاسبه شد و نمونه حاصل از restart دارای بیشترین Loss انتخاب گردید:

$$r_i^* = \underset{r}{\text{argmax}}\, \mathcal{L}_{CE}\left(f_\theta\left(x_{T,i}^r\right), y_i\right)$$

$$x_i^{adv} = x_{T,i}^{r_i^*}$$

این انتخاب نمونه‌به‌نمونه مانع از آن می‌شود که یک restart واحد برای تمام تصاویر دسته انتخاب شود و از اطلاعات restartهای قوی‌تر برای برخی نمونه‌ها صرف‌نظر گردد.

مطابق صورت تمرین، مقدار کران حمله برابر $\frac{8}{255}$ ثابت شد و تمام نه ترکیب زیر با سه شروع تصادفی بررسی شدند:

$$\epsilon = \frac{8}{255}, \quad \alpha \in \left\{\frac{1}{255}, \frac{2}{255}, \frac{3}{255}\right\}, \quad T \in \{10,20,40\}, \quad R = 3$$

برای جلوگیری از نشت اطلاعات، شبکه تنظیمات PGD فقط روی بخش اعتبارسنجی جداشده از تقسیم رسمی آموزش اجرا شد. نتایج Fashion-MNIST بر ۱۰۰۰۰ نمونه اعتبارسنجی و نتایج CIFAR-10 بر ۵۱۲ نمونه اعتبارسنجی محاسبه شدند. مجموعه آزمون رسمی در انتخاب α یا تعداد گام‌ها استفاده نشد.

*جدول ۱–۶: دقت مقاوم مدل‌های پایه در شبکه نه‌حالته **PGD** روی مجموعه اعتبارسنجی*

$\alpha \times 255$	تعداد گام	تعداد restart	Fashion-MNIST	CIFAR-10
۱	۱۰	۳	۶۷.۵۳٪	۰.۰۰٪
۱	۲۰	۳	۶۴.۱۰٪	۰.۰۰٪
۱	۴۰	۳	۶۳.۶۱٪	۰.۰۰٪
۲	۱۰	۳	۶۴.۲۸٪	۰.۰۰٪
۲	۲۰	۳	۶۳.۸۰٪	۰.۰۰٪
۲	۴۰	۳	۶۳.۵۹٪	۰.۰۰٪
۳	۱۰	۳	٭۶۴.۰۷٪	۰.۰۰٪
۳	۲۰	۳	۶۳.۸۹٪	۰.۰۰٪
۳	۴۰	۳	۶۳.۷۲٪	۰.۰۰٪

٭ تنظیم منتخب Compute-aware برای Fashion-MNIST. تنظیم منتخب CIFAR-10 برابر α=2/255، ده گام و سه restart بود.

در Fashion-MNIST، استفاده از $\alpha = \frac{1}{255}$ و تنها ده گام حمله ضعیف‌تری ایجاد کرده است؛ زیرا مجموع حرکت بالقوه و فرصت بهینه‌سازی برای رسیدن به نواحی با خطای بیشتر محدودتر است. افزایش تعداد گام‌ها از ۲۰ به ۴۰ در بیشتر تنظیمات فقط کاهش کوچکی در دقت مقاوم ایجاد می‌کند. این اشباع تدریجی نشان می‌دهد که حمله پس از حدود ۲۰ گام به ناحیه‌ای نزدیک به بیشینه محلی Loss رسیده است.

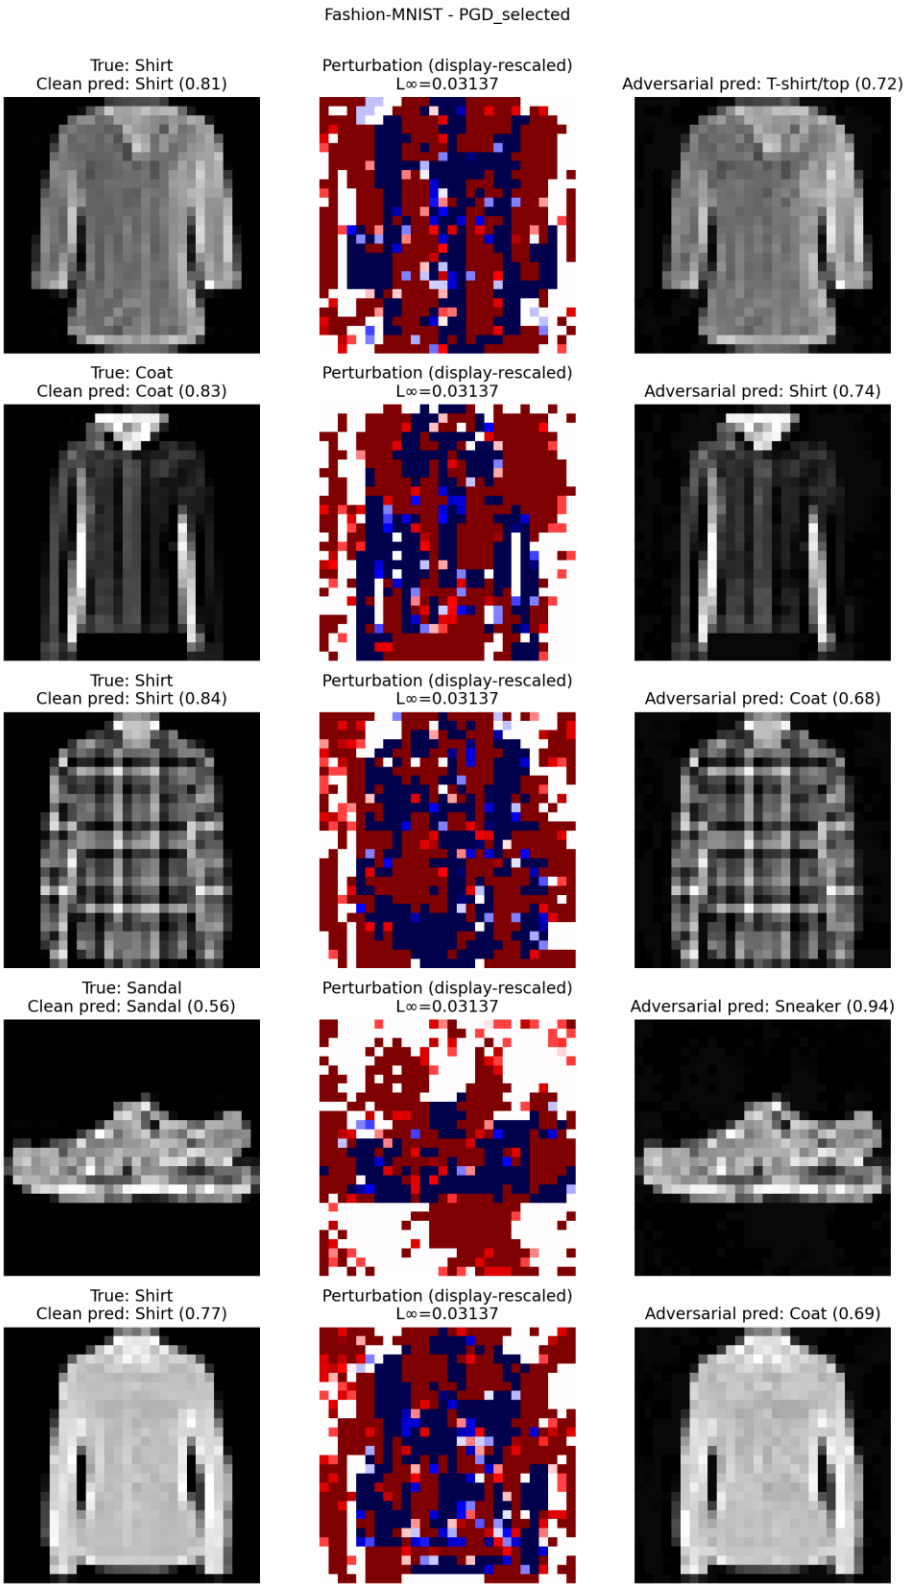
قوی‌ترین تنظیم مشاهده‌شده در Fashion-MNIST از $\alpha = \frac{2}{255}$، چهل گام و سه restart استفاده کرد و دقت اعتبارسنجی را به ۶۳/۵۹ درصد رساند. بااین‌حال، تنظیم $\alpha = \frac{3}{255}$ و ده گام دقت ۶۴/۰۷ درصد ایجاد کرد؛ اختلاف قدرت این دو حمله فقط ۰/۴۸ واحد درصد بود، درحالی‌که تعداد محاسبات گرادیان از ۱۲۰ به ۳۰ محاسبه برای هر نمونه کاهش یافت. زمان ثبت‌شده برای شبکه اعتبارسنجی نیز از حدود ۷/۲۲ ثانیه به ۱/۹۶ ثانیه کاهش پیدا کرد. بنابراین، تنظیم ده‌مرحله‌ای در محدوده تحمل ۰/۵ واحد درصد از قوی‌ترین نتیجه قرار داشت و برای ارزیابی اصلی به‌عنوان تنظیم Compute-aware انتخاب شد.

در CIFAR-10، هر نه تنظیم دقت مقاوم صفر روی مجموعه اعتبارسنجی ایجاد کردند. این نتیجه به معنی یکسان‌بودن عمومی قدرت این تنظیمات نیست؛ بلکه نشان می‌دهد در کران $\frac{8}{255}$، حتی کم‌هزینه‌ترین تنظیم بررسی‌شده برای شکستن تمام نمونه‌های اعتبارسنجی مدل پایه کافی بوده است. هنگامی که معیار دقت به کران پایین صفر رسیده باشد، افزایش قدرت حمله دیگر با این معیار قابل مشاهده نیست. از میان تنظیمات مساوی، $\alpha = \frac{2}{255}$، ده گام و سه restart به دلیل هزینه مشاهده‌شده کمتر انتخاب

شد. بنابراین این انتخاب یک تصمیم محاسباتی میان حالت‌های هم‌نتیجه است و نباید به‌عنوان برتری منحصربه‌فرد این ترکیب درنظر گرفته شود.

تنظیم PGD مورد استفاده در ارزیابی اصلی با یک قاعده Compute-aware و صرفاً بر اساس مجموعه اعتبارسنجی انتخاب شد. ابتدا تنظیم‌هایی که Robust Accuracy آن‌ها حداکثر ۰.۵ واحد درصد با قوی‌ترین تنظیم فاصله داشت مشخص شدند و سپس گزینه دارای کمترین هزینه گرادیانی انتخاب شد. جزئیات پیاده‌سازی این قاعده، نحوه محاسبه هزینه و سازوکار شکستن تساوی در بخش ۱.۷.۳ ارائه می‌شود. این انتخاب فقط برای ارزیابی میانی و کم‌هزینه مدل‌ها به کار رفت و قضاوت نهایی درباره مقاومت، مستقل از آن و بر اساس PGD چهل‌مرحله‌ای با پنج restart و AutoAttack انجام شد.

تنظیمات منتخب سپس روی کل مجموعه آزمون رسمی اجرا شدند. علاوه بر محاسبه دقت، نمونه‌های موفقی انتخاب شدند که مدل در حالت پاک آن‌ها را درست طبقه‌بندی کرده، اما پس از حمله PGD پیش‌بینی متفاوتی داشته است.



شکل ۱–۱۱: نمونه‌های موفق حمله ***PGD*** *منتخب روی مدل پایه* ***Fashion-MNIST*** *با* $\epsilon = \frac{8}{255}$، $\alpha = \frac{3}{255}$، ده گام و سه شروع تصادفی؛ هر ردیف شامل تصویر پاک، اختلال نمایش‌مقیاس‌شده و تصویر خصمانه است.

این شکل نشان می‌دهد که اجرای چندمرحله‌ای حمله می‌تواند در همان کران L_∞ نمونه‌هایی پیدا کند که تابع خطای بیشتری نسبت به حرکت تک‌مرحله‌ای ایجاد می‌کنند. بااین‌حال، نمونه‌های شکل عمداً از میان حملات موفق انتخاب شده‌اند؛ بنابراین میزان فراوانی شکست مدل باید از جدول‌های کل مجموعه آزمون استنباط شود، نه از تعداد نمونه‌های نمایش‌داده‌شده.



*شکل ۱–۱۲: نمونه‌های موفق حملهٔ **PGD** منتخب روی مدل پایه **CIFAR-10** با $\epsilon = \frac{8}{255}$، $\alpha = \frac{2}{255}$، ده گام و سه شروع تصادفی؛ هر ردیف شامل تصویر پاک، اختلال نمایش‌مقیاس‌شده و تصویر خصمانه است.*

در CIFAR-10، دستیابی حمله به دقت تقریباً صفر نشان می‌دهد که آسیب‌پذیری مشاهده‌شده در FGSM صرفاً پیامد یک جهت تک‌مرحله‌ای خاص نبوده است. PGD با به‌روزرسانی مکرر جهت گرادیان و شروع از نقاط مختلف، تقریباً تمام نمونه‌های آزمون را می‌شکند. بااین‌حال، نتیجه نهایی درباره مقاومت یا پوشاندن گرادیان فقط بر این حمله متکی نخواهد بود و در بخش ۱.۵ با تنظیمات قوی‌تر و AutoAttack بررسی می‌شود.

۱-۳-۳- مقایسه تحلیلی FGSM و PGD

برای مقایسه مستقیم دو حمله، FGSM و PGD با کران مشترک $\epsilon = \frac{8}{255}$ روی کل مجموعه آزمون رسمی اجرا شدند. PGD در این جدول از تنظیم Compute-aware انتخاب‌شده بر اساس اعتبارسنجی استفاده می‌کند.

*جدول ۱-۷: مقایسه عملکرد مدل‌های پایه روی داده پاک و تحت **FGSM** و **PGD** با $\epsilon=\frac{8}{255}$*

مجموعه‌داده	دقت پاک	دقت تحت FGSM	دقت تحت PGD منتخب	افت FGSM نسبت به پاک	افت PGD نسبت به پاک
Fashion-MNIST	۸۹.۲۸٪	۶۶.۶۰٪	۶۳.۴۳٪	۲۲.۶۸ واحد درصد	۲۵.۸۵ واحد درصد
CIFAR-10	۸۰.۷۶٪	۴.۲۳٪	۰.۰۲٪	۷۶.۵۳ واحد درصد	۸۰.۷۴ واحد درصد

در هر دو مجموعه‌داده، PGD دقت کمتری از FGSM ایجاد کرده است. این نتیجه با سازوکار حمله سازگار است: FGSM فقط گرادیان نقطه پاک را محاسبه می‌کند و تمام بودجه اختلال را در یک گام مصرف می‌کند، درحالی‌که PGD پس از هر حرکت گرادیان را دوباره محاسبه می‌کند و جهت حمله را با هندسه محلی جدید مرز تصمیم تطبیق می‌دهد. Project کردن مکرر نیز اجازه می‌دهد حمله بدون خروج از ناحیه مجاز، نقاط مختلف کره L_∞ را جست‌وجو کند.

استفاده از چند شروع تصادفی مزیت دیگری برای PGD فراهم می‌کند. یک شروع خاص ممکن است به ناحیه‌ای با Loss پایین‌تر یا بیشینه محلی ضعیف‌تر منتهی شود، اما انتخاب پرخطاترین خروجی میان سه restart احتمال باقی‌ماندن در چنین ناحیه‌ای را کاهش می‌دهد. بااین‌حال، PGD نیز تضمین نمی‌کند که بیشینه سراسری تابع خطا را پیدا کرده باشد؛ به همین دلیل، در بخش تشخیص Gradient Masking تعداد گام‌ها و restartها افزایش یافته و نتایج آن با EOT و AutoAttack مقایسه خواهند شد.

فاصله FGSM و PGD در Fashion-MNIST محدود اما منظم است. این الگو نشان می‌دهد FGSM بخش عمده آسیب‌پذیری مدل را آشکار می‌کند، ولی ارزیابی آن همچنان اندکی خوش‌بینانه است. در CIFAR-10، FGSM مدل را به‌شدت تضعیف می‌کند، اما PGD نشان می‌دهد همان میزان اندک دقت باقی‌مانده نیز ناشی از مقاومت پایدار نیست و با جست‌وجوی تکرارشونده تقریباً به‌طور کامل حذف می‌شود.

بنابراین، دقت مناسب مدل‌ها روی داده پاک هیچ تضمینی درباره پایداری محلی آن‌ها فراهم نمی‌کند. مدل پایه Fashion-MNIST بخشی از عملکرد خود را در کران $\frac{8}{255}$ حفظ می‌کند، اما کاهش قابل‌توجه دقت تحت هر دو حمله نشان‌دهنده

آسیب‌پذیری آن است. مدل پایه CIFAR-10 نیز عملاً فاقد مقاومت قابل اتکا در این کران است. این نتایج ضرورت استفاده از آموزش خصمانه و ارزیابی دفاع‌ها را در بخش بعدی مشخص می‌کنند.

۱-۴- دفاع‌های مبتنی بر آموزش خصمانه

برای افزایش مقاومت مدل‌ها، دو روش مبتنی بر آموزش خصمانه مقایسه شدند. دفاع نخست، ریزتنظیم با نمونه‌های Random-start FGSM است که به‌عنوان دفاع دوم مجاز در صورت تمرین انتخاب شد. دفاع دوم، ریزتنظیم خصمانه PGD است که اجرای آن در تمرین الزامی بود. برای کنترل شرایط مقایسه، هر دو مدل دفاعی از وزن‌های یکسان مدل پایه آغاز شدند و با ترتیب یکسان داده‌های آموزشی ریزتنظیم شدند. بنابراین، تفاوت نتایج آن‌ها عمدتاً به روش تولید نمونه خصمانه و تابع هدف آموزش مربوط است، نه مقداردهی اولیه متفاوت.

۱-۴-۱- روش‌های FGSM-AT و PGD-AT

در دفاع FGSM-AT، هر نمونه ابتدا از یک نقطه تصادفی در کره L_∞ پیرامون تصویر پاک آغاز می‌شود و سپس یک گام در جهت علامت گرادیان تابع خطا حرکت می‌کند. در پایان، تصویر به کره مجاز و دامنه معتبر پیکسل تصویر افکنده می‌شود:

$$u \sim Uniform([-\epsilon, \epsilon]^d)$$

$$x_0 = clip_{[0,1]}(x + u)$$

$$x_{adv}^{FGSM} = \prod_{\mathcal{B}_\infty(x,\epsilon)\cap[0,1]^d} \left[x_0 + \alpha sign\left(\nabla_{x_0}\mathcal{L}_{CE}(f_\theta(x_0), y)\right)\right]$$

تابع هدف FGSM-AT ترکیبی از خطای نمونه پاک و نمونه خصمانه است:

$$\mathcal{L}_{FGSM-AT} = \lambda\mathcal{L}_{CE}(f_\theta(x), y) + (1-\lambda)\mathcal{L}_{CE}\left(f_\theta\left(x_{adv}^{FGSM}\right), y\right)$$

$$\lambda_{Fashion} = 0.20, \quad \lambda_{CIFAR} = 0.25$$

وجود مؤلفه پاک با هدف کاهش افت عملکرد عادی مدل در نظر گرفته شد. در CIFAR-10 اندازه گام FGSM برابر $\frac{10}{255}$ است که از کران نهایی $\frac{8}{255}$ بزرگ‌تر است؛ بااین‌حال، این موضوع باعث نقض محدودیت حمله نمی‌شود، زیرا پس از گام گرادیانی، اختلال مجدداً در کره L_∞ با شعاع $\frac{8}{255}$ تصویر می‌شود.

در PGD-AT، نمونه خصمانه با هفت گام PGD و یک شروع تصادفی تولید می‌شود. تابع هدف این دفاع فقط بر خطای نمونه خصمانه متمرکز است:

$$x_{adv}^{PGD} = PGD\left(x, y; \epsilon = \frac{8}{255}, \alpha = \frac{2}{255}, T = 7, R = 1\right),$$

$$\mathcal{L}_{PGD-AT} = \mathcal{L}_{CE}\left(f_\theta\left(x_{adv}^{PGD}\right), y\right)$$

در هر دو روش، نمونه خصمانه پس از تولید از گراف محاسباتی جدا می‌شود و به‌روزرسانی پارامترهای مدل با یک مرحله مستقل پس‌انتشار انجام می‌گیرد. تنظیمات کامل ریزتنظیم در جدول ۱-۸ ارائه شده‌اند.

جدول ۱–۸: تنظیمات ریزتنظیم خصمانه مدل‌ها

مجموعه‌داده	دفاع	تعداد دوره	اندازه دسته	بهینه‌ساز	نرخ یادگیری	ϵ	α	تعداد گام	Restart	وزن خطای پاک
Fashion-MNIST	FGSM-AT	۶	۲۰۴۸	Adam	1.5×10^{-3}	$\frac{8}{255}$	$\frac{8}{255}$	۱	۱	۰.۲۰
Fashion-MNIST	PGD-AT	۶	۲۰۴۸	Adam	1.5×10^{-3}	$\frac{8}{255}$	$\frac{2}{255}$	۷	۱	۰
CIFAR-10	FGSM-AT	۱۲	۱۰۲۴	SGD با Nesterov	3×10^{-2}	$\frac{8}{255}$	$\frac{10}{255}$	۱	۱	۰.۲۵
CIFAR-10	PGD-AT	۱۲	۱۰۲۴	SGD با Nesterov	1.5×10^{-1}	$\frac{8}{255}$	$\frac{2}{255}$	۷	۱	۰

هر دو دفاع از همان معماری و تعداد پارامتر مدل پایه استفاده می‌کنند و فقط مقادیر وزن‌ها تغییر می‌کنند. همچنین برای هر دو روش زمان‌بند Cosine Annealing به کار رفت. در نتیجه، افزایش هزینه دفاع ناشی از بزرگ‌ترشدن مدل نیست، بلکه عمدتاً از تولید نمونه‌های خصمانه در هر دسته آموزشی ناشی می‌شود.

محدودیت اصلی FGSM-AT آن است که نمونه‌های آموزشی آن با یک گام گرادیانی تولید می‌شوند. بنابراین ارزیابی این دفاع فقط با FGSM ممکن است عملکرد آن را بیش از حد خوش‌بینانه نشان دهد. به همین دلیل، اعتبار هر دو دفاع علاوه بر FGSM با PGD چندمرحله‌ای، PGD قوی و AutoAttack بررسی شد.

۱-۴-۲- مقایسه عملکرد تمیز و مقاوم

عملکرد مدل پایه و دو مدل دفاعی روی کل ۱۰۰۰۰ نمونه آزمون هر مجموعه‌داده محاسبه شد. برای جلوگیری از نتیجه‌گیری بر اساس یک حمله ضعیف، علاوه بر FGSM و PGD منتخب، نتایج PGD با ۴۰ گام و ۵ شروع تصادفی و مجموعه استاندارد AutoAttack نیز در جدول ۱-۹ آورده شده‌اند. جزئیات مربوط به تشخیص پوشاندن گرادیان در بخش ۱.۵ تحلیل خواهند شد.

جدول ۱–۹: مقایسه دقت پاک و مقاوم مدل‌ها روی مجموعه آزمون

مجموعه‌داده	مدل	دقت پاک	FGSM، $\epsilon = \frac{8}{255}$	PGD منتخب	PGD قوی 40×5	AutoAttack
Fashion-MNIST	مدل پایه	۸۹.۲۸٪	۶۶.۶۰٪	۶۳.۴۳٪	۶۲.۷۱٪	۶۲.۶۷٪
Fashion-MNIST	FGSM-AT	۸۸.۶۵٪	۷۸.۴۷٪	۷۶.۹۵٪	۷۶.۶۴٪	۷۶.۴۲٪
Fashion-MNIST	PGD-AT	۸۷.۷۳٪	۷۹.۷۱٪	۷۸.۶۸٪	۷۸.۵۴٪	۷۸.۱۸٪
CIFAR-10	مدل پایه	۸۰.۷۶٪	۴.۲۳٪	۰.۰۲٪	۰.۰۱٪	۰.۰۱٪
CIFAR-10	FGSM-AT	۶۷.۶۴٪	۳۱.۵۶٪	۲۵.۸۳٪	۲۴.۶۰٪	۲۱.۶۹٪
CIFAR-10	PGD-AT	۶۱.۳۳٪	۳۷.۰۱٪	۳۴.۸۲٪	۳۴.۴۱٪	۳۰.۷۳٪

PGD منتخب Compute-aware برای مقایسه کم‌هزینه و یکنواخت مدل‌ها گزارش شده است، اما قضاوت نهایی درباره مقاومت بر اساس نتایج PGD قوی با ۴۰ گام و پنج restart و AutoAttack انجام می‌شود. ازاین‌رو، ستون PGD منتخب یک ارزیابی میانی است و نباید به‌تنهایی مبنای انتخاب دفاع قرار گیرد.

در Fashion-MNIST هر دو دفاع افزایش مقاومت معناداری ایجاد کرده‌اند، درحالی‌که افت دقت پاک محدود باقی مانده است. PGD-AT در تمام حملات قوی‌تر از FGSM-AT عمل می‌کند، اما برتری آن نسبتاً کوچک است و با کاهش بیشتر دقت پاک همراه می‌شود. بنابراین در این مجموعه‌داده، FGSM-AT گزینه‌ای کم‌هزینه‌تر با عملکرد رقابتی است، درحالی‌که PGD-AT بیشترین مقاومت مشاهده‌شده را فراهم می‌کند.

در CIFAR-10 وضعیت متفاوت است. مدل پایه تحت PGD و AutoAttack تقریباً به‌طور کامل شکست می‌خورد؛ در نتیجه، دقت پاک مناسب آن هیچ مقاومت قابل اتکایی در همسایگی خصمانه ورودی تضمین نمی‌کند. هر دو دفاع بخشی از مقاومت را بازیابی می‌کنند، اما این بهبود با کاهش محسوس دقت پاک همراه است. PGD-AT در AutoAttack حدود ۹/۰۴ واحد درصد از FGSM-AT مقاوم‌تر است، ولی دقت پاک آن نیز ۶/۳۱ واحد درصد کمتر است. بنابراین انتخاب میان این دو روش به میزان اهمیت عملکرد عادی در برابر مقاومت خصمانه وابسته است.

ترتیب نتایج نیز از نظر قدرت حمله منطقی است. در اغلب مدل‌های دفاعی، دقت FGSM از PGD منتخب بیشتر و دقت AutoAttack از PGD قوی کمتر است. این روند نشان می‌دهد ارزیابی صرف با FGSM تخمینی خوش‌بینانه از مقاومت ارائه می‌کند. این اختلاف به‌ویژه در CIFAR-10 قابل توجه است و ضرورت استفاده از چند حمله مستقل را تأیید می‌کند.

۱-۴-۳- هزینه محاسباتی دفاع‌ها

هزینه دفاع‌ها با سه جنبه زمان آموزش، تعداد گام‌های گرادیانی مورد نیاز برای تولید حمله در هر دسته و حافظه GPU مقایسه شد. زمان مرحله دفاع فقط مدت ریزتنظیم خصمانه را نشان می‌دهد، درحالی‌که زمان کل خط لوله شامل آموزش مدل پایه و سپس ریزتنظیم دفاع است:

$$T_{pipeline}^{baseline} = T_{baseline}$$

$$T_{pipeline}^{defense} = T_{baseline} + T_{fine-tuning}^{defense}$$

از آنجا که مدل‌های مراحل قبلی برای ارزیابی‌های بعدی روی GPU باقی می‌مانند، Peak خام حافظه کل فرایند معیار منصفانه‌ای برای مقایسه مستقیم مراحل نیست. به همین دلیل، معیار اصلی حافظه به‌صورت زیر محاسبه شد:

$$\Delta M_{peak} = \max\left(0, M_{peak,allocated} - M_{allocated,start}\right)$$

$$M_{estimated} = M_{model} + \Delta M_{peak}$$

این مقدار با عنوان «حافظه بیشینه تخمینی ایزوله» گزارش می‌شود و یک برآورد مقایسه‌ای است، نه اندازه‌گیری مستقیم یک فرایند کاملاً مستقل.

*جدول ۱–۱۰: هزینه زمانی و حافظه **GPU** آموزش مدل پایه و دفاع‌ها*

مجموعه‌داده	مدل	زمان مرحله	زمان کل خط لوله	نسبت زمان کل به مدل پایه	گام گرادیانی حمله در هر دسته	حافظه بیشینه تخمینی مرحله	بیشینه تخمینی کل خط لوله
Fashion-MNIST	مدل پایه	۵۱.۷۵ ثانیه	۵۱.۷۵ ثانیه	1.00 ×	۰	۷۲۷.۳۸ MB	۷۲۷.۳۸ MB
Fashion-MNIST	FGSM-AT	۳۳.۰۰ ثانیه	۸۴.۷۶ ثانیه	1.64 ×	۱	۱۱۹۰.۶۴ MB	۱۱۹۰.۶۴ MB
Fashion-MNIST	PGD-AT	۳۷.۷۲ ثانیه	۸۹.۴۷ ثانیه	1.73 ×	۷	۶۸۸.۴۵ MB	۷۲۷.۳۸ MB
CIFAR-10	مدل پایه	۴۷۶.۲۶ ثانیه	۴۷۶.۲۶ ثانیه	1.00 ×	۰	۶۷۸۱.۳۶ MB	۶۷۸۱.۳۶ MB
CIFAR-10	FGSM-AT	۵۲۵.۳۴ ثانیه	۱۰۰۱.۶۰ ثانیه	2.10 ×	۱	۱۱۳۸۳.۸۵ MB	۱۱۳۸۳.۸۵ MB
CIFAR-10	PGD-AT	۱۰۵۱.۲۰ ثانیه	۱۵۲۷.۴۶ ثانیه	3.21 ×	۷	۶۸۵۴.۲۷ MB	۶۸۵۴.۲۷ MB

زمان مرحله دفاع را نباید به‌تنهایی با زمان مدل پایه مقایسه کرد، زیرا مدل پایه و دفاع‌ها تعداد دوره‌های یکسانی ندارند. زمان کل خط لوله نشان می‌دهد هزینه افزودن دفاع در Fashion-MNIST محدودتر است، اما در CIFAR-10 استفاده از PGD-AT زمان کل را به بیش از سه برابر آموزش پاک افزایش می‌دهد. این اختلاف با معماری عمیق‌تر CIFAR-10 و محاسبه چندباره گرادیان ورودی در PGD سازگار است.

تعداد گام‌های حمله لزوماً با Peak حافظه رابطه خطی ندارد. در پیاده‌سازی PGD، تانسورهای هر گام پس از محاسبه گرادیان جدا می‌شوند و گراف همه هفت مرحله به‌طور هم‌زمان نگهداری نمی‌شود. در مقابل، تابع هدف FGSM-AT شامل forward پاک و خصمانه است و گراف هر دو مؤلفه تا پس‌انتشار نهایی در حافظه باقی می‌ماند. این تفاوت توضیح می‌دهد که چرا FGSM-AT با وجود داشتن فقط یک گام حمله، Peak حافظه بیشتری از PGD-AT ثبت کرده است.

حافظه خود پارامترها در هر سه مدل یک مجموعه‌داده ثابت است: حدود ۱/۷۴ مگابایت برای Fashion-MNIST و ۴۲/۶۶ مگابایت برای CIFAR-10. بنابراین دفاع‌ها اندازه مدل مستقرشده را افزایش نداده‌اند و تفاوت حافظه فقط به عملیات مرحله آموزش مربوط است.

۱-۴-۴- تحلیل مصالحه دقت-مقاومت

نتایج نشان می‌دهند افزایش مقاومت بدون هزینه به دست نیامده است، اما شدت این مصالحه به مجموعه‌داده و نوع دفاع وابسته است. در Fashion-MNIST، FGSM-AT دقت AutoAttack را ۱۳/۷۵ واحد درصد نسبت به مدل پایه افزایش داده، درحالی‌که تنها ۰/۶۳ واحد درصد از دقت پاک کاسته است. PGD-AT بهبود مقاومت را به ۱۵/۵۱ واحد درصد می‌رساند و افت دقت پاک آن ۱/۵۵ واحد درصد است. در این مسئله، هر دو دفاع مصالحه مطلوبی ایجاد کرده‌اند و برتری PGD-AT در برابر افزایش محدود هزینه و افت دقت پاک به دست آمده است.

در CIFAR-10، دفاع‌ها با مصالحه شدیدتری روبه‌رو هستند. FGSM-AT دقت AutoAttack را ۲۱/۶۸ واحد درصد افزایش می‌دهد، اما ۱۳/۱۲ واحد درصد از دقت پاک می‌کاهد. PGD-AT بیشترین مقاومت را ایجاد کرده و بهبود آن نسبت به مدل پایه ۳۰/۷۲ واحد درصد است، ولی افت دقت پاک به ۱۹/۴۳ واحد درصد می‌رسد. ازاین‌رو، نمی‌توان PGD-AT را بدون توجه به شرایط کاربرد به‌طور مطلق بهترین مدل دانست.

در محیطی که احتمال حمله پایین و خطا روی داده پاک پرهزینه باشد، کاهش دقت CIFAR-10 ممکن است استفاده از PGD-AT را نامناسب کند. در مقابل، در سامانه‌ای که مهاجم می‌تواند ورودی را دست‌کاری کند، مدل پایه با وجود دقت پاک بیشتر قابل اتکا نیست و PGD-AT گزینه محافظه‌کارانه‌تری است. FGSM-AT نیز نقطه میانی این دو وضعیت را فراهم می‌کند: دقت پاک بیشتری از PGD-AT حفظ می‌کند، اما تحت حملات قوی‌تر مقاومت پایین‌تری دارد.

در مجموع، PGD-AT در هر دو مجموعه‌داده قوی‌ترین دفاع مشاهده‌شده است، اما برتری آن در Fashion-MNIST با هزینه محدود و در CIFAR-10 با هزینه زمانی و افت دقت قابل توجه حاصل شده است. همچنین فاصله نتایج FGSM با AutoAttack نشان می‌دهد که انتخاب دفاع نباید بر اساس عملکرد آن تحت همان حمله‌ای انجام شود که در آموزش استفاده شده است. اعتبار نهایی این افزایش مقاومت و احتمال وجود پوشاندن گرادیان در بخش بعدی با مجموعه‌ای از آزمون‌های مستقل بررسی می‌شود.

۱-۵- ارزیابی پوشاندن گرادیان

افزایش دقت تحت یک حمله گرادیانی، به‌تنهایی اثبات نمی‌کند که مدل واقعاً مقاوم شده است. ممکن است دفاع، گرادیان را ناپیوسته، تصادفی، بسیار کوچک یا گمراه‌کننده کند و در نتیجه حمله نتواند نمونه خصمانه مناسبی پیدا کند؛ درحالی‌که مدل همچنان در برابر حملات دیگر آسیب‌پذیر باشد. این وضعیت با عنوان پوشاندن یا مبهم‌سازی گرادیان شناخته می‌شود.

مطابق صورت تمرین، احتمال وقوع این پدیده با افزایش تعداد گام‌ها و شروع‌های تصادفی PGD، حمله انتقالی از یک مدل جانشین مستقل، مقایسه White-box و Black-box، اجرای EOT و استفاده از AutoAttack بررسی شد. تمام ارزیابی‌های این بخش روی کل ۱۰۰۰۰ نمونه آزمون رسمی و برای مدل پایه، FGSM-AT و PGD-AT انجام شدند. تنظیمات و نتایج اجرای کامل نیز در نوت‌بوک نهایی ثبت شده‌اند.

از آنجا که PGD منتخب Compute-aware برای کاهش هزینه ارزیابی‌های میانی انتخاب شده بود، ممیزی پوشاندن گرادیان بر تنظیم‌های مستقل و قوی‌تر شامل PGD چهل‌مرحله‌ای با چند شروع تصادفی، EOT-PGD و AutoAttack متکی است. بنابراین، حکم نهایی این بخش بر مبنای PGD منتخب Compute-aware صادر نمی‌شود.

۱-۵-۱- افزایش گام‌ها و Random Restartهای PGD

نخست بررسی شد که آیا افزایش قدرت PGD باعث فروپاشی ناگهانی دقت مقاوم می‌شود یا خیر. برای این منظور، حمله PGD با کران ثابت $\epsilon = \frac{8}{255}$، تعداد گام‌های ۱۰، ۲۰ و ۴۰ و تعداد شروع‌های تصادفی ۱، ۳ و ۵ اجرا شد. برای هر مدل در مجموع نه تنظیم ارزیابی شد.

اندازه گام این ممیزی از تنظیم دارای کمترین دقت در شبکه اعتبارسنجی گرفته شد. این مقدار برای Fashion-MNIST برابر $\frac{2}{255}$ بود. در CIFAR-10 تمام تنظیمات شبکه اعتبارسنجی دقت صفر ایجاد کرده بودند؛ بنابراین ردیف ثبت‌شده به‌عنوان قوی‌ترین تنظیم، یعنی $\alpha = \frac{1}{255}$، برای ممیزی استفاده شد.

در جدول ۱-۱۱، PGD ضعیف به تنظیم ۱۰ گام و یک restart اشاره دارد. ستون PGD منتخب همان تنظیم Compute-aware بخش ۱-۳ با ۱۰ گام و سه restart است. PGD قوی نیز از ۴۰ گام و پنج restart استفاده می‌کند.

*جدول ۱–۱۱: اثر افزایش تعداد گام‌ها و شروع‌های تصادفی **PGD** بر دقت مقاوم*

مجموعه‌داده	مدل	PGD ضعیف 10×1	PGD منتخب 10×3	PGD قوی 40×5	افت ضعیف تا قوی
Fashion-MNIST	مدل پایه	۶۳.۷۱٪	۶۳.۴۳٪	۶۲.۷۱٪	۱.۰۰ واحد درصد
Fashion-MNIST	FGSM-AT	۷۷.۰۵٪	۷۶.۹۵٪	۷۶.۶۴٪	۰.۴۱ واحد درصد
Fashion-MNIST	PGD-AT	۷۸.۷۷٪	۷۸.۶۸٪	۷۸.۵۴٪	۰.۲۳ واحد درصد
CIFAR-10	مدل پایه	۰.۰۷٪	۰.۰۲٪	۰.۰۱٪	۰.۰۶ واحد درصد
CIFAR-10	FGSM-AT	۳۲.۴۲٪	۲۵.۸۳٪	۲۴.۶۰٪	۷.۸۲ واحد درصد
CIFAR-10	PGD-AT	۳۹.۱۱٪	۳۴.۸۲٪	۳۴.۴۱٪	۴.۷۰ واحد درصد

در Fashion-MNIST افزایش قدرت حمله فقط کاهش محدودی در دقت ایجاد کرده است. این پایداری نشان می‌دهد نتایج دفاع‌ها به یک تنظیم ضعیف PGD وابسته نیستند و حمله با افزایش تعداد تکرارها به‌تدریج به حالت اشباع رسیده است. همچنین PGD قوی هیچ‌گاه از نسخه ضعیف‌تر دقت بیشتری تولید نکرده است؛ بنابراین رفتار غیرعادی ناشی از شکست بهینه‌سازی مشاهده نمی‌شود.

در CIFAR-10، افزایش قدرت حمله اثر محسوس‌تری بر دو مدل دفاعی دارد. این کاهش نشان می‌دهد PGD ضعیف بخشی از مقاومت را بیش‌برآورد کرده است، اما افت دقت ناگهانی یا فاجعه‌آمیز نیست. بیشترین افت مشاهده‌شده ۷.۸۲ واحد درصد است و از آستانه عملی ۲۰ واحد درصدی تعیین‌شده برای علامت‌گذاری فروپاشی مشکوک در این آزمایش کمتر است. این آستانه صرفاً یک معیار هشدار مهندسی است و به‌تنهایی مبنای تشخیص Gradient Masking محسوب نمی‌شود؛ ازاین‌رو، نتیجه با حمله انتقالی، EOT و AutoAttack نیز بررسی شده است. علاوه بر این، دقت PGD قوی به نتایج White-box، EOT و AutoAttack نزدیک است؛ بنابراین کاهش آن با افزایش واقعی قدرت حمله سازگار است، نه با آشکارشدن ناگهانی یک دفاع مبتنی بر پوشاندن گرادیان.

مدل پایه CIFAR-10 از همان PGD ضعیف تقریباً به‌طور کامل شکست خورده است. ازاین‌رو، ثابت‌ماندن دقت نزدیک به صفر تحت تنظیم قوی‌تر، نشانه مقاومت نیست؛ بلکه نشان می‌دهد برای توضیح شکست مدل نیازی به فرض پوشاندن گرادیان وجود ندارد.

۱-۵-۲- حمله انتقالی و مقایسه White-box و Black-box

برای ارزیابی حمله انتقالی، برای هر مجموعه‌داده یک مدل جانشین با معماری مستقل آموزش داده شد. مدل جانشین Fashion-MNIST از یک CNN سه‌مرحله‌ای و مدل جانشین CIFAR-10 از یک CNN سبک VGGمانند استفاده می‌کند. این مدل‌ها از وزن‌های تصادفی آموزش داده شدند و هیچ وزن، checkpoint یا پارامتری از مدل‌های هدف دریافت نکردند.

دقت پاک مدل جانشین Fashion-MNIST برابر ۷۶.۵۶ درصد و دقت پاک مدل جانشین CIFAR-10 برابر ۸۸.۵۰ درصد بود. بنابراین هر دو مدل توانایی کافی برای یادگیری ساختار داده و تولید نمونه‌های انتقالی معنادار داشتند.

در حمله White-box، PGD قوی با استفاده مستقیم از گرادیان هر مدل هدف تولید شد. در حالت Black-box، همان تنظیم حمله روی مدل جانشین اجرا و نمونه‌های حاصل بدون دسترسی به گرادیان مدل‌های هدف روی هر سه مدل ارزیابی شدند. در هر دو حالت از ۴۰ گام، پنج restart، کران $\frac{8}{255}$ و کل مجموعه آزمون استفاده شد.

*جدول ۱-۱۲: مقایسه **PGD** قوی **White-box** با حمله انتقالی **Black-box***

مجموعه‌داده	مدل هدف	دقت پاک مدل جانشین	دقت White-box	دقت Transfer Black-box	اختلاف Black-box با White-box
Fashion-MNIST	مدل پایه	۷۶.۵۶٪	۶۲.۷۵٪	۸۶.۵۹٪	۲۳.۸۴ واحد درصد
Fashion-MNIST	FGSM-AT	۷۶.۵۶٪	۷۶.۶۳٪	۸۷.۲۱٪	۱۰.۵۸ واحد درصد
Fashion-MNIST	PGD-AT	۷۶.۵۶٪	۷۸.۵۵٪	۸۶.۱۴٪	۷.۵۹ واحد درصد
CIFAR-10	مدل پایه	۸۸.۵۰٪	۰.۰۱٪	۳۸.۴۴٪	۳۸.۴۳ واحد درصد
CIFAR-10	FGSM-AT	۸۸.۵۰٪	۲۴.۵۴٪	۶۴.۶۲٪	۴۰.۰۸ واحد درصد
CIFAR-10	PGD-AT	۸۸.۵۰٪	۳۴.۴۰٪	۵۹.۸۰٪	۲۵.۴۰ واحد درصد

در تمام مدل‌ها، حمله White-box از حمله انتقالی قوی‌تر است؛ یعنی دقت باقی‌مانده تحت حمله White-box کمتر است. این ترتیب قابل انتظار است، زیرا حمله White-box به گرادیان دقیق مدل هدف دسترسی دارد، درحالی‌که موفقیت حمله انتقالی به شباهت مرزهای تصمیم مدل جانشین و هدف وابسته است.

اگر حمله انتقالی به‌طور نظام‌مند از حمله White-box قوی‌تر بود، می‌توانست نشانه‌ای باشد که گرادیان مدل هدف برای حمله مستقیم اطلاعات مناسبی فراهم نمی‌کند. چنین الگویی در نتایج مشاهده نشد. بنابراین مقایسه White-box و Black-box شواهدی به نفع پوشاندن گرادیان ارائه نمی‌کند.

بااین‌حال، حمله انتقالی نیز کاملاً ناموفق نیست. به‌ویژه در CIFAR-10، نمونه‌های تولیدشده روی مدل جانشین عملکرد هر سه مدل هدف را نسبت به حالت پاک کاهش می‌دهند. این نتیجه نشان می‌دهد بخشی از جهت‌های آسیب‌پذیر میان معماری‌های متفاوت مشترک‌اند، هرچند حمله انتقالی به قدرت حمله مستقیم نمی‌رسد.

اختلاف جزئی میان دقت White-box جدول ۱-۱۲ و مقدار PGD قوی جدول ۱-۱۱ ناشی از اجرای مستقل حمله و نمونه‌گیری مجدد نقاط شروع تصادفی است. این تفاوت‌ها کوچک‌اند و نتیجه مقایسه را تغییر نمی‌دهند.

۱-۵-۳- ارزیابی EOT و AutoAttack

روش Expectation over Transformation برای حمله به مدل‌هایی طراحی شده است که در زمان استنتاج دارای مؤلفه تصادفی هستند. در این مدل‌ها، گرادیان یک اجرای منفرد ممکن است نماینده گرادیان مورد انتظار نباشد. EOT این مسئله را با میانگین‌گیری از چند اجرای مستقل برطرف می‌کند:

$$\mathcal{L}_{EOT}(x,y) = \frac{1}{K}\sum_{k=1}^{K}\mathcal{L}_{CE}\left(f_\theta^{w_k}(x), y\right)$$

$$g_{EOT} = \nabla_x \mathcal{L}_{EOT}(x,y) = \frac{1}{K}\sum_{k=1}^{K}\nabla_x \mathcal{L}_{CE}\left(f_\theta^{w_k}(x), y\right)$$

در آزمایش حاضر، EOT-PGD با ۴۰ گام، سه restart، ده نمونه گرادیانی در هر گام و میانگین‌گیری از ۲۰ پیش‌بینی اجرا شد. برای ایجاد مقایسه کنترل‌شده، PGD معمولی و EOT-PGD از نمونه‌ها، بذر حمله، تعداد گام‌ها، restartها و اندازه گام یکسان استفاده کردند.

دفاع‌های FGSM-AT و PGD-AT در زمان استنتاج تصادفی نیستند. این موضوع با اجرای ۲۰ forward تکراری روی ۱۲۸ نمونه نیز بررسی شد و بیشینه انحراف معیار logit برای تمام مدل‌ها دقیقاً صفر بود. بااین‌حال، EOT برای هر سه مدل و روی کل مجموعه آزمون اجرا شد تا نبود تصادفی‌بودن پنهان به‌صورت تجربی تأیید شود.

علاوه بر EOT، مجموعه استاندارد AutoAttack با کران ۲۵۵/۸ اجرا شد. این مجموعه شامل حملات زیر است:

$$APGD-CE,\quad APGD-T,\quad FAB-T,\quad Square\ Attack$$

ترکیب حملات گرادیانی بدون نیاز به تنظیم دستی و Square Attack مبتنی بر Query، وابستگی نتیجه به یک تابع هدف یا یک روش بهینه‌سازی خاص را کاهش می‌دهد. تمام اجزای AutoAttack روی کل ۱۰۰۰۰ نمونه آزمون اجرا شدند.

*جدول ۱-۱۳: مقایسه **PGD** معمولی، **EOT-PGD** و **AutoAttack***

مجموعه‌داده	مدل	PGD معمولی 40×3	EOT-PGD 40×3	اختلاف EOT با PGD	AutoAttack
Fashion-MNIST	مدل پایه	۶۲.۸۱٪	۶۲.۸۱٪	۰.۰۰ واحد درصد	۶۲.۶۷٪
Fashion-MNIST	FGSM-AT	۷۶.۶۸٪	۷۶.۶۸٪	۰.۰۰ واحد درصد	۷۶.۴۲٪
Fashion-MNIST	PGD-AT	۷۸.۵۹٪	۷۸.۵۹٪	۰.۰۰ واحد درصد	۷۸.۱۸٪
CIFAR-10	مدل پایه	۰.۰۱٪	۰.۰۱٪	۰.۰۰ واحد درصد	۰.۰۱٪
CIFAR-10	FGSM-AT	۲۴.۵۵٪	۲۴.۵۵٪	۰.۰۰ واحد درصد	۲۱.۶۹٪
CIFAR-10	PGD-AT	۳۴.۴۰٪	۳۴.۴۰٪	۰.۰۰ واحد درصد	۳۰.۷۳٪

برابری دقیق PGD معمولی و EOT-PGD با انحراف معیار صفر logits سازگار است. ازآنجاکه خروجی مدل در اجراهای تکراری تغییر نمی‌کند، میانگین‌گیری EOT همان گرادیان حمله معمولی را بازتولید می‌کند. بنابراین هیچ شاهدی از دفاع تصادفی پنهان یا شکست حمله به علت نوسان مسیر گرادیان وجود ندارد.

AutoAttack برای تمام مدل‌ها دقتی برابر یا کمتر از PGD قوی ایجاد کرده است. این ترتیب مورد انتظار است؛ زیرا AutoAttack چند تابع هدف و چند سازوکار حمله را ترکیب می‌کند. در Fashion-MNIST اختلاف AutoAttack با PGD محدود است و نتایج حملات مختلف عملاً به یک برآورد مشترک از مقاومت همگرا شده‌اند.

در CIFAR-10، AutoAttack نسبت به PGD حدود ۲.۹ واحد درصد دقت FGSM-AT و ۳.۷ واحد درصد دقت PGD-AT را کاهش می‌دهد. این اختلاف نشان می‌دهد مجموعه متنوع AutoAttack نمونه‌هایی را پیدا می‌کند که PGD با تابع Cross-Entropy به آن‌ها نرسیده است؛ بااین‌حال، کاهش حاصل ناگهانی و غیرعادی نیست. بنابراین نتایج PGD دفاع‌ها را اندکی خوش‌بینانه برآورد کرده‌اند، اما مقاومت مشاهده‌شده صرفاً محصول شکست PGD نیست.

۱-۵-۴- حکم نهایی درباره مقاومت واقعی

شواهد حاصل از آزمون‌های مختلف باید به‌صورت یکپارچه تفسیر شوند. در هیچ‌یک از شش ترکیب مجموعه‌داده و مدل، افزایش تعداد گام‌ها یا restartها باعث افزایش غیرمنتظره دقت مقاوم نشد. همچنین فروپاشی بیش از ۲۰ واحد درصد میان PGD ضعیف و قوی، قوی‌ترشدن حمله Black-box نسبت به White-box، برتری غیرعادی AutoAttack نسبت به دقت پاک یا اختلاف معنادار EOT با PGD معمولی مشاهده نشد.

برای Fashion-MNIST، نتایج PGD قوی، EOT و AutoAttack بسیار نزدیک‌اند. هر دو دفاع دقت مقاوم را نسبت به مدل پایه افزایش داده‌اند و این افزایش تحت حملات مستقل نیز حفظ شده است. بنابراین مقاومت ایجادشده توسط FGSM-AT و PGD-AT را نمی‌توان صرفاً با پوشاندن گرادیان توضیح داد. PGD-AT بیشترین مقاومت را فراهم می‌کند، هرچند فاصله آن با FGSM-AT محدود است.

در CIFAR-10، مدل پایه تحت تمام حملات قوی دقتی تقریباً صفر دارد. در این مدل نیز شواهدی از پوشاندن گرادیان دیده نمی‌شود، اما این نتیجه به معنی مقاوم‌بودن مدل نیست؛ حملات مختلف به‌طور سازگار نشان می‌دهند که مدل پایه عملاً فاقد مقاومت خصمانه در کران $\frac{8}{255}$ است.

دو مدل دفاعی CIFAR-10 تحت PGD قوی، EOT و AutoAttack دقت غیرصفر و هم‌جهتی دارند. بنابراین دفاع‌ها واقعاً بخشی از مقاومت را افزایش داده‌اند و نتیجه صرفاً ناشی از شکست یک حمله خاص نیست. بااین‌حال، فاصله دقت پاک و مقاوم همچنان زیاد است و AutoAttack بخش دیگری از آسیب‌پذیری را آشکار می‌کند. ازاین‌رو، این مدل‌ها را باید «مقاوم‌تر از مدل پایه» دانست، نه «کاملاً مقاوم».

بر مبنای محدوده تهدید بررسی‌شده، یعنی حملات بدون هدف با نرم L_∞ و کران $\frac{8}{255}$، نتیجه نهایی چنین است: شواهد تجربی از Gradient Masking یا بیش‌برازش صرف به یک حمله مشاهده نشد و افزایش مقاومت مدل‌های دفاعی توسط چند حمله

مستقل پشتیبانی می‌شود. این حکم یک تضمین مطلق امنیتی نیست و فقط در محدوده داده‌ها، کران اختلال و حملات اجراشده معتبر است.

۱-۶- تحلیل تکمیلی توضیح‌پذیری مبتنی بر مفهوم

برای پوشش بخش امتیازی تمرین، علاوه بر اجرای آزمایش‌های مقاومت روی هر دو مجموعه‌داده، از روش TCAV برای بررسی حساسیت مدل‌ها به مفاهیم سطح‌بالای قابل‌تعریف توسط انسان استفاده شد. هدف این تحلیل، مقایسه ساختار حساسیت مفهومی مدل پایه و مدل PGD-AT است؛ بنابراین نتایج TCAV مکمل ارزیابی‌های خصمانه‌اند و به‌عنوان معیاری برای اثبات مقاومت یا استدلال علّی مدل در نظر گرفته نمی‌شوند.

۱-۶-۱- طراحی آزمایش TCAV

روش TCAV بررسی می‌کند که خروجی یک کلاس تا چه اندازه در راستای یک مفهوم تعریف‌شده در فضای فعال‌سازی‌های میانی مدل تغییر می‌کند. برای یک لایه میانی l، ابتدا فعال‌سازی نمونه‌های مفهوم و نمونه‌های مرجع استخراج می‌شود. سپس یک جهت خطی موسوم به بردار فعال‌سازی مفهوم یا CAV به‌دست می‌آید که جهت تمایز مفهوم از مرجع را در فضای بازنمایی لایه مشخص می‌کند.

اگر $z_l(x)$ بازنمایی ورودی x در لایه l، $f_k(x)$ خروجی مربوط به کلاس k و v_C^l بردار مفهوم C باشد، حساسیت جهت‌دار به‌صورت زیر تعریف می‌شود:

$$S_{C,k,l}(x) = \nabla_{z_l} f_k(x)^T v_C^l$$

$$SignCount_{C,k,l} = \frac{1}{N}\sum_{i=1}^{N} 1\left[S_{C,k,l}(x_i) > 0\right]$$

$$Magnitude_{C,k,l} = \frac{1}{N}\sum_{i=1}^{N} S_{C,k,l}(x_i)$$

مقدار Sign-count سهم نمونه‌های هدفی را نشان می‌دهد که حرکت در جهت مفهوم، خروجی کلاس هدف را افزایش می‌دهد. Magnitude نیز شدت متوسط این حساسیت جهت‌دار را منعکس می‌کند. مقدار بالای Sign-count به معنی تکرار بیشتر یک جهت اثر است، اما الزاماً نشان‌دهنده بزرگی زیاد آن اثر نیست؛ به همین دلیل، هر دو معیار به‌طور هم‌زمان گزارش شدند.

برای کاهش وابستگی نتیجه به انتخاب یک مجموعه مرجع خاص، مفهوم ثابت با ۳۰ مجموعه مرجع دارای نمونه‌گیری مستقل مقایسه شد. در هر مقایسه، دو Contrast زیر محاسبه شدند:

$$\Delta_{sign} = SignCount_C - SignCount_R$$

$$\Delta_{magnitude} = Magnitude_C - Magnitude_R$$

مقدار مثبت Contrast نشان می‌دهد جهت مفهوم نسبت به جهت مرجع غالب است و مقدار منفی بیانگر غلبه جهت مرجع است. این تفسیر نسبی است؛ بنابراین مقدار منفی به معنی استفاده علّی مدل از کلاس‌های مرجع نیست، بلکه فقط نشان می‌دهد حساسیت خروجی در راستای مفهوم انتخاب‌شده، نسبت به جهت مرجع کمتر بوده است.

طراحی کلاس‌های مفهوم، مرجع و هدف در جدول ۱-۱۴ ارائه شده است. این سه مجموعه در هر دو دیتاست کاملاً مجزا هستند. به‌ویژه، کلاس هدف مرتبط در ساخت مفهوم استفاده نشده است؛ برای مثال، مفهوم Footwear از Sandal و Sneaker ساخته شده و شامل Ankle boot نیست. به همین ترتیب، مفهوم Vehicle از Airplane، Ship و Truck ساخته شده و Automobile در مجموعه مفهوم قرار ندارد. این جداسازی مانع از آن می‌شود که نتیجه صرفاً بازتاب استفاده مستقیم از نمونه‌های همان کلاس هدف در ساخت CAV باشد.

جدول ۱-۱۴: طراحی مفاهیم، مجموعه‌های مرجع و کلاس‌های هدف در تحلیل ***TCAV***

مجموعه‌داده	لایه تحلیل	مفهوم	کلاس‌های مفهوم	کلاس‌های مرجع	هدف مرتبط	هدف نامرتبط
Fashion-MNIST	backbone.penultimate	Footwear	Sandal, Sneaker	Trouser, Pullover, Dress, Coat, Shirt, Bag	Ankle boot	T-shirt/top
CIFAR-10	backbone.avgpool	Vehicle	Airplane, Ship, Truck	Bird, Cat, Deer, Frog, Horse	Automobile	Dog

انتخاب یک هدف مرتبط و یک هدف نامرتبط، یک کنترل معنایی درون‌دیتاستی ایجاد می‌کند. انتظار می‌رود مفهوم Footwear با خروجی Ankle boot هم‌راستا و با T-shirt/top ناهم‌راستا باشد. به همین ترتیب، مفهوم Vehicle باید با Automobile هم‌راستا و با Dog ناهم‌راستا باشد. در نتیجه، تحلیل فقط بالا یا پایین‌بودن یک TCAV score را بررسی نمی‌کند، بلکه توانایی روش در جداسازی دو هدف با ارتباط معنایی متفاوت را نیز می‌سنجد.

برای هر دیتاست، ۲۵۰ تصویر مفهوم از تقسیم آموزش و بدون Data Augmentation انتخاب شد. هر یک از ۳۰ مجموعه مرجع نیز شامل ۲۵۰ تصویر بود و نمونه‌ها تقریباً به‌طور متوازن از کلاس‌های تشکیل‌دهنده انتخاب شدند. تحلیل روی مدل پایه و PGD-AT انجام شد تا اثر قوی‌ترین دفاع بررسی‌شده بر ساختار حساسیت مفهومی مطالعه شود.

برای هر کلاس هدف، حداکثر ۱۲۸ تصویر از مجموعه آزمون انتخاب شد که مدل مورد تحلیل آن‌ها را در حالت پاک به‌درستی طبقه‌بندی می‌کرد. در تمام هشت ترکیب دیتاست، مدل و کلاس هدف، تعداد کامل ۱۲۸ نمونه در دسترس بود. بنابراین اختلاف نتایج مدل پایه و PGD-AT ناشی از کمبود تعداد نمونه هدف در یکی از مدل‌ها نیست. طراحی نهایی، مجزابودن مجموعه‌ها و استفاده انحصاری از نمونه‌های پاک و صحیح هدف در خروجی نوت‌بوک کنترل و ثبت شده است.

برای هر Contrast، میانگین و فاصله اطمینان ۹۵ درصد در میان ۳۰ مجموعه مرجع محاسبه شد. علاوه بر آن، آزمون علامت دقیق دوطرفه بر اختلاف‌های زوجی غیرصفر اجرا شد. این آزمون فقط بررسی می‌کند که جهت اختلاف در چند مجموعه مرجع

مثبت یا منفی بوده است و به بزرگی اختلاف وابسته نیست. در مقابل، فاصله اطمینان میانگین و آزمون t زوجی به مقدار اختلاف‌ها نیز حساس هستند؛ ازاین‌رو، این دو نوع شواهد ممکن است در نتایج مرزی دقیقاً یک حکم آماری ارائه نکنند.

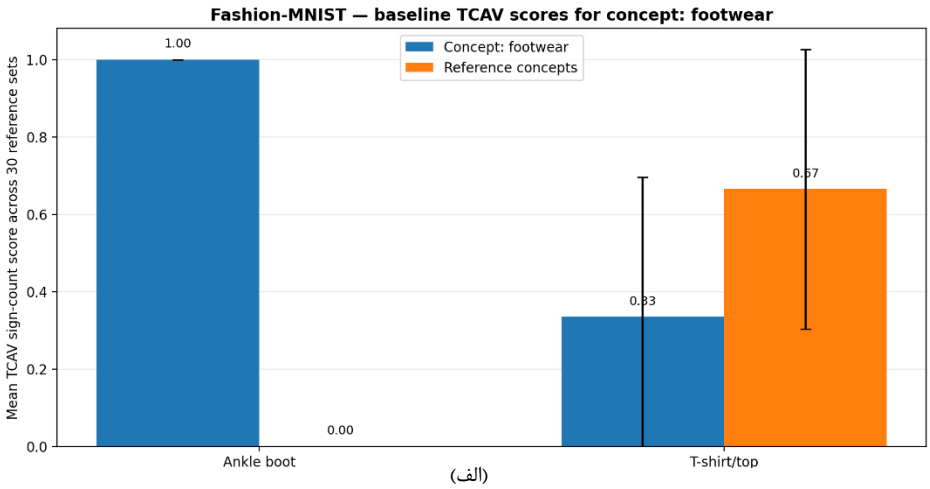
۱-۶-۲- نتایج TCAV و مقایسه مدل پایه با PGD-AT

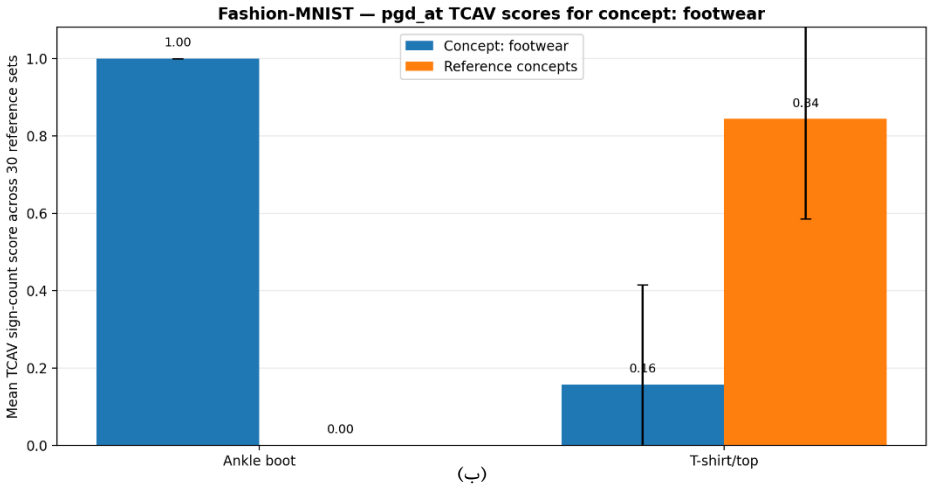
نتایج عددی TCAV در جدول ۱-۱۵ ارائه شده‌اند. ستون‌های Sign-count میانگین امتیاز مفهوم و مرجع را در ۳۰ مقایسه نشان می‌دهند. دو ستون Contrast نیز میانگین اختلاف مفهوم و مرجع را همراه با فاصله اطمینان ۹۵ درصد گزارش می‌کنند. مقدار p_{sign} مربوط به آزمون علامت دقیق است.

*جدول ۱-۱۵: نتایج **TCAV** برای مدل پایه و **PGD-AT***

مجموعه‌داده	مدل	کلاس هدف	Sign-count مفهوم	Sign-count مرجع	Contrast علامت و CI 95%	Contrast بزرگی و CI 95%	p_{sign}
Fashion-MNIST	مدل پایه	Ankle boot	۱.۰۰۰	۰.۰۰۰	+1.000 [1.000,1.000]	+2.988 [2.723, 3.253]	1.86×10^{-9}
Fashion-MNIST	مدل پایه	T-shirt/top	۰.۳۳۵	۰.۶۶۵	−0.330 [−0.600, −0.060]	−0.281 [−0.488, −0.074]	0.0987
Fashion-MNIST	PGD-AT	Ankle boot	۱.۰۰۰	۰.۰۰۰	+1.000 [1.000,1.000]	+1.168 [1.021, 1.315]	1.86×10^{-9}
Fashion-MNIST	PGD-AT	T-shirt/top	۰.۱۵۷	۰.۸۴۳	−0.686 [−0.879, −0.494]	−0.238 [−0.312, −0.165]	1.52×10^{-5}
CIFAR-10	مدل پایه	Automobile	۰.۹۶۷	۰.۰۳۳	+0.933 [0.797, 1.000]	+4.398 [3.837, 4.960]	5.77×10^{-8}
CIFAR-10	مدل پایه	Dog	۰.۰۰۰	۱.۰۰۰	−1.000 [−1.000, −1.000]	−2.933 [−3.242, −2.624]	1.86×10^{-9}
CIFAR-10	PGD-AT	Automobile	۱.۰۰۰	۰.۰۰۰	+1.000 [1.000,1.000]	+4.090 [3.817, 4.363]	1.86×10^{-9}
CIFAR-10	PGD-AT	Dog	۰.۰۰۰	۱.۰۰۰	−1.000 [−1.000, −1.000]	−2.756 [−2.911, −2.601]	1.86×10^{-9}

در Fashion-MNIST، جهت Footwear برای Ankle boot در مدل پایه و PGD-AT در تمام ۳۰ مجموعه مرجع مثبت بوده است. در مقابل، حساسیت T-shirt/top عمدتاً در جهت مخالف مفهوم Footwear قرار دارد. این الگو نشان می‌دهد بازنمایی هر دو مدل میان هدف مرتبط و نامرتبط تمایز مفهومی ایجاد کرده است.

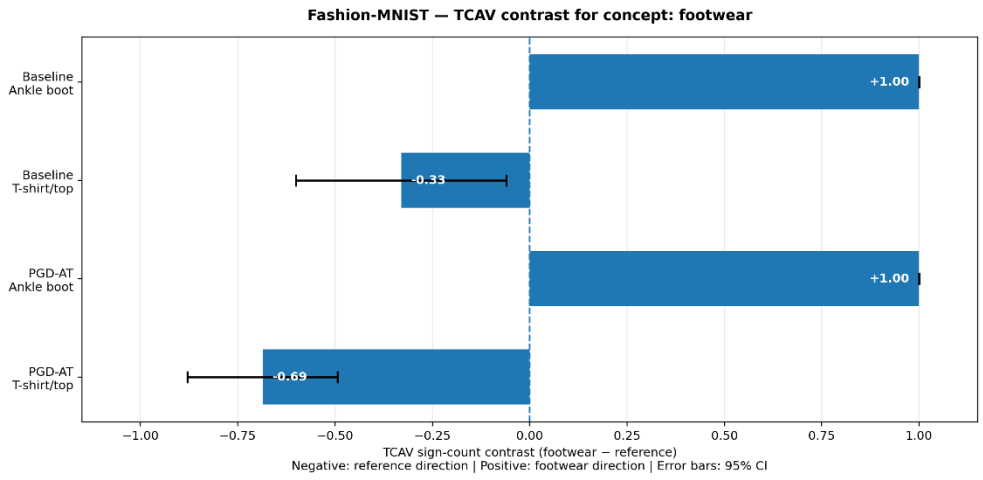




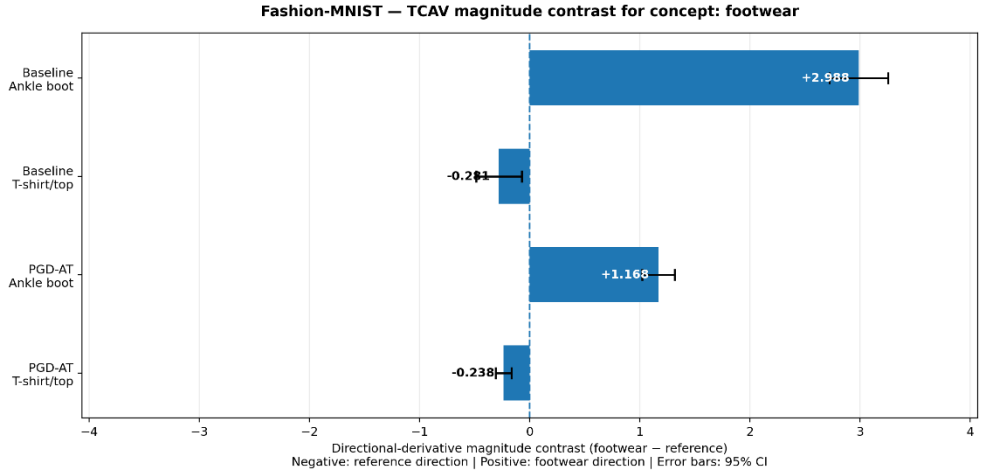
*شکل ۱–۱۳: میانگین **TCAV sign-count** مفهوم **Footwear** و مجموعه‌های مرجع برای کلاس‌های **Ankle boot** و **T-shirt/top** در **Fashion-MNIST**؛ پنل (الف) مدل پایه و پنل (ب) مدل **PGD-AT** را نشان می‌دهد. میله‌های خطا بیانگر انحراف معیار امتیازها در میان ۳۰ مجموعه مرجع هستند.*

در مدل پایه، نتیجه T-shirt/top نسبت به سایر ردیف‌ها یکنواختی کمتری دارد. میانگین Contrast آن منفی است و فاصله اطمینان میانگین صفر را شامل نمی‌شود، اما فقط ۲۰ مورد از ۳۰ مقایسه جهت منفی داشته‌اند و آزمون علامت به سطح ۰.۰۵ نمی‌رسد. بنابراین شواهد مدل پایه برای ناهم‌راستایی T-shirt/top با Footwear از نظر اندازه متوسط قابل مشاهده، اما از نظر ثبات جهت میان مجموعه‌های مرجع محدودتر است.

پس از PGD-AT، ۲۶ مقایسه دارای Contrast منفی، سه مقایسه مثبت و یک مقایسه صفر بوده‌اند. در نتیجه، جهت ناهم‌راستایی T-shirt/top با Footwear در میان مجموعه‌های مرجع پایدارتر شده است. هم‌زمان، Contrast علامت برای Ankle boot در مقدار بیشینه باقی مانده است. این تغییر از افزایش جداسازی جهت حساسیت میان هدف مرتبط و نامرتبط حمایت می‌کند، اما به معنی افزایش شدت تمام حساسیت‌های مفهومی نیست.



(الف)

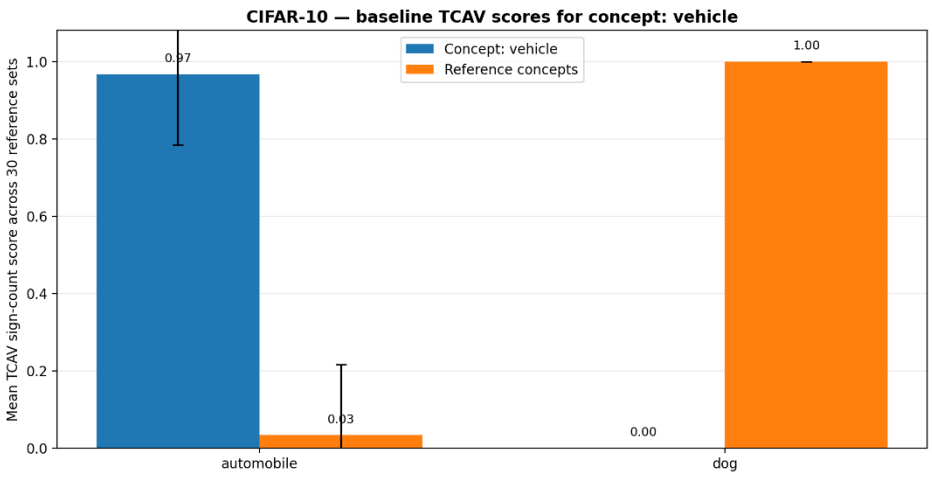


(ب)

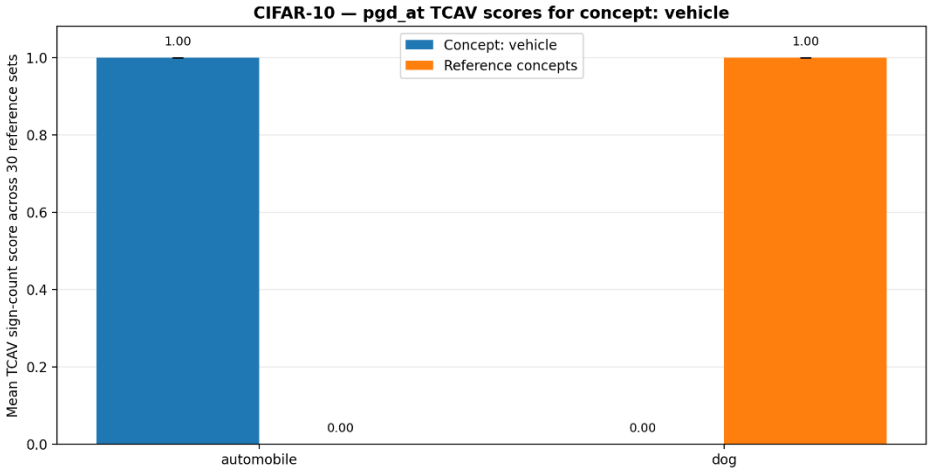
*شکل ۱–۱۴: **Contrast**های **TCAV** در **Fashion-MNIST** برای مدل پایه و **PGD-AT**؛ پنل (الف) اختلاف **Sign-count** و پنل (ب) اختلاف بزرگی مشتق جهت‌دار را نشان می‌دهد. مقادیر مثبت بیانگر غلبه جهت **Footwear** و مقادیر منفی بیانگر غلبه جهت مرجع هستند؛ میله‌های خطا فاصله اطمینان ۹۵ درصد*

مقایسه Magnitude نشان می‌دهد شدت حساسیت Ankle boot در راستای Footwear پس از PGD-AT کاهش یافته، هرچند جهت اثر همچنان در تمام مجموعه‌ها مثبت است. بنابراین دفاع، علامت رابطه مفهومی را حفظ کرده ولی اندازه مشتق جهت‌دار را افزایش نداده است. برای T-shirt/top نیز اندازه متوسط Contrast اندکی به صفر نزدیک‌تر شده، اما ثبات علامت منفی بیشتر شده است. این تفاوت تأکید می‌کند که Sign-count و Magnitude جنبه‌های متفاوتی از حساسیت مدل را اندازه می‌گیرند و نباید به‌جای یکدیگر تفسیر شوند.

در CIFAR-10، مدل پایه در ۲۹ مجموعه از ۳۰ مجموعه مرجع برای Automobile جهت مثبت Vehicle نشان می‌دهد و برای Dog در تمام مجموعه‌ها جهت منفی دارد. در مدل PGD-AT، هر دو جهت به توافق کامل ۳۰ از ۳۰ می‌رسند. در نتیجه، جداسازی معنایی هدف مرتبط و نامرتبط در هر دو مدل بسیار روشن است.



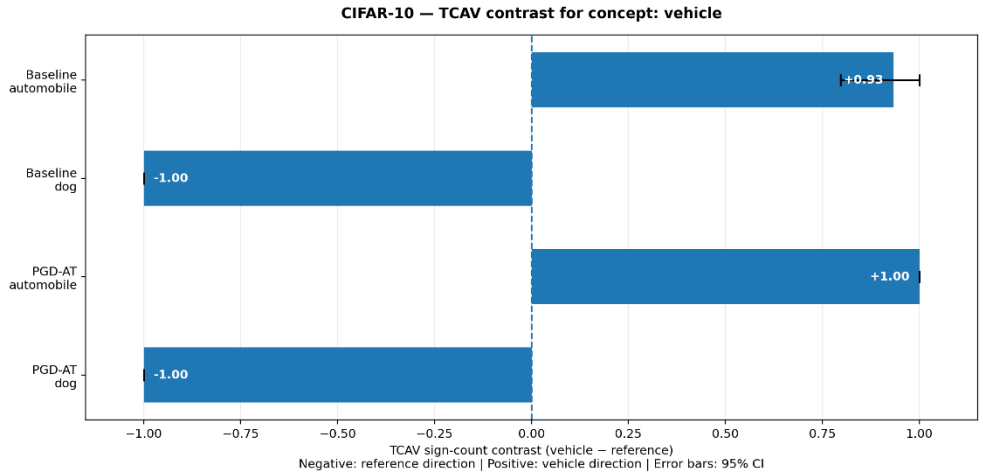
(الف)



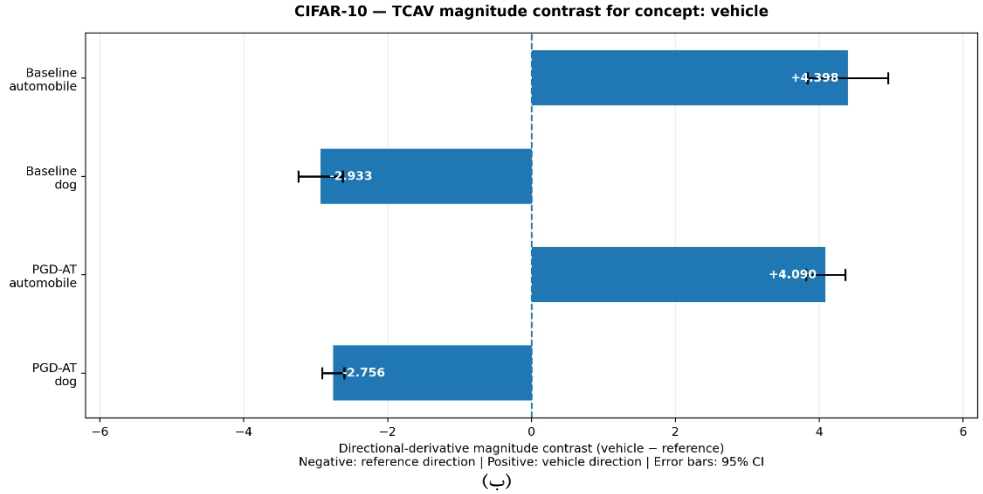
(ب)

*شکل ۱–۱۵: میانگین **TCAV sign-count** مفهوم **Vehicle** و مجموعه‌های مرجع برای کلاس‌های **Automobile** و **Dog** در **CIFAR-10**. پنل (الف) نتایج مدل پایه و پنل (ب) نتایج **PGD-AT** را نشان می‌دهد. میله‌های خطا بیانگر انحراف معیار امتیازها در میان ۳۰ مجموعه مرجع هستند.*

این نتیجه اهمیت طراحی مجزای کلاس‌ها را نشان می‌دهد. Automobile در مجموعه نمونه‌های مفهوم وجود نداشته است، اما CAV ساخته‌شده از Airplane، Ship و Truck همچنان با خروجی Automobile هم‌راستا است. بنابراین جهت آموخته‌شده فقط یک آشکارساز برای یک کلاس منفرد نیست و بخشی از ساختار مشترک میان کلاس‌های وسیله نقلیه را منعکس می‌کند.



(الف)



(ب)

*شکل ۱–۱۶: **Contrast**های **TCAV** در **CIFAR-10** برای مدل پایه و **PGD-AT**؛ پنل (الف) **Contrast** علامت و پنل (ب) **Contrast** بزرگی مشتق جهت‌دار را نشان می‌دهد. جهت مثبت متناظر با مفهوم **Vehicle** و جهت منفی متناظر با مجموعه‌های مرجع حیوانی است؛ میله‌های خطا فاصله اطمینان ۹۵ درصد را*

پس از PGD-AT، جهت اثر برای Automobile از ۲۹ مورد مثبت به توافق کامل ۳۰ مورد مثبت می‌رسد، اما Magnitude مثبت آن اندکی کاهش می‌یابد. برای Dog نیز علامت منفی در هر دو مدل کاملاً پایدار است و اندازه مطلق Contrast پس از دفاع کمی کمتر می‌شود. بنابراین PGD-AT ساختار جهت‌گیری معنایی Vehicle در برابر هدف حیوانی را حفظ کرده است، ولی شواهدی وجود ندارد که شدت این حساسیت را به‌طور عمومی افزایش داده باشد.

در ردیف‌هایی که تمام ۳۰ اختلاف دقیقاً هم‌جهت بوده‌اند، واریانس Sign-count Contrast صفر است. در این حالت، آزمون t زوجی به آماره نامتناهی و مقدار عددی $p = 0$ منجر می‌شود که تفسیر مناسبی برای گزارش نیست. به همین دلیل، این نتایج با آزمون علامت دقیق گزارش شدند. برای توافق کامل ۳۰ از ۳۰، مقدار دوطرفه آزمون علامت برابر 1.86×10^{-9} است و به‌جای ادعای «احتمال صفر»، توافق کامل جهت در تمام مجموعه‌های مرجع بیان می‌شود. نتایج کامل Contrast و آزمون علامت در خروجی نهایی نوت‌بوک ذخیره شده‌اند.

در مجموع، TCAV در هر دو مجموعه‌داده الگوی مورد انتظار را بازیابی کرده است: مفهوم انتخاب‌شده برای کلاس مرتبط جهت مثبت و برای کلاس نامرتبط جهت منفی دارد. PGD-AT این ساختار معنایی را از بین نبرده و در برخی موارد، به‌ویژه هدف نامرتبط Fashion-MNIST، ثبات جهت آن را افزایش داده است. بااین‌حال، کاهش برخی Magnitudeها نشان می‌دهد نمی‌توان دفاع را صرفاً عامل افزایش حساسیت مفهومی دانست. همچنین این تحلیل فقط روی تصاویر پاکی انجام شده که مدل آن‌ها را درست طبقه‌بندی کرده است؛ بنابراین رفتار مدل روی نمونه‌های اشتباه یا تصاویر خصمانه را مستقیماً توضیح نمی‌دهد و نباید به‌عنوان اثبات استدلال علّی یا مقاومت مدل تفسیر شود.

۱-۷- نکات پیاده‌سازی و ملاحظات عملی

در این بخش، اجزای مهم پیاده‌سازی حملات، آموزش خصمانه، ممیزی حملات قوی و کنترل طراحی TCAV بررسی می‌شوند. هدف، بازنویسی خط‌به‌خط کد نیست؛ بلکه نشان‌دادن تصمیم‌هایی است که صحت محدودیت حمله، مقایسه منصفانه مدل‌ها و جلوگیری از نشت اطلاعات را تضمین می‌کنند. توابع عمومی مربوط به بازتولیدپذیری، مدیریت داده و رسم نمودارها به دلیل سادگی نسبی در نوت‌بوک باقی مانده‌اند و تصویر جداگانه‌ای از آن‌ها در گزارش ارائه نمی‌شود.

جدول ۱–۱۶: توابع منتخب برای بررسی نکات مهم پیاده‌سازی

زیربخش	تابع	نقش اصلی
۱-۷-۱	FGSM	تولید حمله تک‌مرحله‌ای در فضای اصلی پیکسل
۱-۷-۱	RandomStartFGSM	تولید FGSM با شروع تصادفی و Projection
۱-۷-۱	PGD	اجرای حمله چندمرحله‌ای با چند Random Restart
۱-۷-۱	train_one_epoch	یکپارچه‌سازی آموزش پاک، FGSM-AT و PGD-AT
۲-۷-۱	pgd_grid_search	ارزیابی شبکه PGD و انتخاب تنظیم Compute-aware
۲-۷-۱	evaluate_transfer_pgd_multi_target	حمله انتقالی از مدل جانشین مستقل
۲-۷-۱	EOT_PGD	ممیزی گرادیان با میانگین‌گیری EOT
۲-۷-۱	evaluate_autoattack	اجرای مجموعه استاندارد AutoAttack و کنترل محدودیت‌ها
۳-۷-۱	validate_tcav_class_design	کنترل مجزابودن کلاس‌های مفهوم، مرجع و هدف

این مجموعه، مسیر اصلی آزمایش را از تولید نمونه خصمانه تا آموزش دفاع و ممیزی نهایی پوشش می‌دهد. انتخاب توابع به‌گونه‌ای انجام شده است که از نمایش کدهای تکراری یا کم‌اهمیت جلوگیری شود و در عین حال، تصمیم‌های مؤثر بر اعتبار نتایج قابل مشاهده باشند.

۱-۷-۱- پیاده‌سازی حملات و آموزش خصمانه

حملات FGSM، Random-start FGSM و PGD به‌صورت مستقیم در نوت‌بوک پیاده‌سازی شده‌اند و ورودی‌ها را در فضای اصلی پیکسل $[۰,۱]$ دریافت می‌کنند. نرمال‌سازی داده در نخستین لایه مدل انجام می‌شود؛ بنابراین گرادیان حمله نسبت به مقادیر واقعی پیکسل محاسبه شده و اعمال محدودیت L_∞ به‌طور مستقیم قابل کنترل است.

```python
def FGSM(model: nn.Module, images: torch.Tensor, labels: torch.Tensor, epsilon: float) -> tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
    """Generate an untargeted L-infinity FGSM attack in the original [0, 1] pixel domain."""
    was_training = model.training
    model.eval()

    clean = images.detach()
    attack_input = clean.clone().requires_grad_(True)
    logits = model(attack_input)
    loss = F.cross_entropy(logits, labels)
    gradient = torch.autograd.grad(loss, attack_input, only_inputs=True)[0]

    adversarial = torch.clamp(clean + epsilon * gradient.sign(), 0.0, 1.0).detach()
    perturbation = (adversarial - clean).detach()
    with torch.no_grad():
        adversarial_output = model(adversarial).detach()

    model.train(was_training)
    return adversarial, perturbation, adversarial_output
```

*شکل ۱–۱۷: پیاده‌سازی حمله **FGSM**؛ محاسبه گرادیان **Cross-Entropy** نسبت به ورودی، حرکت در جهت علامت گرادیان و محدودسازی تصویر خصمانه به دامنه معتبر پیکسل.*

تابع FGSM ابتدا وضعیت آموزش یا ارزیابی مدل را ذخیره کرده و مدل را موقتاً در حالت ارزیابی قرار می‌دهد. سپس یک نسخه مستقل از تصویر پاک با قابلیت محاسبه گرادیان ساخته می‌شود. پس از محاسبه Cross-Entropy Loss، گرادیان فقط نسبت به ورودی استخراج شده و تصویر خصمانه با یک گام به اندازه ϵ در جهت علامت گرادیان تولید می‌شود.

استفاده از torch.clamp تضمین می‌کند که مقدار پیکسل‌ها پس از حمله در بازه $[۰,۱]$ باقی بماند. تابع در پایان علاوه بر تصویر خصمانه، اختلال واقعی و خروجی مدل روی تصویر خصمانه را بازمی‌گرداند. همچنین وضعیت اولیه مدل بازیابی می‌شود تا فراخوانی حمله، حالت مدل را برای مراحل بعدی تغییر ندهد.

```python
def RandomStartFGSM(model: nn.Module, images: torch.Tensor, labels: torch.Tensor, epsilon: float, alpha: float) ->
tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
    """One-step FGSM from a random point in the L-infinity ball, followed by projection."""
    was_training = model.training
    model.eval()
    clean = images.detach()

    initial = clean + torch.empty_like(clean).uniform_(-epsilon, epsilon)
    initial = torch.clamp(initial, 0.0, 1.0).detach().requires_grad_(True)
    logits = model(initial)
    loss = F.cross_entropy(logits, labels)
    gradient = torch.autograd.grad(loss, initial, only_inputs=True)[0]

    adversarial = initial.detach() + alpha * gradient.sign()
    delta = torch.clamp(adversarial - clean, min=-epsilon, max=epsilon)
    adversarial = torch.clamp(clean + delta, 0.0, 1.0).detach()
    perturbation = adversarial - clean
    with torch.no_grad():
        output = model(adversarial).detach()

    model.train(was_training)
    return adversarial, perturbation.detach(), output
```

*شکل ۱–۱۸: پیاده‌سازی **Random-start FGSM**: آغاز از یک نقطه تصادفی در کره L_∞، اجرای یک گام گرادیانی و تصویرکردن نتیجه به کران مجاز اختلال.*

در RandomStartFGSM، حمله به‌جای شروع مستقیم از تصویر پاک، از نقطه‌ای تصادفی در بازه $[-\epsilon, \epsilon]$ پیرامون آن آغاز می‌شود. این شروع تصادفی تنوع نمونه‌های خصمانه مورد استفاده در آموزش را افزایش می‌دهد و احتمال وابستگی دفاع به یک جهت ثابت از گرادیان را کاهش می‌دهد.

پس از حرکت یک‌مرحله‌ای با اندازه گام α، اختلاف تصویر حاصل با تصویر پاک محاسبه و در بازه $[-\epsilon, \epsilon]$ محدود می‌شود. این Projection اهمیت ویژه‌ای دارد؛ زیرا در تنظیم CIFAR-10 مقدار $\alpha = \frac{10}{255}$ از $\epsilon = \frac{8}{255}$ بزرگ‌تر است، اما خروجی نهایی همچنان در کره مجاز قرار می‌گیرد. این تابع برای ساخت نمونه‌های دفاع FGSM-AT استفاده شده است.

```python
def PGD(model: nn.Module, images: torch.Tensor, labels: torch.Tensor, epsilon: float, alpha: float, steps: int, random_restarts: int) -> tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
    """Generate a multi-restart untargeted L-infinity PGD attack."""
    if random_restarts < 1:
        raise ValueError("random_restarts must be at least 1")

    was_training = model.training
    model.eval()
    clean = images.detach()
    best_adversarial = clean.clone()
    best_loss = torch.full((clean.size(0),), -float("inf"), device=clean.device)

    for _ in range(random_restarts):
        adversarial = clean + torch.empty_like(clean).uniform_(-epsilon, epsilon)
        adversarial = torch.clamp(adversarial, 0.0, 1.0).detach()

        for _ in range(steps):
            adversarial.requires_grad_(True)
            logits = model(adversarial)
            loss = F.cross_entropy(logits, labels)
            gradient = torch.autograd.grad(loss, adversarial, only_inputs=True)[0]

            adversarial = adversarial.detach() + alpha * gradient.sign()
            delta = torch.clamp(adversarial - clean, min=-epsilon, max=epsilon)
            adversarial = torch.clamp(clean + delta, 0.0, 1.0).detach()

        with torch.no_grad():
            final_logits = model(adversarial)
            per_sample_loss = F.cross_entropy(final_logits, labels, reduction="none")
            stronger = per_sample_loss > best_loss
            best_loss[stronger] = per_sample_loss[stronger]
            best_adversarial[stronger] = adversarial[stronger]

    with torch.no_grad():
        best_output = model(best_adversarial).detach()

    model.train(was_training)
    return best_adversarial.detach(), (best_adversarial - clean).detach(), best_output
```

*شکل ۱–۱۹: پیاده‌سازی حمله **PGD** چندمرحله‌ای و چندراه‌اندازی؛ به‌روزرسانی تکرارشونده ورودی، **Projection** پس از هر گام و انتخاب قوی‌ترین **restart** برای هر نمونه.*

تابع PGD برای هر restart از یک نقطه تصادفی در کره مجاز آغاز می‌کند و در هر مرحله، گرادیان Cross-Entropy Loss را نسبت به تصویر جاری محاسبه می‌کند. پس از هر حرکت، اختلال به بازه $[-\epsilon, \epsilon]$ تصویر شده و مقدار نهایی پیکسل نیز در محدوده $[۰,۱]$ نگه داشته می‌شود. بنابراین هیچ‌یک از به‌روزرسانی‌های میانی یا خروجی نهایی از مدل تهدید تعیین‌شده خارج نمی‌شوند.

پس از پایان هر restart، خطای هر نمونه به‌صورت جداگانه محاسبه می‌شود. سپس برای هر تصویر، خروجی restartی نگه داشته می‌شود که بیشترین Loss را ایجاد کرده است. این انتخاب نمونه‌به‌نمونه از انتخاب یک restart مشترک برای کل Batch دقیق‌تر است؛ زیرا قوی‌ترین نقطه شروع برای تصاویر مختلف الزاماً یکسان نیست.

```python
def train_one_epoch(model: nn.Module, loader: DataLoader, optimizer: torch.optim.Optimizer, adversarial_builder:
Optional[Callable[[nn.Module, torch.Tensor, torch.Tensor], torch.Tensor]] = None, clean_loss_weight: float = 0.0) -> float:
    if not 0.0 <= clean_loss_weight <= 1.0:
        raise ValueError("clean_loss_weight must be between 0 and 1.")

    model.train()
    running_loss = 0.0
    seen = 0

    for images, labels in tqdm(loader, leave=False):
        images = images.to(DEVICE, non_blocking=True)
        labels = labels.to(DEVICE, non_blocking=True)

        optimizer.zero_grad(set_to_none=True)
        if adversarial_builder is None:
            logits = model(images)
            loss = F.cross_entropy(logits, labels)
        else:
            adversarial = adversarial_builder(model, images, labels).detach()
            adversarial_logits = model(adversarial)
            adversarial_loss = F.cross_entropy(adversarial_logits, labels)
            if clean_loss_weight > 0:
                clean_logits = model(images)
                clean_loss = F.cross_entropy(clean_logits, labels)
                loss = clean_loss_weight * clean_loss + (1.0 - clean_loss_weight) * adversarial_loss
            else:
                loss = adversarial_loss

        loss.backward()
        optimizer.step()

        running_loss += float(loss.item()) * labels.size(0)
        seen += labels.size(0)

    return running_loss / max(seen, 1)
```

شکل ۱–۲۰: پیاده‌سازی حلقه عمومی آموزش؛ پشتیبانی مشترک از آموزش پاک و خصمانه و امکان ترکیب خطای نمونه پاک و نمونه خصمانه.

تابع train_one_epoch به‌گونه‌ای طراحی شده است که هر سه روش آموزش مدل پایه، FGSM-AT و PGD-AT را با یک حلقه مشترک اجرا کند. در حالت آموزش پاک، adversarial_builder برابر None است و تابع فقط Cross-Entropy Loss تصاویر اصلی را محاسبه می‌کند. در آموزش خصمانه، Builder مربوط به دفاع نمونه‌های خصمانه را تولید کرده و Loss بر اساس آن‌ها محاسبه می‌شود.

نمونه خصمانه پیش از مرحله اصلی پس‌انتشار با detach از گراف تولید حمله جدا می‌شود. در نتیجه، هنگام به‌روزرسانی وزن‌های مدل نیازی به نگهداری یا مشتق‌گیری مرتبه بالاتر از تمام مراحل ساخت حمله وجود ندارد. پارامتر clean_loss_weight نیز امکان ترکیب Loss پاک و خصمانه را برای FGSM-AT فراهم می‌کند، درحالی‌که مقدار صفر آن در PGD-AT موجب تمرکز کامل تابع هدف بر نمونه‌های خصمانه می‌شود.

استفاده از یک تابع آموزش مشترک باعث می‌شود عملیات صفرکردن گرادیان، پس‌انتشار، به‌روزرسانی بهینه‌ساز و محاسبه میانگین Loss در تمام مدل‌ها یکسان باقی بماند. بنابراین تفاوت مشاهده‌شده میان مدل‌ها به نوع داده آموزشی و تابع هدف دفاع مربوط است، نه تفاوت در ساختار حلقه آموزش.

۱-۷-۲- ارزیابی حملات قوی و مدیریت هزینه اجرا

ارزیابی مقاومت فقط به اجرای یک تنظیم ثابت PGD محدود نشده است. ابتدا شبکه کامل تنظیمات الزامی روی مجموعه اعتبارسنجی اجرا شد و سپس مدل‌ها با حمله انتقالی، EOT-PGD و AutoAttack بررسی شدند. در پیاده‌سازی این مراحل، علاوه بر قدرت حمله، کنترل تعداد نمونه‌ها، کران L_∞ و استقلال مدل جانشین نیز در نظر گرفته شده است.

```python
def pgd_grid_search(model: nn.Module, search_loader: DataLoader, dataset_name: str, search_samples: Optional[int] = None, tolerance: float = 0.005) -> tuple[pd.DataFrame, dict[str, Any], dict[str, Any]]:

    fixed_images, fixed_labels = collect_fixed_samples(search_loader, search_samples)

    fixed_loader = DataLoader(TensorDataset(fixed_images, fixed_labels), batch_size=DATASET_SPECS[dataset_name].batch_size, shuffle=False)

    actual_search_samples = len(fixed_loader.dataset)
    records = []

    for alpha in PGD_ALPHAS:
        for steps in PGD_STEPS:
            metrics = evaluate_attack(
                model,
                fixed_loader,
                attack_builder=lambda current_model, x, y, a=alpha, s=steps: PGD(current_model, x, y, epsilon=PGD_EPSILON, alpha=a, steps=s, random_restarts=PGD_SEARCH_RESTARTS),
            )

            records.append({
                "search_split": "heldout_validation_from_official_train",
                "official_test_used_for_selection": False,
                "validation_dataset_size": len(search_loader.dataset),
                "search_samples": actual_search_samples,
                "epsilon": PGD_EPSILON,
                "alpha": alpha,
                "steps": steps,
                "restarts": PGD_SEARCH_RESTARTS,
                "gradient_steps_per_sample": steps * PGD_SEARCH_RESTARTS,
                **metrics,
            })

            print(f"Validation PGD alpha={alpha:.6f}, steps={steps}, restarts={PGD_SEARCH_RESTARTS}, n={actual_search_samples} -> robust_accuracy={metrics['robust_accuracy']:.4f}")

    table = pd.DataFrame(records).sort_values(["robust_accuracy", "gradient_steps_per_sample", "alpha"], ascending=[True, True, True]).reset_index(drop=True)

    strongest = table.iloc[0].to_dict()

    near_strongest = table[table["robust_accuracy"] <= strongest["robust_accuracy"] + tolerance]

    compute_aware = near_strongest.sort_values(["gradient_steps_per_sample", "attack_seconds", "robust_accuracy"]).iloc[0].to_dict()

    output_dir = RESULTS_ROOT / dataset_name / "attacks"
    output_dir.mkdir(parents=True, exist_ok=True)

    table.to_csv(output_dir / "pgd_grid_search_validation.csv", index=False)

    selection_metadata = {
        "dataset": dataset_name,
        "selection_split": "heldout_validation_from_official_train",
        "official_test_used_for_selection": False,
        "validation_dataset_size": int(len(search_loader.dataset)),
        "search_samples": int(actual_search_samples),
        "strongest_validation_configuration": strongest,
        "compute_aware_validation_configuration": compute_aware,
    }

    (output_dir / "pgd_grid_selection_metadata.json").write_text(json.dumps(selection_metadata, indent=2, ensure_ascii=False), encoding="utf-8")

    return table, strongest, compute_aware
```

*شکل ۱–۲۱: پیاده‌سازی جست‌وجوی شبکه **PGD** روی مجموعه اعتبارسنجی و انتخاب جداگانه قوی‌ترین تنظیم و تنظیم **Compute-aware**.*

تابع pgd_grid_search ابتدا یک مجموعه ثابت از تصاویر و برچسب‌های اعتبارسنجی جمع‌آوری می‌کند. استفاده از نمونه‌های یکسان در تمام تنظیمات موجب می‌شود تفاوت نتایج ناشی از مقادیر α و تعداد گام‌ها باشد، نه تغییر نمونه‌های ارزیابی. سپس هر ۹ ترکیب الزامی با سه restart اجرا شده و دقت مقاوم، زمان حمله و هزینه گرادیانی آن ثبت می‌شود.

قوی‌ترین تنظیم به‌عنوان حالتی تعریف می‌شود که کمترین Robust Accuracy را روی Validation ایجاد کرده باشد. در مرحله بعد، تنظیم‌هایی که دقت آن‌ها حداکثر ۰.۰۰۵، معادل ۰.۵ واحد درصد، با قوی‌ترین حمله فاصله دارد نگه داشته می‌شوند. از میان آن‌ها، گزینه دارای کمترین مقدار

$$Gradient\ Cost = Steps \times Restarts$$

انتخاب می‌شود و زمان اجرا نقش معیار بعدی شکستن تساوی را دارد.

این قاعده، تنظیم Compute-aware را برای ارزیابی‌های میانی تعیین می‌کند و جایگزین حمله نهایی قوی نیست. به همین دلیل، در ممیزی نهایی از PGD چهل‌مرحله‌ای با پنج restart و AutoAttack استفاده شده است. تابع همچنین جدول کامل شبکه و فراداده انتخاب را در فایل‌های CSV و JSON ذخیره می‌کند تا تصمیم انتخاب تنظیم قابل بازبینی باشد.

```python
def evaluate_transfer_pgd_multi_target(target_models: dict[str, nn.Module], surrogate_model: nn.Module, loader: DataLoader, alpha: float, steps: int, restarts: int, max_samples: Optional[int]) -> pd.DataFrame:
    """Generate PGD once on an independent surrogate and test all targets."""
    if any(model is surrogate_model for model in target_models.values()):
        raise ValueError("The surrogate must be a separate model object.")

    surrogate_model.eval()
    for target_model in target_models.values():
        target_model.eval()

    correct = {name: 0 for name in target_models}
    total_samples = 0
    maximum_linf = 0.0
    start = time.perf_counter()

    for images, labels in tqdm(loader, desc="Independent-surrogate transfer PGD"):
        if max_samples is not None:
            remaining = max_samples - total_samples
            if remaining <= 0:
                break
            images = images[:remaining]
            labels = labels[:remaining]

        images = images.to(DEVICE, non_blocking=True)
        labels = labels.to(DEVICE, non_blocking=True)

        adversarial, _, _ = PGD(surrogate_model, images, labels, epsilon=PGD_EPSILON, alpha=alpha, steps=steps, random_restarts=restarts)

        linf = (adversarial - images).abs().flatten(1).max(dim=1).values
        maximum_linf = max(maximum_linf, float(linf.max().item()))
        if maximum_linf > PGD_EPSILON + 1e-5:
            raise RuntimeError("Transfer PGD left the requested L-infinity ball.")

        with torch.no_grad():
            for model_name, target_model in target_models.items():
                predictions = target_model(adversarial).argmax(dim=1)
                correct[model_name] += int((predictions == labels).sum().item())

        total_samples += labels.size(0)

    expected_samples = len(loader.dataset) if max_samples is None else min(max_samples, len(loader.dataset))
    if total_samples != expected_samples:
        raise RuntimeError(f"Transfer PGD evaluated {total_samples} samples; expected {expected_samples}.")

    elapsed = time.perf_counter() - start
    surrogate_architecture = type(surrogate_model.backbone).__name__

    return pd.DataFrame([
        {
            "model": model_name,
            "surrogate_model": "independent_surrogate",
            "surrogate_architecture": surrogate_architecture,
            "surrogate_is_independent": True,
            "shared_target_weights": False,
            "transfer_black_box_accuracy": correct[model_name] / max(total_samples, 1),
            "transfer_attack_seconds": elapsed,
            "transfer_batch_size": int(loader.batch_size or 1),
            "steps": steps,
            "restarts": restarts,
            "n_samples": total_samples,
            "max_linf": maximum_linf,
        }
        for model_name in target_models
    ])
```

شکل ۱–۲۲: پیاده‌سازی حمله انتقالی چندمدلی؛ تولید نمونه‌های خصمانه روی یک مدل جانشین مستقل و ارزیابی همان نمونه‌ها روی تمام مدل‌های هدف.

تابع evaluate_transfer_pgd_multi_target ابتدا بررسی می‌کند که مدل جانشین همان شیء یکی از مدل‌های هدف نباشد. سپس هر Batch فقط یک‌بار با استفاده از گرادیان مدل جانشین مورد حمله قرار می‌گیرد و نمونه خصمانه حاصل بدون تغییر روی مدل پایه، FGSM-AT و PGD-AT ارزیابی می‌شود.

این طراحی موجب می‌شود هر سه مدل هدف دقیقاً نمونه‌های Black-box یکسانی دریافت کنند و مقایسه آن‌ها تحت تأثیر تصادفی‌بودن حمله‌های جداگانه قرار نگیرد. همچنین نرم L_∞ هر Batch کنترل می‌شود و در صورت خروج از کران مجاز، اجرا متوقف خواهد شد. تعداد نمونه‌های پردازش‌شده نیز با اندازه مورد انتظار مجموعه ارزیابی مقایسه می‌شود تا حذف ناخواسته نمونه‌ها رخ ندهد.

خروجی تابع شامل دقت انتقالی هر مدل، معماری مدل جانشین، تعداد گام‌ها و restartها، زمان حمله و بیشینه اختلال مشاهده‌شده است. ثبت صریح استقلال مدل جانشین نیز مانع از آن می‌شود که حمله انتقالی به اشتباه به‌عنوان یک حمله White-box گزارش شود.

```python
def EOT_PGD(model: nn.Module, images: torch.Tensor, labels: torch.Tensor, epsilon: float, alpha: float, steps: int, random_restarts: int, eot_grad_samples: int = EOT_GRAD_SAMPLES, eot_prediction_samples: int = EOT_PREDICTION_SAMPLES) -> tuple[torch.Tensor, torch.Tensor, torch.Tensor]:
    """
    Untargeted L-infinity EOT-PGD in the original [0, 1] pixel domain.

    At every PGD step, input gradients are averaged over repeated forward
    passes. The strongest restart is selected independently for each sample.
    """
    if epsilon < 0:
        raise ValueError("epsilon must be non-negative.")
    if alpha <= 0:
        raise ValueError("alpha must be positive.")
    if steps < 1 or random_restarts < 1:
        raise ValueError("steps and random_restarts must be at least 1.")
    if eot_grad_samples < 1 or eot_prediction_samples < 1:
        raise ValueError("EOT sample counts must be at least 1.")

    was_training = model.training
    model.eval()

    clean = images.detach()
    best_adversarial = clean.clone()
    best_expected_loss = torch.full((clean.size(0),), -float("inf"), device=clean.device)

    try:
        for _ in range(random_restarts):
            adversarial = clean + torch.empty_like(clean).uniform_(-epsilon, epsilon)
            adversarial = torch.clamp(adversarial, 0.0, 1.0).detach()

            for _ in range(steps):
                adversarial.requires_grad_(True)
                gradient_sum = torch.zeros_like(adversarial)

                for _ in range(eot_grad_samples):
                    loss = F.cross_entropy(model(adversarial), labels)
                    gradient_sum += torch.autograd.grad(loss, adversarial, only_inputs=True, retain_graph=False, create_graph=False)[0].detach()

                mean_gradient = gradient_sum / float(eot_grad_samples)

                with torch.no_grad():
                    adversarial = adversarial + alpha * mean_gradient.sign()
                    delta = torch.clamp(adversarial - clean, min=-epsilon, max=epsilon)
                    adversarial = torch.clamp(clean + delta, min=0.0, max=1.0).detach()

            with torch.no_grad():
                expected_loss = _mean_eot_per_sample_loss(model=model, images=adversarial, labels=labels, samples=eot_prediction_samples)
                stronger = expected_loss > best_expected_loss
                best_expected_loss = torch.where(stronger, expected_loss, best_expected_loss)
                mask_shape = [clean.size(0), *([1] * (clean.ndim - 1))]
                best_adversarial = torch.where(stronger.view(*mask_shape), adversarial, best_adversarial)

        with torch.no_grad():
            averaged_logits = _mean_eot_logits(model=model, images=best_adversarial, samples=eot_prediction_samples).detach()

        perturbation = (best_adversarial - clean).detach()
        return best_adversarial.detach(), perturbation, averaged_logits

    finally:
        model.train(was_training)
```

شکل ۱–۲۳: پیاده‌سازی ***EOT-PGD****: میانگین‌گیری گرادیان چند اجرای* ***forward*** *در هر گام و انتخاب* ***restart*** *بر اساس* ***Expected Loss*** *هر نمونه.*

تابع EOT_PGD ساختار اصلی PGD را حفظ می‌کند، اما در هر مرحله به‌جای استفاده از گرادیان یک forward، چند گرادیان مستقل را محاسبه و میانگین‌گیری می‌کند. در اجرای نهایی، این میانگین بر اساس ۱۰ نمونه گرادیانی در هر گام به دست آمده است. این روش برای دفاع‌هایی مناسب است که رفتار تصادفی آن‌ها ممکن است گرادیان یک اجرای منفرد را غیرنماینده کند.

پس از پایان هر restart، قدرت نمونه بر اساس میانگین Loss چند پیش‌بینی ارزیابی می‌شود و قوی‌ترین restart به‌صورت مستقل برای هر تصویر انتخاب می‌گردد. خروجی نهایی مدل نیز از میانگین logits در چند اجرای forward به دست می‌آید. در پایان، حالت اولیه آموزش یا ارزیابی مدل حتی در صورت وقوع خطا با ساختار finally بازیابی می‌شود.

مدل‌های استفاده‌شده در این آزمایش در زمان استنتاج قطعی بودند؛ ازاین‌رو، برابری نتیجه EOT-PGD با PGD معمولی قابل انتظار بود. بااین‌حال، اجرای صریح این تابع امکان بررسی تجربی نبود تصادفی‌بودن پنهان یا شکست گرادیان را فراهم کرد.

```python
def evaluate_autoattack(model: nn.Module, loader: DataLoader, dataset_name: str, max_samples: Optional[int]) -> dict[str, Any]:
    spec = DATASET_SPECS[dataset_name]
    if EXECUTION_MODE == "full" and max_samples is not None:
        raise ValueError("Full-mode AutoAttack must use max_samples=None and the complete test set.")

    attack = torchattacks.AutoAttack(model, norm="Linf", eps=PGD_EPSILON, version=AUTOATTACK_VERSION, n_classes=spec.num_classes, seed=SEED, verbose=True)

    model.eval()
    total_correct = 0
    total_samples = 0
    total_linf = 0.0
    maximum_linf = 0.0
    start = time.perf_counter()

    for images, labels in tqdm(loader, desc=f"AutoAttack {dataset_name}"):
        if max_samples is not None:
            remaining = max_samples - total_samples
            if remaining <= 0:
                break
            images = images[:remaining]
            labels = labels[:remaining]

        images = images.to(DEVICE)
        labels = labels.to(DEVICE)
        adversarial = attack(images, labels)
        perturbation_linf = (adversarial - images).abs().flatten(1).max(dim=1).values
        if float(perturbation_linf.max()) > PGD_EPSILON + 1e-5:
            raise RuntimeError("AutoAttack produced an example outside the requested L-infinity ball.")
        with torch.no_grad():
            predictions = model(adversarial).argmax(dim=1)

        total_correct += int((predictions == labels).sum().item())
        total_samples += labels.size(0)
        total_linf += float(perturbation_linf.sum().item())
        maximum_linf = max(maximum_linf, float(perturbation_linf.max().item()))

    expected_samples = len(loader.dataset) if max_samples is None else min(max_samples, len(loader.dataset))
    if total_samples != expected_samples:
        raise RuntimeError(f"AutoAttack evaluated {total_samples} samples; expected {expected_samples}.")

    return {
        "robust_accuracy": total_correct / max(total_samples, 1),
        "n_samples": total_samples,
        "full_test_set": bool(max_samples is None),
        "suite_version": AUTOATTACK_VERSION,
        "suite_components": ", ".join(AUTOATTACK_COMPONENTS),
        "mean_linf": total_linf / max(total_samples, 1),
        "max_linf": maximum_linf,
        "attack_seconds": time.perf_counter() - start,
    }
```

*شکل ۱–۲۴: پیاده‌سازی ارزیابی **AutoAttack**؛ اجرای نسخه استاندارد، کنترل استفاده از کل مجموعه آزمون و بررسی کران L_∞ نمونه‌های تولیدشده.*

تابع evaluate_autoattack از نسخه استاندارد AutoAttack در کتابخانه torchattacks استفاده می‌کند. این نسخه مجموعه APGD-CE، APGD-T، FAB-T و Square Attack را اجرا می‌کند و به یک تابع هدف یا حمله گرادیانی واحد محدود نیست. تعداد کلاس‌ها، Seed، نرم L_∞ و کران $\epsilon = \frac{8}{255}$ هنگام ساخت حمله مشخص می‌شوند.

در حالت اجرای کامل، تابع اجازه استفاده از زیرمجموعه آزمون را نمی‌دهد و max_samples باید برابر None باشد. پس از تولید هر Batch خصمانه، نرم اختلال کنترل می‌شود و نمونه‌ای که از کران تعیین‌شده خارج باشد پذیرفته نخواهد شد. در پایان نیز تعداد نمونه‌های واقعاً ارزیابی‌شده با اندازه مورد انتظار مجموعه آزمون مقایسه می‌شود.

خروجی تابع فقط شامل Robust Accuracy نیست؛ تعداد نمونه‌ها، میانگین و بیشینه نرم اختلال، نسخه مجموعه حمله، اجزای آن و زمان کل اجرا نیز ثبت می‌شوند. این اطلاعات امکان بررسی صحت اجرا و تمایز نتیجه AutoAttack از حملات PGD سفارشی را فراهم می‌کنند.

مجموع این چهار تابع باعث می‌شود ارزیابی نهایی به یک حمله یا یک تنظیم خاص وابسته نباشد. جست‌وجوی PGD برای انتخاب تنظیم میانی، حمله انتقالی برای سنجش Black-box، EOT برای بررسی گرادیان‌های احتمالی تصادفی و AutoAttack برای ارزیابی چندحمله‌ای مستقل استفاده شده‌اند.

۱-۷-۳- پیاده‌سازی تحلیل TCAV و ثبت خروجی‌ها

یکی از خطرهای طراحی TCAV آن است که کلاس هدف مستقیماً در نمونه‌های مفهوم یا مرجع حضور داشته باشد. در چنین حالتی، جهت CAV می‌تواند اطلاعات مستقیم کلاس هدف را یاد بگیرد و نتیجه به‌اشتباه به یک مفهوم سطح‌بالا نسبت داده شود. به همین دلیل، پیش از اجرای تحلیل، ساختار کلاس‌های مفهوم، مرجع و هدف به‌صورت خودکار کنترل شده است.

```python
def validate_tcav_class_design(spec: DatasetSpec) -> None:
    concept = set(spec.concept_classes)
    reference = set(spec.reference_classes)
    targets = set(spec.tcav_target_classes)
    assert concept.isdisjoint(reference), "TCAV concept and reference classes overlap."
    assert reference.isdisjoint(targets), "TCAV reference set contains a target class."
    assert concept.isdisjoint(targets), "TCAV concept examples directly contain a target class."
```

*شکل ۱–۲۵: کنترل طراحی کلاس‌های **TCAV**؛ بررسی عدم هم‌پوشانی مجموعه‌های مفهوم، مرجع و هدف پیش از اجرای تحلیل.*

تابع validate_tcav_class_design شناسه کلاس‌های مفهوم، مرجع و هدف را به سه مجموعه تبدیل می‌کند و مجزابودن زوجی آن‌ها را بررسی می‌کند. در صورت وجود هرگونه اشتراک، اجرای نوت‌بوک با یک پیام مشخص متوقف می‌شود. بنابراین، خطای طراحی TCAV به‌جای آنکه پس از تولید نتایج کشف شود، پیش از شروع تحلیل شناسایی خواهد شد.

این کنترل در Fashion-MNIST تضمین می‌کند که کلاس‌های Sandal و Sneaker برای ساخت مفهوم Footwear با کلاس‌های مرجع و اهداف Ankle boot و T-shirt/top اشتراک نداشته باشند. در CIFAR-10 نیز کلاس‌های سازنده مفهوم Vehicle از کلاس‌های مرجع حیوانی و اهداف Automobile و Dog مجزا نگه داشته می‌شوند.

سادگی این تابع از اهمیت آن کم نمی‌کند؛ زیرا مجزابودن کلاس‌ها یکی از پیش‌شرط‌های تفسیر معتبر Contrastهای TCAV در این آزمایش است. با این کنترل نمی‌توان رابطه علّی مفهوم و پیش‌بینی را اثبات کرد، اما می‌توان از یک منبع روشن نشت برچسب و نتیجه‌گیری بدیهی جلوگیری کرد.

در مجموع، پیاده‌سازی نهایی علاوه بر تولید نتایج عددی، مجموعه‌ای از کنترل‌های اجرایی را نیز در خود دارد: حملات در دامنه اصلی پیکسل و داخل کران تعیین‌شده باقی می‌مانند، قوی‌ترین restart به‌صورت نمونه‌محور انتخاب می‌شود، آموزش پاک و خصمانه از یک حلقه مشترک استفاده می‌کنند، انتخاب تنظیم PGD فقط بر اساس Validation انجام می‌شود، حمله انتقالی از مدل جانشین مستقل تولید می‌گردد و طراحی TCAV پیش از اجرا از نظر هم‌پوشانی کلاس‌ها اعتبارسنجی می‌شود. این کنترل‌ها احتمال آن را کاهش می‌دهند که نتایج گزارش‌شده ناشی از خطای پیاده‌سازی، نشت داده یا مقایسه ناهماهنگ مدل‌ها باشند.

۱-۸- نتیجه‌گیری و تصمیم نهایی

در این فصل، مقاومت خصمانه مدل‌های طبقه‌بندی تصویر روی Fashion-MNIST و CIFAR-10 در یک پروتکل بازتولیدپذیر بررسی شد. جداسازی مجموعه اعتبارسنجی از آزمون، اجرای حملات در فضای اصلی پیکسل و استفاده از کل مجموعه آزمون در ارزیابی‌های نهایی موجب شد انتخاب تنظیمات از گزارش عملکرد نهایی مستقل باقی بماند.

مدل‌های پایه روی داده‌های پاک عملکرد مناسبی داشتند، اما این عملکرد به پایداری در برابر اختلال‌های کوچک منجر نشد. حمله FGSM آسیب‌پذیری هر دو مدل را آشکار کرد و PGD با جست‌وجوی چندمرحله‌ای نشان داد که ارزیابی تک‌مرحله‌ای می‌تواند مقاومت مدل را خوش‌بینانه برآورد کند. این مسئله در CIFAR-10 شدیدتر بود و مدل پایه در محدوده تهدید بررسی‌شده عملاً فاقد مقاومت قابل اتکا بود.

هر دو روش FGSM-AT و PGD-AT مقاومت مدل‌ها را افزایش دادند. PGD-AT در مجموع قوی‌ترین دفاع آزمایش‌شده بود، اما این برتری با هزینه آموزش بیشتر و کاهش بیشتر دقت پاک همراه شد. در Fashion-MNIST این مصالحه محدود و قابل‌قبول بود، درحالی‌که در CIFAR-10 افت دقت پاک و هزینه محاسباتی نقش مهم‌تری در انتخاب دفاع داشتند. FGSM-AT گزینه‌ای کم‌هزینه‌تر و متعادل‌تر است، اما در برابر حملات قوی به سطح PGD-AT نمی‌رسد.

ممیزی با PGD قوی‌تر، چند شروع تصادفی، حمله انتقالی، EOT و AutoAttack الگوی ناسازگار یا فروپاشی ناگهانی ناشی از پوشاندن گرادیان را نشان نداد. بنابراین افزایش مقاومت دفاع‌ها صرفاً نتیجه شکست یک حمله خاص یا گرادیان گمراه‌کننده نیست. بااین‌حال، نبود شواهد Gradient Masking به معنی امنیت کامل نیست و نتایج فقط در محدوده حملات بدون هدف L_∞ و کران بررسی‌شده معتبر هستند.

تحلیل تکمیلی TCAV نیز نشان داد که مدل‌ها میان مفاهیم مرتبط و نامرتبط تمایز جهت‌دار ایجاد کرده‌اند و آموزش PGD-AT این ساختار مفهومی را از بین نبرده است. در برخی حالت‌ها ثبات جهت مفهومی پس از دفاع افزایش یافت، اما تغییر Magnitudeها یکنواخت نبود. ازاین‌رو، این تحلیل شواهدی درباره ساختار بازنمایی مدل فراهم می‌کند، ولی اثبات‌کننده رابطه علّی، توضیح‌پذیری کامل یا مقاومت خصمانه نیست.

در تصمیم نهایی، استفاده از مدل پایه در محیطی با امکان دست‌کاری ورودی توصیه نمی‌شود. برای Fashion-MNIST، PGD-AT مناسب‌ترین گزینه در شرایطی است که مقاومت اولویت اصلی باشد و FGSM-AT می‌تواند در صورت اهمیت بیشتر هزینه و دقت پاک انتخاب شود. برای CIFAR-10 نیز PGD-AT مقاوم‌ترین مدل بررسی‌شده است، اما فاصله باقی‌مانده میان عملکرد پاک و خصمانه نشان می‌دهد برای کاربردهای حساس، به آموزش قوی‌تر، تنظیم دقیق‌تر و ارزیابی تحت مدل‌های تهدید گسترده‌تر نیاز است. در مجموع، آموزش خصمانه مقاومت را به‌طور واقعی افزایش داد، اما آن را به یک تضمین مطلق امنیتی تبدیل نکرد.

فصل دوم

تحلیل عدالت، توضیح‌پذیری و کاهش سوگیری در طبقه‌بندی درآمد

در این فصل، مسئله پیش‌بینی سطح درآمد در مجموعه‌داده Adult با استفاده از دو مدل رگرسیون لجستیک و جنگل تصادفی بررسی می‌شود. پس از ارزیابی عملکرد پیش‌بینی، رفتار مدل‌ها از منظر عدالت گروهی، کالیبراسیون و توضیح‌پذیری تحلیل شده و اثر دو روش کاهش سوگیری بر معیارهای عملکرد و عدالت مقایسه خواهد شد.

۲-۱- معرفی مسئله و طراحی آزمایش

در این بخش، مجموعه‌داده، متغیر هدف، ویژگی‌های حساس و مراحل آماده‌سازی داده معرفی می‌شوند. همچنین ترکیب جمعیتی گروه‌های حساس و نرخ پایه خروجی مثبت بررسی می‌شود تا مبنای مناسبی برای تفسیر نتایج عدالت در بخش‌های بعد فراهم شود.

۲-۱-۱- معرفی مجموعه‌داده و تعریف مسئله

در این آزمایش از نسخه کامل مجموعه‌داده Adult Income استفاده شد. این مجموعه‌داده شامل اطلاعات جمعیت‌شناختی، تحصیلی و شغلی افراد است و هدف آن پیش‌بینی قرارگرفتن درآمد سالانه فرد در یکی از دو طبقه کمتر یا مساوی ۵۰ هزار دلار و بیشتر از ۵۰ هزار دلار است. نسخه استفاده‌شده دارای ۴۸۸۴۲ نمونه و ۱۴ ویژگی ورودی است و در نوت‌بوک از نسخه ذخیره‌شده محلی مجموعه‌داده OpenML Adult، نسخه ۲، بارگذاری شد.

در این مسئله، طبقه درآمد بیشتر از ۵۰ هزار دلار به‌عنوان خروجی مثبت با برچسب ۱ و طبقه درآمد کمتر یا مساوی ۵۰ هزار دلار به‌عنوان خروجی منفی با برچسب ۰ در نظر گرفته شد. از مجموع نمونه‌ها، ۱۱۶۸۷ نمونه متعلق به طبقه مثبت و ۳۷۱۵۵ نمونه متعلق به طبقه منفی هستند؛ بنابراین نرخ کلی طبقه مثبت برابر با ۲۳.۹۳ درصد است.

جدول ۲–۱: مشخصات کلی مجموعه‌داده **Adult Income**

مشخصه	مقدار
تعداد کل نمونه‌ها	۴۸۸۴۲
تعداد ویژگی‌های ورودی	۱۴
تعداد ویژگی‌های عددی	۶
تعداد ویژگی‌های طبقه‌ای	۸
تعداد نمونه‌های طبقه مثبت	۱۱۶۸۷
تعداد نمونه‌های طبقه منفی	۳۷۱۵۵
نرخ کلی طبقه مثبت	۲۳.۹۳٪
تعریف طبقه مثبت	درآمد سالانه بیشتر از ۵۰ هزار دلار
ویژگی‌های حساس اصلی	sexوrace
تحلیل تقاطعی	sex × race

کم‌بودن نسبت نمونه‌های مثبت نشان می‌دهد که Accuracy به‌تنهایی معیار کافی برای ارزیابی مدل نیست؛ زیرا یک مدل متمایل به طبقه اکثریت نیز می‌تواند دقت ظاهری نسبتاً بالایی به دست آورد. ازاین‌رو، در بخش ارزیابی مدل علاوه بر Accuracy، معیارهای Precision، Recall، F1 و ROC-AUC نیز گزارش می‌شوند.

ویژگی‌های ورودی مجموعه‌داده به دو گروه عددی و طبقه‌ای تقسیم شدند. فهرست این ویژگی‌ها در جدول ۲-۲ ارائه شده است.

جدول ۲–۲: ویژگی‌های ورودی مورد استفاده در مدل‌سازی

نوع ویژگی	ویژگی‌ها
عددی	age، fnlwgt، education-num، capital-gain، capital-loss، hours-per-week
طبقه‌ای	workclass، education، marital-status، occupation، relationship، race، sex، native-country

دو ویژگی sex و race علاوه بر حضور در ورودی مدل، به‌عنوان ویژگی‌های حساس برای ارزیابی عدالت گروهی انتخاب شدند. همچنین ترکیب این دو ویژگی برای بررسی عدالت تقاطعی در نظر گرفته شد. حضور ویژگی‌های حساس در مدل امکان بررسی مستقیم نحوه استفاده مدل از این اطلاعات را فراهم می‌کند؛ بااین‌حال، در ادامه به‌صورت جداگانه بررسی می‌شود که آیا حذف آن‌ها می‌تواند شکاف‌های عدالت را برطرف کند یا اطلاعات مشابه همچنان از طریق ویژگی‌های جانشین منتقل می‌شود.

ویژگی‌های education و education-num دو نمایش طبقه‌ای و عددی از سطح تحصیلات هستند و بنابراین اطلاعات وابسته‌ای را حمل می‌کنند. همچنین fnlwgt در اصل وزن نمونه‌برداری سرشماری است. این ویژگی‌ها در آزمایش حفظ شدند، اما وابستگی میان دو نمایش تحصیلات و ماهیت خاص fnlwgt در تفسیر اهمیت ویژگی‌ها مورد توجه قرار می‌گیرد.

۲-۱-۲- آماده‌سازی و تقسیم‌بندی داده‌ها

پیش از آموزش مدل‌ها، فاصله‌های اضافی مقادیر متنی حذف و علامت ? به‌عنوان مقدار گمشده در نظر گرفته شد. پیش‌پردازش داخل یک Pipeline انجام گرفت تا پارامترهای جای‌گذاری مقادیر گمشده، استانداردسازی و کدگذاری تنها از داده‌های آموزش استخراج شوند و اطلاعات مجموعه آزمون وارد فرایند آموزش نشود.

برای ویژگی‌های عددی، مقادیر گمشده با میانه همان ویژگی جای‌گذاری و سپس ویژگی‌ها استاندارد شدند. برای ویژگی‌های طبقه‌ای، مقدار گمشده با پرتکرارترین طبقه جایگزین و کدگذاری One-Hot اعمال شد. کدگذار نیز به‌گونه‌ای تنظیم شد که مشاهده یک طبقه جدید در مجموعه اعتبارسنجی یا آزمون باعث خطای اجرایی نشود.

جدول ۲–۳: مراحل پیش‌پردازش ویژگی‌ها

گروه ویژگی	جای‌گذاری مقادیر گمشده	تبدیل بعدی
ویژگی‌های عددی	میانه ویژگی در داده آموزش	استانداردسازی باStandardScaler
ویژگی‌های طبقه‌ای	پرتکرارترین مقدار در داده آموزش	کدگذاریOne-Hot
طبقات مشاهده‌نشده	-	نادیده‌گرفتن با handle_unknown="ignore"

به‌منظور ارزیابی منصفانه مدل و جلوگیری از استفاده غیرمستقیم از مجموعه آزمون، داده‌ها به سه بخش آموزش، اعتبارسنجی و آزمون تقسیم شدند. ابتدا ۲۰ درصد داده‌ها به مجموعه آزمون اختصاص یافت و سپس ۲۰ درصد از بخش باقی‌مانده برای اعتبارسنجی جدا شد. هر دو مرحله به‌صورت طبقه‌بندی‌شده بر اساس متغیر هدف و با بذر تصادفی ثابت ۴۲ انجام شدند؛ در نتیجه نسبت نمونه‌های مثبت و منفی در سه بخش تقریباً حفظ شد.

جدول ۲–۴: تقسیم‌بندی مجموعه‌داده

بخش داده	تعداد نمونه	سهم از کل داده	کاربرد
آموزش	۳۱۲۵۸	۶۴٪	برازش مدل‌ها و پارامترهای پیش‌پردازش
اعتبارسنجی	۷۸۱۵	۱۶٪	انتخاب آستانه‌ها و تنظیم روش کاهش سوگیری
آزمون	۹۷۶۹	۲۰٪	ارزیابی نهایی عملکرد، عدالت و کالیبراسیون
مجموع	۴۸۸۴۲	۱۰۰٪	–

جداسازی مجموعه اعتبارسنجی در این آزمایش اهمیت ویژه‌ای دارد، زیرا آستانه‌های تصمیم گروهی در روش کاهش سوگیری تنها با استفاده از این مجموعه انتخاب می‌شوند. بنابراین مجموعه آزمون در انتخاب روش یا تنظیم آستانه‌ها نقشی نداشته و صرفاً برای ارزیابی نهایی استفاده شده است.

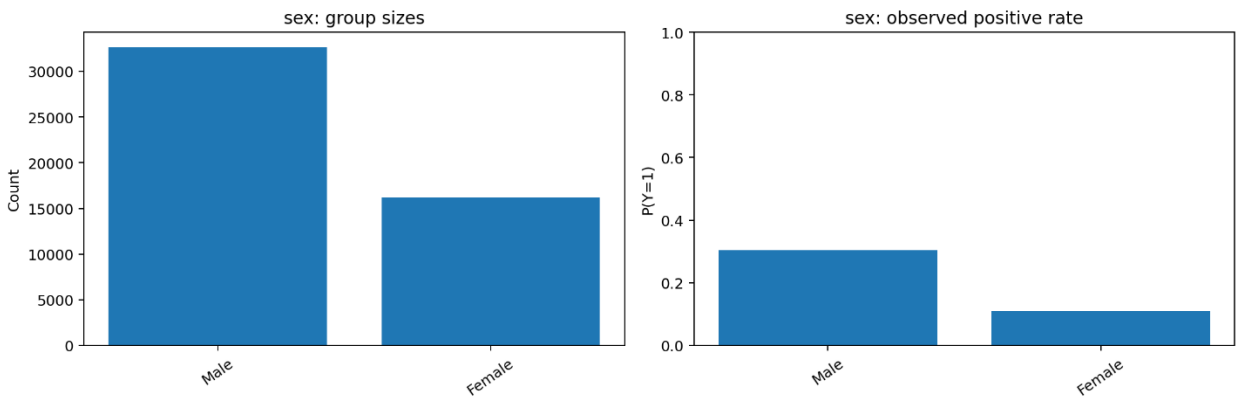
۲-۱-۳- ترکیب گروه‌ها و نرخ‌های پایه

پیش از تحلیل خروجی مدل، توزیع گروه‌های حساس و نرخ واقعی طبقه مثبت در هر گروه بررسی شد. نرخ پایه یک گروه برابر با نسبت نمونه‌هایی است که در داده واقعی دارای برچسب مثبت هستند. این مقدار خصوصیتی از داده است و نباید با نرخ خروجی مثبت مدل اشتباه گرفته شود.

در تقسیم‌بندی جنسیتی مجموعه‌داده، ۳۲۶۵۰ نمونه متعلق به گروه مردان و ۱۶۱۹۲ نمونه متعلق به گروه زنان هستند. بنابراین حدود دو سوم مجموعه‌داده از مردان تشکیل شده است.

جدول ۲–۵: ترکیب مجموعه‌داده و نرخ پایه بر اساس جنسیت

گروه	تعداد نمونه	سهم از کل داده	تعداد تقریبی نمونه‌های مثبت	نرخ پایه مثبت
مردان	۳۲۶۵۰	۶۶.۸۵٪	۹۹۱۸	۳۰.۳۸٪
زنان	۱۶۱۹۲	۳۳.۱۵٪	۱۷۶۹	۱۰.۹۳٪



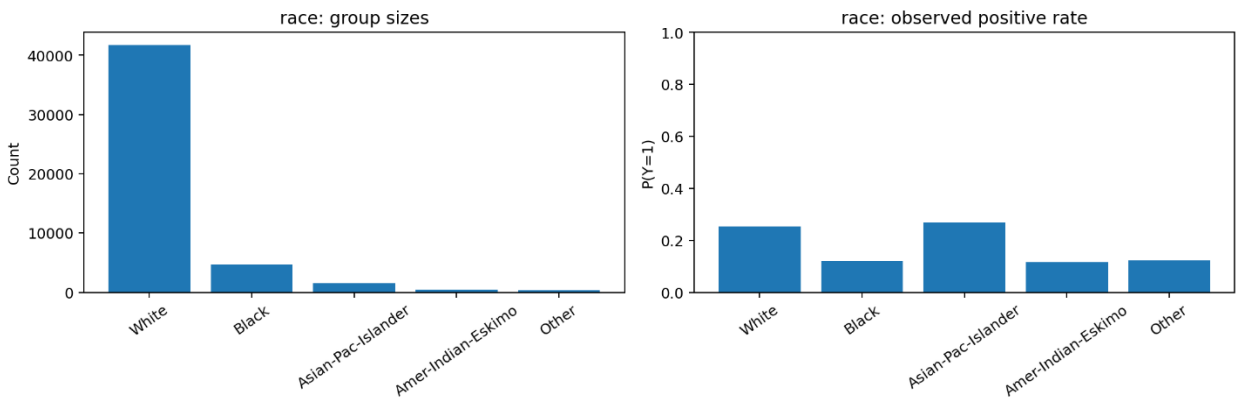
شکل ۲–۱: مقایسه تعداد نمونه‌ها و نرخ واقعی درآمد بیشتر از ۵۰ هزار دلار در گروه‌های جنسیتی مجموعه‌داده ***Adult***

نرخ پایه مثبت در گروه مردان حدود ۱۹.۴۵ واحد درصد بیشتر از گروه زنان است. این اختلاف پیش از آموزش مدل وجود دارد و نشان می‌دهد که برابری کامل برخی معیارهای عدالت الزاماً از ساختار طبیعی داده حاصل نمی‌شود. بااین‌حال، وجود تفاوت در نرخ پایه به‌تنهایی رفتار نابرابر مدل را توجیه نمی‌کند و لازم است نرخ خطاها و فرصت دریافت خروجی مثبت پس از آموزش به‌صورت مستقل بررسی شوند.

ترکیب نژادی داده نیز نامتوازن است. بیش از ۸۵ درصد نمونه‌ها در گروه White قرار دارند، درحالی‌که سهم هر یک از گروه‌های Amer-Indian-Eskimo و Other کمتر از یک درصد است.

جدول ۲–۶: ترکیب مجموعه‌داده و نرخ پایه بر اساس نژاد

گروه	تعداد نمونه	سهم از کل داده	نرخ پایه مثبت
White	۴۱۷۶۲	۸۵.۵۰٪	۲۵.۴۰٪
Black	۴۶۸۵	۹.۵۹٪	۱۲.۰۸٪
Asian-Pac-Islander	۱۵۱۹	۳.۱۱٪	۲۶.۹۳٪
Amer-Indian-Eskimo	۴۷۰	۰.۹۶٪	۱۱.۷۰٪
Other	۴۰۶	۰.۸۳٪	۱۲.۳۲٪



شکل ۲–۲: مقایسه تعداد نمونه‌ها و نرخ واقعی درآمد بیشتر از ۵۰ هزار دلار در گروه‌های نژادی مجموعه‌داده ***Adult***

بالاترین نرخ پایه مثبت در گروه Asian-Pac-Islander و پس از آن در گروه White مشاهده می‌شود، درحالی‌که نرخ پایه سه گروه Black، Amer-Indian-Eskimo و Other تقریباً در محدوده ۱۲ درصد قرار دارد. علاوه بر اختلاف نرخ‌های پایه، اندازه بسیار کوچک برخی گروه‌ها موجب می‌شود معیارهای عدالت و کالیبراسیون آن‌ها عدم قطعیت بیشتری داشته باشند. ازاین‌رو، در تحلیل‌های بعدی اندازه گروه و تعداد نمونه‌های مثبت و منفی واقعی در کنار مقدار معیارهای عدالت در نظر گرفته می‌شود و تفاوت‌های مربوط به گروه‌های کوچک به‌صورت قطعی تفسیر نخواهند شد.

۲-۲- آموزش و ارزیابی مدل‌ها

در این بخش، یک مدل نسبتاً تفسیرپذیر و یک مدل با ساختار پیچیده‌تر روی مجموعه آموزش برازش داده شدند و عملکرد آن‌ها روی مجموعه آزمون مستقل مقایسه شد. ارزیابی با آستانه تصمیم ثابت ۰.۵ انجام گرفت و علاوه بر معیارهای مبتنی بر برچسب نهایی، کیفیت رتبه‌بندی و احتمال‌های خروجی مدل نیز بررسی شد.

۲-۲-۱- مدل‌ها و تنظیمات آموزش

مدل نخست، رگرسیون لجستیک بود که به دلیل رابطه خطی میان ویژگی‌های تبدیل‌شده و لگاریتم نسبت شانس، نسبت به مدل‌های مجموعه‌ای تفسیرپذیری ساختاری بیشتری دارد. بااین‌حال، به‌دلیل استفاده از کدگذاری One-Hot و تعداد زیاد ویژگی‌های حاصل از آن، تفسیر مدل همچنان مستلزم بررسی ضرایب ویژگی‌های تبدیل‌شده است.

مدل دوم، جنگل تصادفی بود که تصمیم نهایی را از تجمیع خروجی چندین درخت تصمیم به دست می‌آورد. این ساختار قادر است روابط غیرخطی و برهم‌کنش‌های پیچیده میان ویژگی‌ها را مدل کند، اما تفسیر مستقیم تصمیم آن نسبت به رگرسیون لجستیک دشوارتر است. تنظیمات دو مدل در جدول ۲-۷ گزارش شده‌اند.

جدول ۲–۷: تنظیمات مدل‌های مورد استفاده

مدل	تنظیمات اصلی
رگرسیون لجستیک	حل‌گر lbfgs ، حداکثر ۲۰۰۰ تکرار، بذر تصادفی ۴۲
جنگل تصادفی	۳۰۰ درخت، min_samples_leaf=2، max_features="sqrt"، استفاده از تمام هسته‌های پردازنده، بذر تصادفی ۴۲
پیش‌پردازش مشترک	جای‌گذاری مقادیر گمشده، استانداردسازی ویژگی‌های عددی و کدگذاری One-Hot ویژگی‌های طبقه‌ای
آستانه تصمیم	۰.۵
داده آموزش	۳۱۲۵۸ نمونه
داده ارزیابی نهایی	۹۷۶۹ نمونه آزمون

هر مدل همراه با پیش‌پردازش مربوط به خود در یک Pipeline مستقل آموزش داده شد. این طراحی سبب می‌شود تمام پارامترهای پیش‌پردازش فقط از مجموعه آموزش برآورد شوند و مراحل تبدیل داده در زمان ارزیابی دقیقاً مشابه مرحله آموزش باشند.

۲-۲-۲- معیارهای ارزیابی عملکرد

به‌دلیل نامتوازن‌بودن متغیر هدف، ارزیابی مدل‌ها صرفاً بر اساس Accuracy انجام نشد. معیارهای Precision، Recall و F1 برای بررسی عملکرد مدل روی طبقه مثبت و ROC-AUC برای ارزیابی توانایی رتبه‌بندی نمونه‌های مثبت و منفی استفاده شدند. روابط معیارهای وابسته به ماتریس درهم‌ریختگی به‌صورت زیر تعریف می‌شوند:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2\frac{Precision \times Recall}{Precision + Recall}$$

در این روابط، TP تعداد نمونه‌های مثبت درست، TN تعداد نمونه‌های منفی درست، FP تعداد خطاهای مثبت کاذب و FN تعداد خطاهای منفی کاذب است. Precision نشان می‌دهد چه نسبتی از افراد پیش‌بینی‌شده در طبقه درآمد بالا واقعاً متعلق به این طبقه هستند، درحالی‌که Recall نسبت افراد واقعاً مثبت شناسایی‌شده توسط مدل را اندازه‌گیری می‌کند.

معیار ROC-AUC مستقل از آستانه تصمیم است و احتمال این را می‌سنجد که مدل به یک نمونه مثبت واقعی امتیاز بیشتری نسبت به یک نمونه منفی واقعی اختصاص دهد. برای ارزیابی صحت احتمال‌های خروجی نیز Brier Score محاسبه شد:

$$Brier = \frac{1}{N}\sum_{i=1}^{N}(p_i - y_i)^2$$

که در آن p_i احتمال پیش‌بینی‌شده برای طبقه مثبت و y_i برچسب واقعی نمونه است. برخلاف سایر معیارهای جدول عملکرد، مقدار کمتر Brier Score مطلوب‌تر است. بااین‌حال، این معیار به‌تنهایی برابری کالیبراسیون میان گروه‌ها را نشان نمی‌دهد و تحلیل گروهی آن در بخش عدالت انجام خواهد شد.

۲-۲-۳- نتایج و مقایسه مدل‌ها

نتایج مجموعه آزمون در جدول ۲-۸ ارائه شده‌اند. جنگل تصادفی در تمام معیارهای اصلی عملکرد مقدار بهتری نسبت به رگرسیون لجستیک به دست آورده است. همچنین Brier Score کمتر این مدل نشان می‌دهد که احتمال‌های تولیدشده توسط آن در ارزیابی کلی، خطای مربعی کمتری نسبت به برچسب واقعی داشته‌اند.

جدول ۲–۸: مقایسه عملکرد مدل‌ها روی مجموعه آزمون

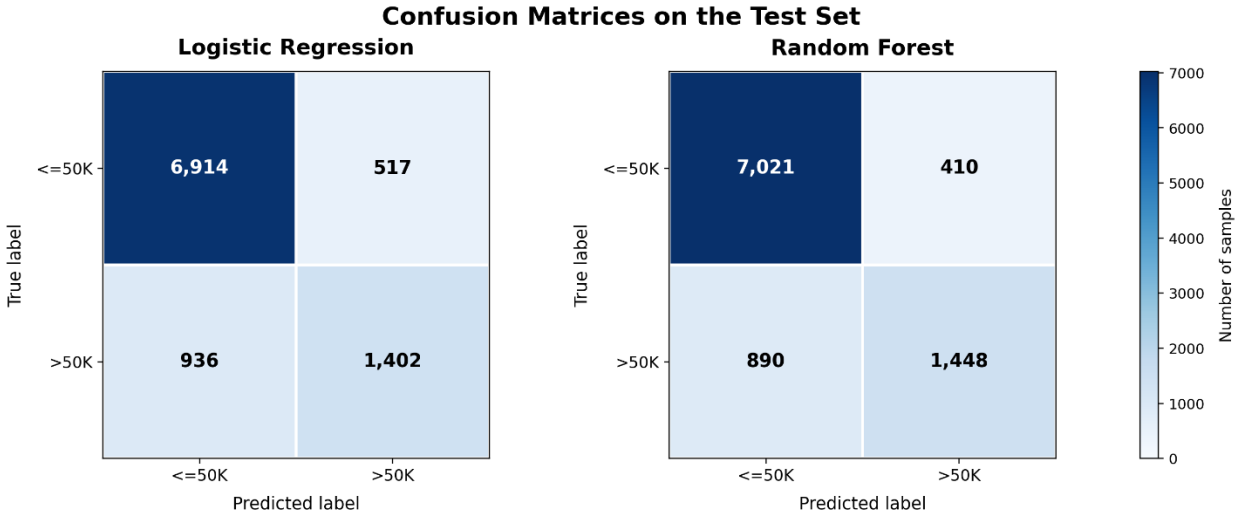
مدل	Accuracy	Precision	Recall	F1	ROC-AUC	Brier Score	زمان آموزش (ثانیه)
رگرسیون لجستیک	۰.۸۵۱۳	۰.۷۳۰۶	۰.۵۹۹۷	۰.۶۵۸۷	۰.۹۰۳۵	۰.۱۰۳۵	۱.۴۷
جنگل تصادفی	۰.۸۶۶۹	۰.۷۷۹۳	۰.۶۱۹۳	۰.۶۹۰۲	۰.۹۱۷۰	۰.۰۹۵۲	۱.۸۱

جنگل تصادفی Accuracy را حدود ۱.۵۷ واحد درصد، Precision را ۴.۸۷ واحد درصد، Recall را ۱.۹۷ واحد درصد و F1 را ۳.۱۵ واحد درصد افزایش داده است. افزایش هم‌زمان Precision و Recall نشان می‌دهد بهبود F1 صرفاً حاصل جابه‌جایی میان این دو معیار نیست؛ مدل هم تعداد بیشتری از نمونه‌های مثبت واقعی را شناسایی کرده و هم نسبت خطای کمتری در میان خروجی‌های مثبت داشته است.

مقادیر ماتریس درهم‌ریختگی دو مدل در جدول ۲-۹ گزارش شده‌اند. ترتیب درایه‌ها مطابق تعریف استاندارد شامل نمونه‌های منفی درست، مثبت کاذب، منفی کاذب و مثبت درست است.

جدول ۲–۹: اجزای ماتریس درهم‌ریختگی مدل‌ها روی مجموعه آزمون

مدل	TN	FP	FN	TP
رگرسیون لجستیک	۶۹۱۴	۵۱۷	۹۳۶	۱۴۰۲
جنگل تصادفی	۷۰۲۱	۴۱۰	۸۹۰	۱۴۴۸



شکل ۲–۳: ماتریس‌های درهم‌ریختگی رگرسیون لجستیک و جنگل تصادفی روی مجموعه آزمون با مقیاس رنگ یکسان.

در مقایسه با رگرسیون لجستیک، جنگل تصادفی ۱۰۷ خطای مثبت کاذب و ۴۶ خطای منفی کاذب کمتر ایجاد کرده است. کاهش FP با افزایش Precision و کاهش FN با افزایش Recall سازگار است؛ بنابراین برتری مشاهده‌شده در معیارهای تجمیعی مستقیماً توسط شمارش خطاهای ماتریس درهم‌ریختگی تأیید می‌شود.

ROC-AUC جنگل تصادفی نیز از ۰.۹۰۳۵ به ۰.۹۱۷۰ افزایش یافته است؛ در نتیجه برتری این مدل فقط به آستانه ۰.۵ محدود نیست و در رتبه‌بندی احتمال‌های خروجی نیز مشاهده می‌شود. Brier Score نیز از ۰.۱۰۳۵ به ۰.۰۹۵۲ کاهش یافته، اما برای نتیجه‌گیری درباره کالیبراسیون لازم است این مقادیر در کنار منحنی‌های کالیبراسیون و نتایج تفکیک‌شده گروهی بررسی شوند.

در مجموع، جنگل تصادفی از نظر عملکرد پیش‌بینی مدل مناسب‌تری برای ادامه تحلیل‌های توضیح‌پذیری و کاهش سوگیری است. بااین‌حال، بهبود عملکرد آن به معنای عادلانه‌تر بودن مدل نیست؛ زیرا معیارهای جدول ۲–۸ عملکرد کل جمعیت را تجمیع می‌کنند و ممکن است تفاوت رفتار مدل میان گروه‌های حساس را پنهان کنند. ازاین‌رو، عدالت جنسیتی، نژادی و تقاطعی هر دو مدل در بخش بعد به‌صورت مستقل ارزیابی می‌شود.

۲-۳- ارزیابی عدالت گروهی و کالیبراسیون

در این بخش، رفتار دو مدل به تفکیک جنسیت، نژاد و گروه‌های تقاطعی sex × race بررسی می‌شود. هدف آن است که علاوه بر تفاوت نرخ دریافت خروجی مثبت، توزیع خطاها و کیفیت احتمال‌های پیش‌بینی‌شده میان گروه‌ها ارزیابی شود؛ زیرا عملکرد مناسب مدل روی کل جمعیت الزاماً به معنای رفتار مشابه آن برای تمام گروه‌های حساس نیست. این تحلیل معیارهای Demographic Parity، Equal Opportunity، Equalized Odds، Predictive Parity، FPR، FNR و کالیبراسیون گروهی موردنیاز تمرین را پوشش می‌دهد.

۲-۳-۱- معیارهای عدالت و قرارداد محاسبه شکاف‌ها

فرض می‌شود S ویژگی حساس، g یکی از گروه‌های آن، Y برچسب واقعی و $\hat{Y}$ تصمیم دودویی مدل باشد. نرخ خروجی مثبت، نرخ مثبت درست، نرخ مثبت کاذب، نرخ منفی کاذب و دقت خروجی مثبت برای هر گروه به‌صورت زیر تعریف می‌شوند:

$$PPR_g = P(\hat{Y} = 1 | S = g)$$

$$TPR_g = P\left(\hat{Y} = 1 \middle| Y = 1, S = g\right) = \frac{TP_g}{TP_g + FN_g}$$

$$FPR_g = P\left(\hat{Y} = 1 \middle| Y = 0, S = g\right) = \frac{FP_g}{FP_g + TN_g}$$

$$FNR_g = P\left(\hat{Y} = 0 \middle| Y = 1, S = g\right) = \frac{FN_g}{FN_g + TP_g}$$

$$Precision_g = P\left(Y = 1 \middle| \hat{Y} = 1, S = g\right) = \frac{TP_g}{TP_g + FP_g}$$

Demographic Parity بر برابری نرخ خروجی مثبت، Equal Opportunity بر برابری TPR و Predictive Parity بر برابری Precision میان گروه‌ها تمرکز دارند. Equalized Odds شرط سخت‌گیرانه‌تری است و برابری هم‌زمان TPR و FPR را بررسی می‌کند.

در پیاده‌سازی حاضر، برای ویژگی‌های دارای دو یا چند گروه، شکاف هر معیار به‌صورت فاصله میان بیشترین و کمترین مقدار مشاهده‌شده محاسبه شد:

$$\Delta_{DP} = \max_g PPR_g - \min_g PPR_g$$

$$\Delta_{EOpp} = \max_g TPR_g - \min_g TPR_g$$

$$\Delta_{FPR} = \max_g FPR_g - \min_g FPR_g$$

$$\Delta_{EOdds} = \max\left(\Delta_{EOpp}, \Delta_{FPR}\right)$$

$$\Delta_{PP} = \max_g Precision - \min_g Precision$$

مقدار صفر برای هر شکاف نشان‌دهنده برابری کامل همان معیار است، اما کوچک‌بودن یک شکاف لزوماً به معنای برقراری سایر معیارهای عدالت نیست. برای نمونه، دو گروه ممکن است Precision تقریباً یکسانی داشته باشند، ولی نرخ دریافت خروجی مثبت یا نرخ منفی کاذب آن‌ها متفاوت باشد. در نوت‌بوک نیز تمام شکاف‌های چندگروهی بر اساس قرارداد بیشینه منهای کمینه محاسبه شده‌اند.

۲-۳-۲- تحلیل عدالت بر اساس جنسیت

نتایج تفکیک‌شده بر اساس جنسیت در جدول ۲-۱۰ ارائه شده‌اند. نرخ پایه مثبت در مجموعه آزمون برای زنان ۰.۱۱۱۶ و برای مردان ۰.۳۰۴۲ است؛ بنابراین تفاوت نرخ خروجی مثبت مدل‌ها باید در کنار این اختلاف اولیه تفسیر شود.

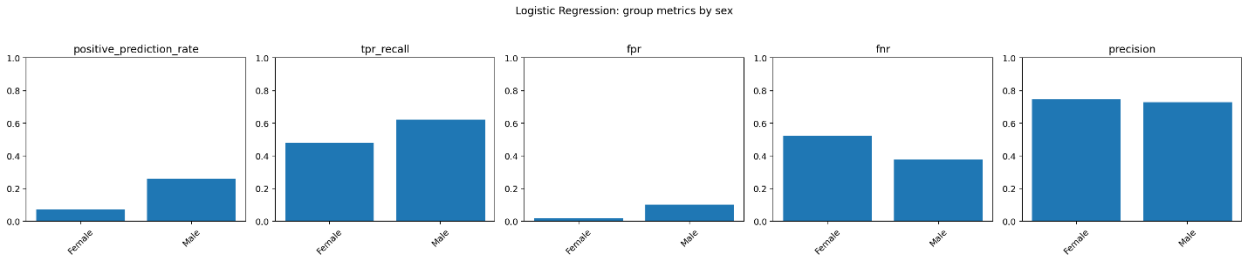
جدول ۲-۱۰: معیارهای عملکرد گروهی مدل‌ها بر اساس جنسیت

مدل	گروه	تعداد نمونه	نرخ پایه	نرخ خروجی مثبت	TPR	FPR	FNR	Precision
رگرسیون لجستیک	زنان	۳۲۸۹	۰.۱۱۱۶	۰.۰۷۱۸	۰.۴۷۹۶	۰.۰۲۰۵	۰.۵۲۰۴	۰.۷۴۵۸
رگرسیون لجستیک	مردان	۶۴۸۰	۰.۳۰۴۲	۰.۲۵۹۷	۰.۶۲۲۰	۰.۱۰۱۴	۰.۳۷۸۰	۰.۷۲۸۵
جنگل تصادفی	زنان	۳۲۸۹	۰.۱۱۱۶	۰.۰۷۴۸	۰.۵۲۰۴	۰.۰۱۸۸	۰.۴۷۹۶	۰.۷۷۶۴
جنگل تصادفی	مردان	۶۴۸۰	۰.۳۰۴۲	۰.۲۴۸۸	۰.۶۳۷۷	۰.۰۷۸۷	۰.۳۶۲۳	۰.۷۷۹۸

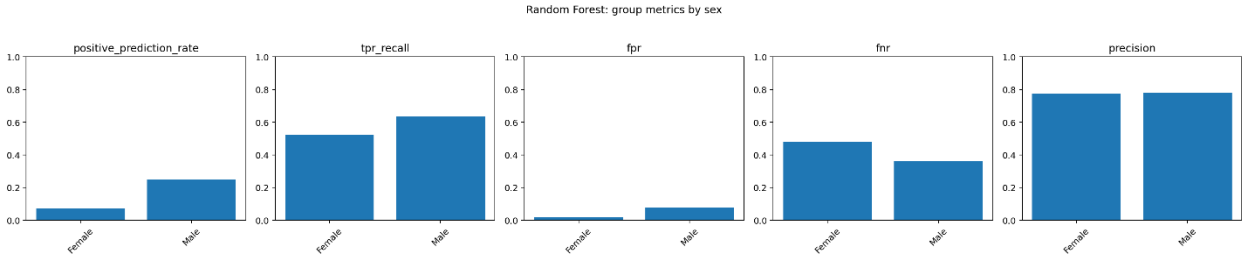
در هر دو مدل، زنان نسبت به مردان نرخ خروجی مثبت و TPR پایین‌تری دارند. برای جنگل تصادفی، تنها ۷.۴۸ درصد زنان خروجی مثبت دریافت کرده‌اند، درحالی‌که این مقدار برای مردان ۲۴.۸۸ درصد است؛ بنابراین شکاف Demographic Parity برابر با ۰.۱۷۴۰ است. همچنین TPR زنان ۰.۵۲۰۴ و TPR مردان ۰.۶۳۷۷ است که شکاف Equal Opportunity برابر با ۰.۱۱۷۳ را ایجاد می‌کند.

این اختلاف در TPR مستقیماً در FNR منعکس شده است. جنگل تصادفی ۴۷.۹۶ درصد از زنان واقعاً مثبت و ۳۶.۲۳ درصد از مردان واقعاً مثبت را شناسایی نکرده است. در مقابل، FPR مردان بیشتر است؛ به‌طوری‌که ۷.۸۷ درصد مردان واقعاً منفی به‌اشتباه مثبت پیش‌بینی شده‌اند، درحالی‌که این مقدار برای زنان ۱.۸۸ درصد است. بنابراین نمی‌توان یک گروه را در تمام انواع خطا نامطلوب‌تر دانست: زنان بار بیشتری از خطای منفی کاذب و مردان بار بیشتری از خطای مثبت کاذب را تجربه کرده‌اند.

Precision جنگل تصادفی برای زنان و مردان به‌ترتیب ۰.۷۷۶۴ و ۰.۷۷۹۸ است و شکاف آن فقط ۰.۰۰۳۴ است. در نتیجه Predictive Parity تقریباً برقرار است، اما این برابری هم‌زمان با تفاوت محسوس در نرخ دریافت خروجی مثبت و TPR مشاهده می‌شود. این نتیجه نشان می‌دهد گزارش تنها یک معیار عدالت می‌تواند تصویری ناقص از رفتار مدل ارائه دهد.



*شکل ۲–۴: مقایسه نرخ خروجی مثبت، **TPR**، **FPR**، **FNR** و **Precision** رگرسیون لجستیک در گروه‌های جنسیتی.*



*شکل ۲–۵: مقایسه نرخ خروجی مثبت، **TPR**، **FPR**، **FNR** و **Precision** جنگل تصادفی در گروه‌های جنسیتی.*

جنگل تصادفی نسبت به رگرسیون لجستیک شکاف‌های جنسیتی DP، Equal Opportunity و Equalized Odds را کاهش داده است؛ بااین‌حال، این کاهش به معنای حذف نابرابری نیست. بهبود TPR زنان از ۰.۴۷۹۶ به ۰.۵۲۰۴ مهم است، اما همچنان تقریباً نیمی از زنان واقعاً مثبت خروجی منفی دریافت می‌کنند.

۲-۳-۳- تحلیل عدالت بر اساس نژاد و گروه‌های تقاطعی

رفتار مدل‌ها بر اساس پنج گروه نژادی در جدول ۲-۱۱ گزارش شده است. اندازه گروه‌ها به‌شدت نامتوازن است؛ به‌ویژه گروه‌های Amer-Indian-Eskimo و Other در مجموعه آزمون به‌ترتیب تنها ۱۰۴ و ۶۹ نمونه دارند. ازاین‌رو، تغییر چند پیش‌بینی می‌تواند مقدار معیارهای این گروه‌ها را به‌طور محسوس تغییر دهد.

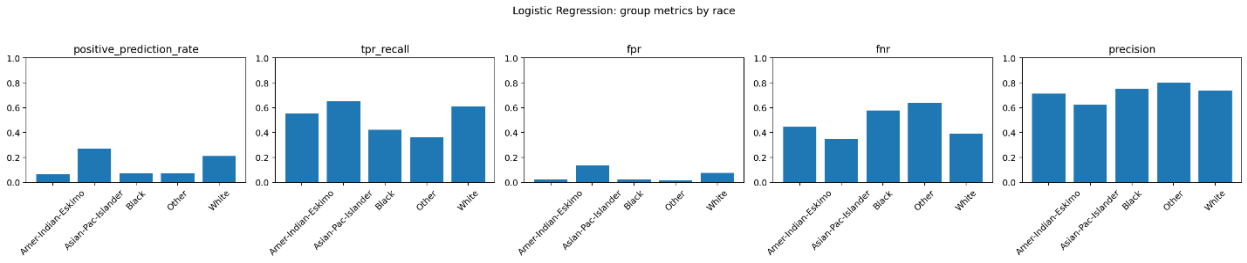
جدول ۲–۱۱: معیارهای عملکرد گروهی مدل‌ها بر اساس نژاد

مدل	گروه	تعداد نمونه	نرخ خروجی مثبت	TPR	FPR	FNR	Precision
رگرسیون لجستیک	Amer-Indian-Eskimo	۱۰۴	۰.۰۶۷۳	۰.۵۵۵۶	۰.۰۲۱۱	۰.۴۴۴۴	۰.۷۱۴۳
رگرسیون لجستیک	Asian-Pac-Islander	۳۰۴	۰.۲۶۹۷	۰.۶۵۳۸	۰.۱۳۷۲	۰.۳۴۶۲	۰.۶۲۲۰
رگرسیون لجستیک	Black	۹۴۴	۰.۰۷۲۰	۰.۴۲۱۵	۰.۰۲۰۷	۰.۵۷۸۵	۰.۷۵۰۰
رگرسیون لجستیک	Other	۶۹	۰.۰۷۲۵	۰.۳۶۳۶	۰.۰۱۷۲	۰.۶۳۶۴	۰.۸۰۰۰
رگرسیون لجستیک	White	۸۳۴۸	۰.۲۱۰۵	۰.۶۰۹۲	۰.۰۷۴۸	۰.۳۹۰۸	۰.۷۳۴۸
جنگل تصادفی	Amer-Indian-Eskimo	۱۰۴	۰.۰۷۶۹	۰.۵۵۵۶	۰.۰۳۱۶	۰.۴۴۴۴	۰.۶۲۵۰
جنگل تصادفی	Asian-Pac-Islander	۳۰۴	۰.۲۴۳۴	۰.۶۵۳۸	۰.۱۰۱۸	۰.۳۴۶۲	۰.۶۸۹۲
جنگل تصادفی	Black	۹۴۴	۰.۰۸۲۶	۰.۵۲۰۷	۰.۰۱۸۲	۰.۴۷۹۳	۰.۸۰۷۷
جنگل تصادفی	Other	۶۹	۰.۰۸۷۰	۰.۴۵۴۵	۰.۰۱۷۲	۰.۵۴۵۵	۰.۸۳۳۳
جنگل تصادفی	White	۸۳۴۸	۰.۲۰۲۷	۰.۶۲۴۸	۰.۰۵۹۱	۰.۳۷۵۲	۰.۷۸۲۵

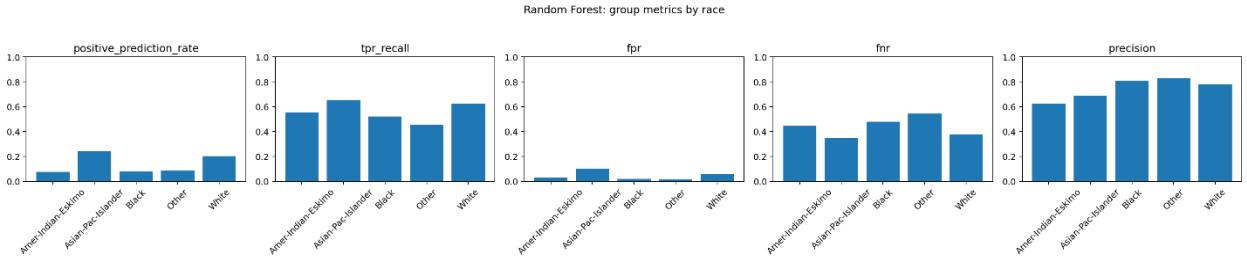
در جنگل تصادفی، بیشترین TPR متعلق به گروه Asian-Pac-Islander با مقدار ۰.۶۵۳۸ و کمترین TPR متعلق به گروه Other با مقدار ۰.۴۵۴۵ است؛ در نتیجه شکاف Equal Opportunity برابر با ۰.۱۹۹۳ است. بااین‌حال، گروه Other تنها ۱۱ نمونه مثبت واقعی دارد و مقدار TPR آن بر اساس پنج پیش‌بینی مثبت درست به دست آمده است. بنابراین رتبه‌بندی قطعی گروه‌ها بر اساس این مقدار قابل اتکا نیست.

گروه Black با ۱۲۱ نمونه مثبت واقعی، FNR برابر با ۰.۴۷۹۳ دارد که از مقدار متناظر گروه White یعنی ۰.۳۷۵۲ بیشتر است. این اختلاف با پشتیبانی نمونه‌ای بیشتری نسبت به گروه‌های کوچک همراه است و نشان می‌دهد جنگل تصادفی نسبت کمتری از نمونه‌های مثبت واقعی گروه Black را شناسایی کرده است.

از سوی دیگر، گروه Asian-Pac-Islander بیشترین FPR را در هر دو مدل دارد. FPR این گروه در رگرسیون لجستیک ۰.۱۳۷۲ و در جنگل تصادفی ۰.۱۰۱۸ است. بنابراین افزایش TPR این گروه با نرخ بیشتر مثبت کاذب همراه بوده است و باید به‌عنوان یک Trade-off میان شناسایی نمونه‌های مثبت و افزایش خطای مثبت کاذب تفسیر شود.



شکل ۲–۶: مقایسه معیارهای عدالت رگرسیون لجستیک در پنج گروه نژادی.



شکل ۲–۷: مقایسه معیارهای عدالت جنگل تصادفی در پنج گروه نژادی.

جدول ۲-۱۲ خلاصه شکاف‌های عدالت را برای جنسیت، نژاد و گروه‌های تقاطعی ارائه می‌کند.

جدول ۲–۱۲: خلاصه شکاف‌های عدالت مدل‌ها

مدل	ویژگی حساس	تعداد گروه	DP	Equal Opportunity	Equalized Odds	Predictive Parity	شکاف FPR	شکاف FNR
رگرسیون لجستیک	جنسیت	۲	۰.۱۸۸۰	۰.۱۴۲۵	۰.۱۴۲۵	۰.۰۱۷۳	۰.۰۸۰۸	۰.۱۴۲۵
رگرسیون لجستیک	نژاد	۵	۰.۲۰۲۴	۰.۲۹۰۲	۰.۲۹۰۲	۰.۱۷۸۰	۰.۱۱۹۹	۰.۲۹۰۲
رگرسیون لجستیک	جنسیت × نژاد	۹	۰.۳۳۹۲	۰.۴۱۶۷	۰.۴۱۶۷	۰.۴۵۴۵	۰.۲۰۴۷	۰.۴۱۶۷
جنگل تصادفی	جنسیت	۲	۰.۱۷۴۰	۰.۱۱۷۳	۰.۱۱۷۳	۰.۰۰۳۴	۰.۰۵۹۹	۰.۱۱۷۳
جنگل تصادفی	نژاد	۵	۰.۱۶۶۵	۰.۱۹۹۳	۰.۱۹۹۳	۰.۲۰۸۳	۰.۰۸۴۵	۰.۱۹۹۳
جنگل تصادفی	جنسیت × نژاد	۹	۰.۲۹۹۰	۰.۳۵۰۰	۰.۳۵۰۰	۰.۴۰۰۰	۰.۱۵۷۵	۰.۳۵۰۰

جنگل تصادفی نسبت به رگرسیون لجستیک شکاف‌های DP، Equal Opportunity و Equalized Odds را برای هر سه نوع گروه‌بندی کاهش داده است. بااین‌حال، شکاف Predictive Parity نژادی از ۰.۱۷۸۰ به ۰.۲۰۸۳ افزایش یافته است؛ بنابراین بهبود یک مجموعه از معیارها با بهبود تمام معیارهای عدالت همراه نبوده است.

در تحلیل تقاطعی، گروه Female | Other به دلیل داشتن تنها ۲۰ نمونه از محاسبه شکاف‌ها کنار گذاشته شد و ۹ گروه دارای حداقل ۳۰ نمونه حفظ شدند. حتی در میان گروه‌های حفظ‌شده نیز چند گروه کمتر از ۲۰ نمونه مثبت واقعی دارند؛ برای مثال Male | Amer-Indian-Eskimo تنها چهار و Female | Amer-Indian-Eskimo تنها پنج نمونه مثبت واقعی دارند. بنابراین شکاف‌های بزرگ تقاطعی، هرچند نشانه‌ای از ناهمگنی رفتار مدل هستند، باید به‌عنوان نتایج اکتشافی و نه برآوردهای پایدار جمعیتی تفسیر شوند.

۲-۳-۴- ارزیابی کالیبراسیون گروهی

عدالت تصمیم‌های دودویی و کالیبراسیون احتمال‌ها دو مفهوم متفاوت‌اند. یک مدل در یک گروه کالیبره است اگر میان نمونه‌هایی که احتمال مشابهی دریافت کرده‌اند، فراوانی واقعی طبقه مثبت نیز تقریباً با همان احتمال برابر باشد.

در این آزمایش، علاوه بر منحنی کالیبراسیون، سه معیار عددی بررسی شدند. Calibration-in-the-Large اختلاف میانگین احتمال پیش‌بینی‌شده و نرخ واقعی مثبت گروه را اندازه‌گیری می‌کند؛ مقدار مثبت به معنای بیش‌برآوردی و مقدار منفی به معنای

کم‌برآوردی احتمال است. Brier Score خطای مربعی احتمال‌ها و ECE اختلاف میانگین اطمینان و نرخ واقعی را در بازه‌های احتمال اندازه‌گیری می‌کند:

$$CIL_g = \frac{1}{n_g}\sum_{i:S_i=g} p_i = \frac{1}{n_g}\sum_{i:S_i=g} y_i$$

$$Brier_g = \frac{1}{n_g}\sum_{i:S_i=g} (p_i - y_i)^2$$

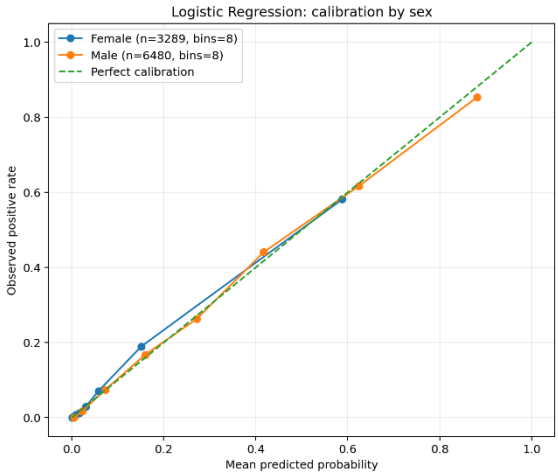
$$ECE_g = \sum_{b=1}^{B} \frac{|I_b|}{n_g} \left| mean_{i\in I_b}(p_i) - mean_{i\in I_b}(y_i) \right|$$

مقادیر کالیبراسیون جنسیتی در جدول ۲-۱۳ ارائه شده‌اند

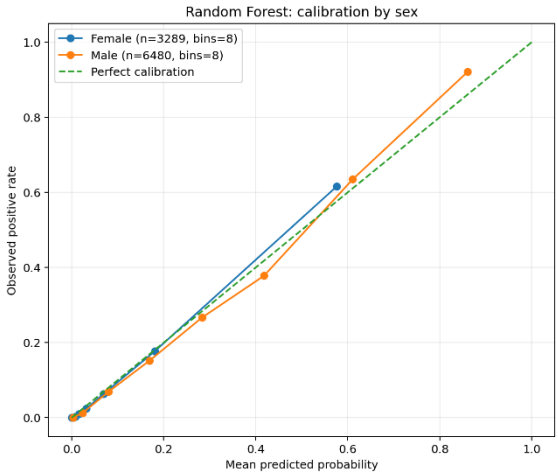
جدول ۲–۱۳: معیارهای کالیبراسیون بر اساس جنسیت

مدل	گروه	میانگین احتمال	نرخ پایه	CIL	Brier Score	ECE
رگرسیون لجستیک	زنان	۰.۱۰۷۵	۰.۱۱۱۶	-۰.۰۰۴۱	۰.۰۵۸۴	۰.۰۱۲۳
رگرسیون لجستیک	مردان	۰.۳۰۶۹	۰.۳۰۴۲	۰.۰۰۲۷	۰.۱۲۶۴	۰.۰۰۹۶
جنگل تصادفی	زنان	۰.۱۱۰۶	۰.۱۱۱۶	-۰.۰۰۱۰	۰.۰۵۳۵	۰.۰۱۱۹
جنگل تصادفی	مردان	۰.۳۰۶۰	۰.۳۰۴۲	۰.۰۰۱۸	۰.۱۱۶۴	۰.۰۲۳۲

CIL هر دو مدل در گروه‌های جنسیتی به صفر نزدیک است؛ بنابراین میانگین احتمال‌های پیش‌بینی‌شده با نرخ پایه هر گروه اختلاف اندکی دارد. جنگل تصادفی Brier Score هر دو گروه را نسبت به رگرسیون لجستیک کاهش داده است، اما ECE مردان در آن از ۰.۰۰۹۶ به ۰.۰۲۳۲ افزایش یافته است. این تفاوت نشان می‌دهد بهبود Brier Score الزاماً با کاهش تمام معیارهای خطای کالیبراسیون همراه نیست.



شکل ۲–۸: منحنی‌های کالیبراسیون رگرسیون لجستیک به تفکیک جنسیت.



شکل ۲–۹: منحنی‌های کالیبراسیون جنگل تصادفی به تفکیک جنسیت.

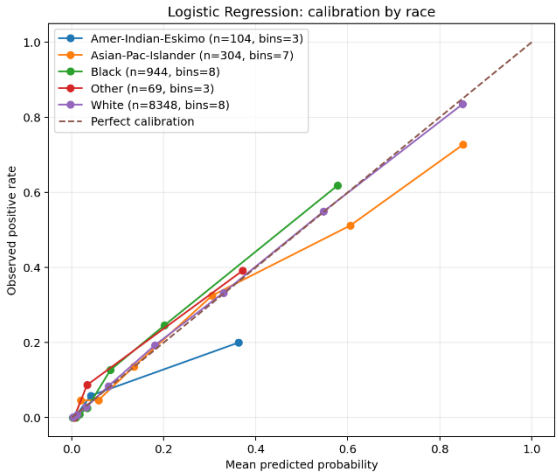
نتایج کالیبراسیون نژادی در جدول ۲-۱۴ گزارش شده‌اند.

جدول ۲–۱۴: معیارهای کالیبراسیون بر اساس نژاد

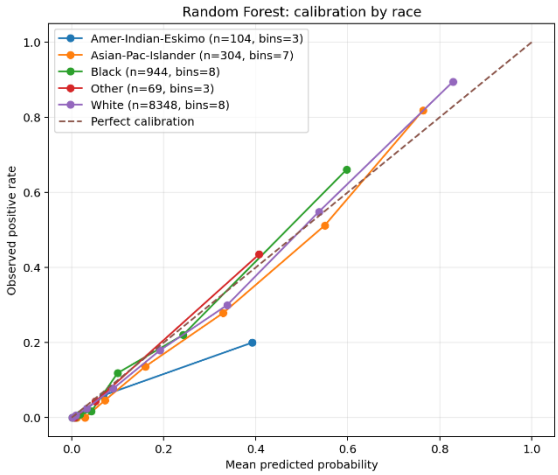
مدل	گروه	CIL	Brier Score	ECE	تعداد بازه ECE
رگرسیون لجستیک	Amer-Indian-Eskimo	۰.۰۵۱۰	۰.۰۵۸۶	۰.۰۶۷۲	۳
رگرسیون لجستیک	Asian-Pac-Islander	۰.۰۲۶۸	۰.۱۲۷۴	۰.۰۴۸۵	۶
رگرسیون لجستیک	Black	-۰.۰۱۲۰	۰.۰۶۵۹	۰.۰۱۴۵	۱۰
رگرسیون لجستیک	Other	-۰.۰۲۲۹	۰.۰۸۱۵	۰.۰۴۰۷	۳
رگرسیون لجستیک	White	۰.۰۰۰۴	۰.۱۰۷۷	۰.۰۰۹۰	۱۰
جنگل تصادفی	Amer-Indian-Eskimo	۰.۰۷۱۲	۰.۰۶۵۵	۰.۰۸۷۶	۳
جنگل تصادفی	Asian-Pac-Islander	۰.۰۱۷۲	۰.۱۰۸۷	۰.۰۳۹۶	۶
جنگل تصادفی	Black	-۰.۰۰۱۹	۰.۰۶۰۸	۰.۰۲۷۰	۱۰
جنگل تصادفی	Other	-۰.۰۰۴۵	۰.۰۷۴۹	۰.۰۳۲۹	۳
جنگل تصادفی	White	-۰.۰۰۰۲	۰.۰۹۹۲	۰.۰۱۹۰	۱۰

بیشترین بیش‌برآوردی میانگین احتمال در هر دو مدل برای گروه Amer-Indian-Eskimo مشاهده می‌شود. در جنگل تصادفی، میانگین احتمال پیش‌بینی‌شده این گروه ۰.۰۷۱۲ بیشتر از نرخ واقعی آن است. بااین‌حال، این گروه در مجموعه آزمون تنها ۱۰۴ نمونه و ۹ نمونه مثبت واقعی دارد؛ بنابراین مقدار به‌دست‌آمده می‌تواند نسبت به تغییر پیش‌بینی تعداد کمی از نمونه‌ها حساس باشد. در نتیجه، این مشاهده صرفاً نشانه‌ای اولیه از بیش‌برآوردی احتمال برای این گروه است و نمی‌توان بر اساس آن نتیجه گرفت که مدل در جامعه اصلی نیز به‌طور پایدار همین میزان بیش‌برآوردی دارد. تأیید چنین نتیجه‌ای به داده بیشتر یا محاسبه بازه‌های اطمینان نیاز دارد.

برای جلوگیری از بازه‌های تقریباً خالی، تعداد بازه‌های ECE به‌صورت تطبیقی و بر اساس اندازه گروه انتخاب شده است. ازاین‌رو، مقایسه مستقیم ECE گروهی که با سه بازه محاسبه شده با گروهی که ده بازه دارد، باید با احتیاط انجام شود. در گروه‌های کوچک، منحنی کالیبراسیون، CIL، Brier Score و تعداد نمونه‌ها مبنای مطمئن‌تری برای تفسیر مشترک فراهم می‌کنند.



شکل ۲–۱۰: منحنی‌های کالیبراسیون رگرسیون لجستیک به تفکیک نژاد.



شکل ۲–۱۱: منحنی‌های کالیبراسیون جنگل تصادفی به تفکیک نژاد.

در مجموع، احتمال‌های هر دو مدل برای گروه‌های بزرگ، به‌ویژه گروه White و گروه‌های جنسیتی، از نظر میانگین احتمال به نرخ واقعی نزدیک‌اند. بااین‌حال، تفاوت قابل‌توجه در نرخ خروجی مثبت و FNR همچنان باقی مانده است. بنابراین کالیبراسیون مناسب احتمال‌ها لزوماً به معنای برابری تصمیم‌های نهایی یا نرخ خطاها میان گروه‌ها نیست.

۲-۳-۵- گروه آسیب‌دیده و هزینه انواع خطا

تعیین گروه «آسیب‌دیده‌تر» بدون مشخص‌کردن زمینه استفاده و هزینه خطاها ممکن نیست. در کاربردی که خروجی مثبت مدل نماینده دسترسی به یک فرصت اقتصادی باشد، خطای منفی کاذب می‌تواند زیان مستقیم‌تری برای فرد ایجاد کند؛ زیرا فردی که واقعاً متعلق به طبقه مثبت است، از دریافت فرصت محروم می‌شود. در مقابل، خطای مثبت کاذب ممکن است هزینه تصمیم اشتباه را به نهاد تصمیم‌گیرنده یا مراحل بعدی سامانه منتقل کند.

برای کمک به تحلیل زمینه‌محور، در نوت‌بوک یک امتیاز توصیفی با وزن بیشتر برای FNR تعریف شد:

$$HarmScore_g = 0.60FNR_g + 0.25(\max_h PPR_h - PPR_g) + 0.15|CIL_g|$$

این امتیاز یک معیار استاندارد عدالت نیست و صرفاً اولویت فرضی یک کاربرد مبتنی بر تخصیص فرصت را بازنمایی می‌کند. بر اساس آن، بیشترین بار فرصت برای زنان به دست آمد: مقدار امتیاز در رگرسیون لجستیک ۰.۳۶۰ و در جنگل تصادفی ۰.۳۳۱ بود. این نتیجه با FNR بالاتر و نرخ خروجی مثبت پایین‌تر زنان سازگار است.

بااین‌حال، زنان در تمام معیارها وضعیت نامطلوب‌تری ندارند. FPR مردان در هر دو مدل بیشتر است و Precision جنگل تصادفی تقریباً میان دو جنس برابر است. بنابراین نتیجه قابل‌دفاع آن است که زنان از منظر ازدست‌دادن فرصت و خطای منفی کاذب بار بیشتری تحمل می‌کنند، درحالی‌که مردان بیشتر در معرض خطای مثبت کاذب قرار گرفته‌اند. انتخاب معیار اولویت‌دار باید بر اساس پیامد واقعی هر نوع خطا انجام شود، نه صرفاً بر اساس یک امتیاز تجمیعی.

در تحلیل نژادی نیز نتیجه به معیار وابسته است. گروه‌های Black و Other FNR بالاتری دارند، اما گروه Asian-Pac-Islander دارای FPR بیشتری است. علاوه بر این، اندازه کوچک برخی گروه‌ها مانع نتیجه‌گیری قطعی درباره رتبه‌بندی آسیب می‌شود. ازاین‌رو، برای تصمیم‌های حساس لازم است بازه‌های عدم قطعیت یا ارزیابی روی داده‌های بیشتر نیز در نظر گرفته شوند.

۲-۳-۶- حذف ویژگی‌های حساس و باقی‌ماندن ویژگی‌های جانشین

برای بررسی اینکه آیا حذف مستقیم ویژگی‌های حساس مسئله عدالت را حل می‌کند، یک جنگل تصادفی جدید پس از حذف هم‌زمان sex و race آموزش داده شد. این مدل همچنان با استفاده از آستانه ۰.۵ روی همان مجموعه آزمون ارزیابی شد. نتایج عملکرد در جدول ۲-۱۵ آمده‌اند.

جدول ۲–۱۵: عملکرد جنگل تصادفی قبل و بعد از حذف ویژگی‌های حساس

مدل	Accuracy	Precision	Recall	F1	ROC-AUC	Brier Score
با ***sex*** و ***race***	۰.۸۶۶۹	۰.۷۷۹۳	۰.۶۱۹۳	۰.۶۹۰۲	۰.۹۱۷۰	۰.۰۹۵۲
بدون ***sex*** و ***race***	۰.۸۶۶۶	۰.۷۷۸۱	۰.۶۱۹۳	۰.۶۸۹۷	۰.۹۱۶۳	۰.۰۹۵۸

حذف ویژگی‌های حساس تغییر محسوسی در عملکرد کلی ایجاد نکرد. Accuracy تنها ۰.۰۰۰۳، F1 حدود ۰.۰۰۰۵ و ROC-AUC حدود ۰.۰۰۰۷ کاهش یافته است. این پایداری نشان می‌دهد بخش عمده اطلاعات مورد استفاده مدل از سایر ویژگی‌ها قابل بازیابی بوده است.

اثر حذف ویژگی‌ها بر شکاف‌های عدالت در جدول ۲-۱۶ گزارش شده است.

*جدول ۲-۱۶: تغییر شکاف‌های عدالت پس از حذف **sex** و **race***

ویژگی ارزیابی	مدل	DP	Equal Opportunity	Equalized Odds	Predictive Parity	شکاف FPR	شکاف کالیبراسیون
جنسیت	با ویژگی‌های حساس	۰.۱۷۴۰	۰.۱۱۷۳	۰.۱۱۷۳	۰.۰۰۳۴	۰.۰۵۹۹	۰.۰۰۰۸
جنسیت	بدون ویژگی‌های حساس	۰.۱۷۴۹	۰.۱۱۷۳	۰.۱۱۷۳	۰.۰۰۱۷	۰.۰۶۱۱	۰.۰۰۳۹
نژاد	با ویژگی‌های حساس	۰.۱۶۶۵	۰.۱۹۹۳	۰.۱۹۹۳	۰.۲۰۸۳	۰.۰۸۴۵	۰.۰۷۰۹
نژاد	بدون ویژگی‌های حساس	۰.۱۶۰۲	۰.۲۱۲۱	۰.۲۱۲۱	۰.۲۷۷۸	۰.۰۸۴۵	۰.۰۸۱۷

در تحلیل جنسیتی، حذف ویژگی‌های حساس شکاف DP را اندکی از ۰.۱۷۴۰ به ۰.۱۷۴۹ افزایش داده و Equal Opportunity و Equalized Odds را بدون تغییر باقی گذاشته است. هرچند شکاف Predictive Parity کاهش یافته، شکاف FPR و شکاف کالیبراسیون افزایش یافته‌اند.

در تحلیل نژادی، شکاف DP اندکی کاهش یافته است، اما Equal Opportunity و Equalized Odds از ۰.۱۹۹۳ به ۰.۲۱۲۱ و Predictive Parity از ۰.۲۰۸۳ به ۰.۲۷۷۸ افزایش یافته‌اند. بنابراین حذف مستقیم sex و race تنها یکی از معیارها را اندکی بهتر کرده و چند معیار دیگر را بدتر کرده است.

این نتیجه نشان می‌دهد ناآگاهی صریح مدل از ویژگی حساس معادل عدالت نیست. ویژگی‌هایی مانند relationship، marital-status، occupation، education و سابقه یا الگوی کار می‌توانند با جنسیت یا نژاد هم‌بستگی داشته باشند و بخشی از اطلاعات آن‌ها را به‌صورت غیرمستقیم منتقل کنند. در بخش توضیح‌پذیری سراسری، اهمیت این ویژگی‌ها بررسی می‌شود تا شواهد بیشتری درباره نقش احتمالی آن‌ها به‌عنوان Proxy ارائه شود. بااین‌حال، صرف اهمیت یک ویژگی برای اثبات رابطه علّی یا تبعیض کافی نیست و نتیجه باید در کنار تحلیل‌های گروهی و دانش حوزه تفسیر شود.

۲-۴- توضیح‌پذیری سراسری مدل

در این بخش، رفتار کلی مدل جنگل تصادفی با سه روش Permutation Feature Importance، Partial Dependence Plot (PDP) و SHAP بررسی می‌شود. استفاده هم‌زمان از این روش‌ها ضروری است؛ زیرا میزان اهمیت یک ویژگی، جهت اثر آن

و نحوه مشارکت مقادیر مختلف آن در خروجی مدل مفاهیم متفاوتی هستند. تحلیل حاضر علاوه بر شناسایی ویژگی‌های مهم، نقش مستقیم ویژگی‌های حساس و نقش احتمالی ویژگی‌های جانشین را بررسی می‌کند.

۲-۴-۱- اهمیت ویژگی بر اساس درهم‌ریزی

در روش Permutation Feature Importance، ابتدا عملکرد مدل روی داده‌های بدون تغییر اندازه‌گیری می‌شود. سپس مقادیر یک ویژگی به‌صورت تصادفی میان نمونه‌ها جابه‌جا شده و افت عملکرد مدل محاسبه می‌شود. اگر درهم‌ریزی یک ویژگی باعث کاهش محسوس ROC-AUC شود، مدل برای رتبه‌بندی نمونه‌های مثبت و منفی وابستگی بیشتری به آن ویژگی دارد. اهمیت ویژگی j با R بار تکرار به‌صورت زیر محاسبه می‌شود:

$$I_j^r = AUC(X, y) - AUC(X_{\pi_j^r}, y)$$

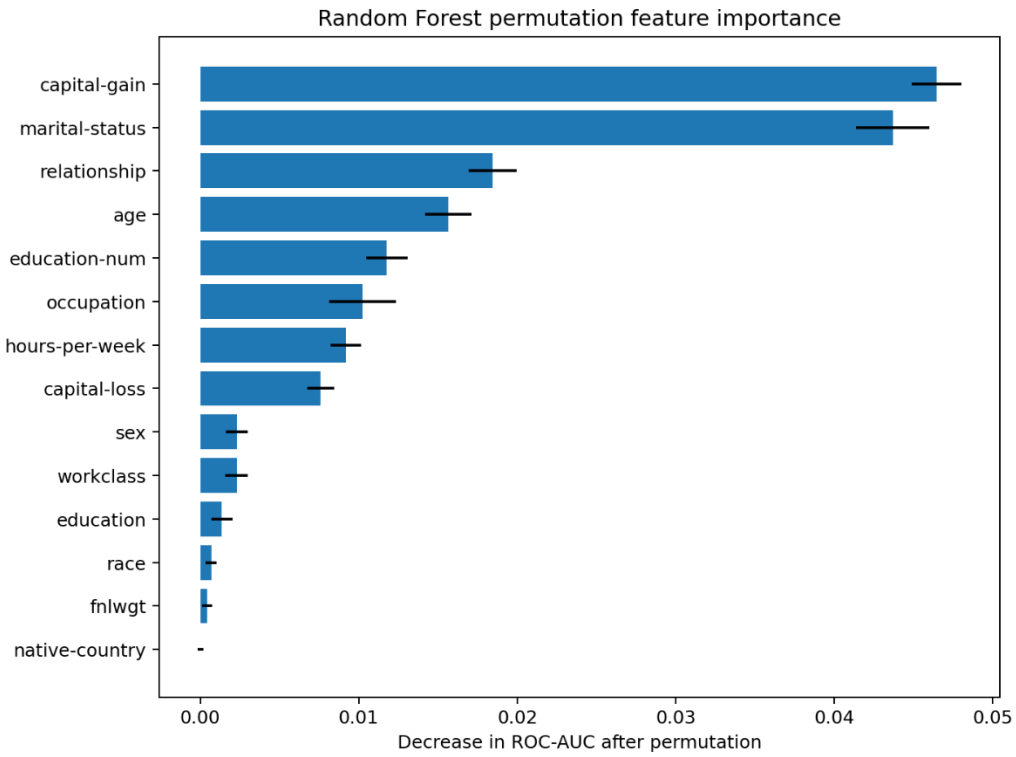
$$\overline{I_j} = \frac{1}{R}\sum_{r=1}^{R} I_j^r$$

در این آزمایش، محاسبات روی ۵۰۰۰ نمونه از مجموعه آزمون و با ۱۰ بار تکرار برای هر ویژگی انجام شد. میانگین و انحراف معیار افت ROC-AUC در جدول ۲-۱۷ گزارش شده‌اند.

*جدول ۲–۱۷: اهمیت ویژگی‌های جنگل تصادفی بر اساس افت **ROC-AUC** پس از درهم‌ریزی*

رتبه	ویژگی	میانگین اهمیت	انحراف معیار
۱	capital-gain	۰.۰۴۶۵	۰.۰۰۱۶
۲	marital-status	۰.۰۴۳۷	۰.۰۰۲۳
۳	relationship	۰.۰۱۸۴	۰.۰۰۱۵
۴	age	۰.۰۱۵۷	۰.۰۰۱۵
۵	education-num	۰.۰۱۱۸	۰.۰۰۱۳
۶	occupation	۰.۰۱۰۳	۰.۰۰۲۱
۷	hours-per-week	۰.۰۰۹۲	۰.۰۰۱۰
۸	capital-loss	۰.۰۰۷۶	۰.۰۰۰۸
۹	sex	۰.۰۰۲۳	۰.۰۰۰۷
۱۰	workclass	۰.۰۰۲۳	۰.۰۰۰۷
۱۱	education	۰.۰۰۱۴	۰.۰۰۰۷
۱۲	race	۰.۰۰۰۷	۰.۰۰۰۳
۱۳	fnlwgt	۰.۰۰۰۴	۰.۰۰۰۳
۱۴	native-country	۰.۰۰۰۰	۰.۰۰۰۲

دو ویژگی capital-gain و marital-status بیشترین افت ROC-AUC را ایجاد کرده‌اند و فاصله اهمیت آن‌ها با سایر ویژگی‌ها قابل‌توجه است. پس از آن، ویژگی‌های relationship، age، education-num، occupation و hours-per-week قرار دارند. کوچک‌بودن انحراف معیار نسبت به میانگین اهمیت در ویژگی‌های بالای جدول نیز نشان می‌دهد اهمیت آن‌ها در تکرارهای مختلف نسبتاً پایدار بوده است.



*شکل ۲–۱۲: اهمیت ویژگی‌های جنگل تصادفی بر اساس میانگین افت **ROC-AUC** پس از درهم‌ریزی، همراه با انحراف معیار ۱۰ تکرار.*

ویژگی حساس sex در رتبه نهم قرار گرفته و اهمیت آن به‌مراتب کمتر از ویژگی‌هایی مانند capital-gain، وضعیت تأهل، رابطه خانوادگی و سن است. ویژگی race نیز در رتبه دوازدهم قرار دارد. بنابراین وابستگی مستقیم مدل به ویژگی‌های حساس در مقایسه با عوامل اصلی کمتر است، اما صفر نبودن اهمیت آن‌ها نشان می‌دهد این اطلاعات کاملاً بدون تأثیر نبوده‌اند.

از سوی دیگر، چند ویژگی دارای اهمیت زیاد، از جمله marital-status، relationship، occupation، education-num و hours-per-week ممکن است با جنسیت یا نژاد هم‌بستگی داشته باشند. در نتیجه، این ویژگی‌ها نامزدهای احتمالی Proxy Feature محسوب می‌شوند. بااین‌حال، اهمیت زیاد یک ویژگی به‌تنهایی برای اثبات نقش جانشینی آن کافی نیست و چنین ادعایی به بررسی آماری وابستگی ویژگی به گروه حساس و تحلیل زمینه‌ای نیاز دارد.

همچنین education و education-num دو نمایش وابسته از سطح تحصیلات هستند. در ویژگی‌های هم‌بسته، درهم‌ریزی تنها یکی از ستون‌ها ممکن است اهمیت میان آن‌ها را تقسیم یا منحرف کند؛ زیرا ستون دیگر بخشی از اطلاعات ازدست‌رفته را همچنان حفظ می‌کند. ازاین‌رو، اهمیت این دو ویژگی بهتر است در قالب مفهوم کلی «تحصیلات» تفسیر شود و رتبه انفرادی آن‌ها به‌عنوان اثر مستقل در نظر گرفته نشود.

۲-۴-۲- Partial Dependence Plot (PDP)

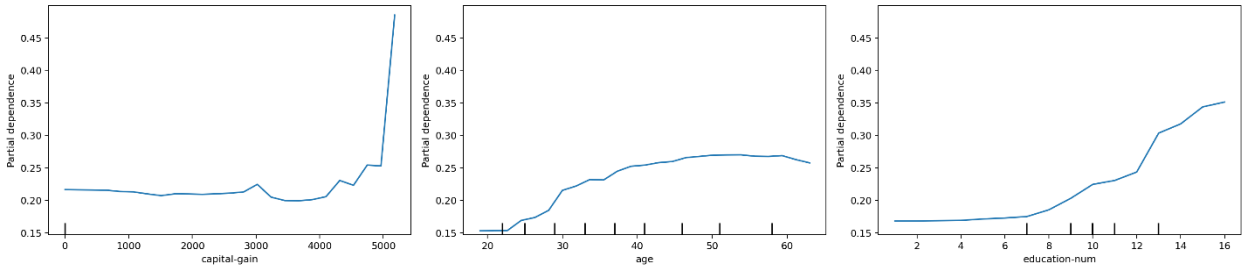
Permutation Feature Importance میزان وابستگی مدل به یک ویژگی را نشان می‌دهد، اما جهت و شکل اثر آن را مشخص نمی‌کند. برای بررسی تغییر متوسط خروجی مدل در اثر تغییر مقدار یک ویژگی، از Partial Dependence Plot استفاده

شد. برای ویژگی x_j، مقدار Partial Dependence در نقطه z به‌صورت میانگین پیش‌بینی مدل پس از قراردادن مقدار این ویژگی برابر با z تعریف می‌شود:

$$\hat{f}_j(z) = \frac{1}{n}\sum_{i=1}^{n} \hat{f}(z, x_{i,-j})$$

در این رابطه، $x_{i,-j}$ شامل سایر ویژگی‌های نمونه i است. بنابراین PDP رفتار متوسط مدل را نشان می‌دهد و نباید به‌عنوان اثر علّی تغییر یک ویژگی تفسیر شود.

سه ویژگی عددی دارای بیشترین Permutation Importance، یعنی capital-gain، age و education-num، به‌صورت خودکار انتخاب شدند. نمودارها با استفاده از ۵۰۰۰ نمونه مجموعه آزمون و شبکه‌ای شامل ۲۵ مقدار محاسبه شدند.



*شکل ۲–۱۳: **PDP** احتمال پیش‌بینی درآمد بیشتر از ۵۰ هزار دلار نسبت به ویژگی‌های **capital-gain**، **age** و **education-num** در مدل جنگل تصادفی.*

در محدوده نمایش‌داده‌شده، اثر متوسط capital-gain تا مقادیر میانی نسبتاً ثابت است و احتمال پیش‌بینی‌شده عمدتاً در محدوده ۰.۲۰ تا ۰.۲۲ باقی می‌ماند. در مقادیر بالاتر، به‌ویژه نزدیک انتهای بازه، احتمال خروجی مثبت به‌شدت افزایش می‌یابد. این رفتار با رتبه نخست capital-gain در Permutation Importance سازگار است و نشان می‌دهد مدل از مقادیر بالای سود سرمایه برای افزایش احتمال طبقه درآمد بالا استفاده می‌کند.

اثر age در سنین پایین افزایشی است. احتمال متوسط خروجی مثبت از حدود ۰.۱۵ در اوایل دهه بیست زندگی افزایش یافته و در محدوده ۴۵ تا ۵۵ سال به حدود ۰.۲۷ می‌رسد. پس از این محدوده، منحنی تقریباً ثابت شده و در انتهای بازه کاهش اندکی مشاهده می‌شود. بنابراین رابطه آموخته‌شده توسط مدل کاملاً خطی نیست و افزایش سن در تمام بازه اثر یکسانی ندارد.

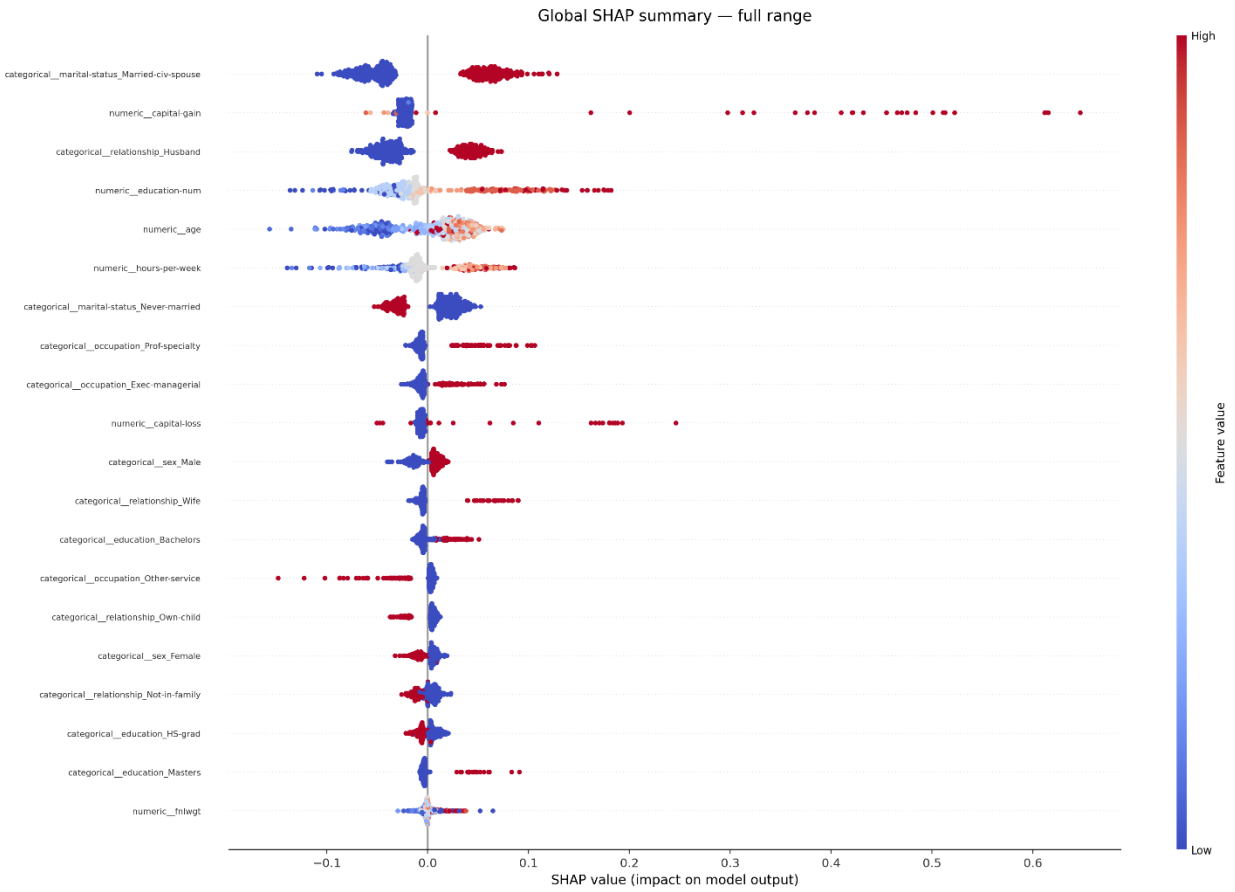
برای education-num، احتمال خروجی مثبت در سطوح پایین تحصیلات نزدیک ۰.۱۷ است و با افزایش سطح تحصیلات رشد می‌کند. افزایش منحنی پس از سطوح میانی محسوس‌تر است و در بالاترین سطوح به حدود ۰.۳۵ می‌رسد. این الگو با اهمیت ویژگی‌های تحصیلی در روش‌های دیگر سازگار است.

بااین‌حال، PDP مربوط به education-num باید با احتیاط تفسیر شود. ستون education نمایش طبقه‌ای همان مفهوم را نگه می‌دارد و روش استاندارد PDP هنگام تغییر education-num، مقدار education را ثابت باقی می‌گذارد. بنابراین ممکن است ترکیب‌های مصنوعی ناسازگاری میان این دو ستون ایجاد شوند. این محدودیت خطای اجرایی محسوب نمی‌شود، اما مانع تفسیر مستقل یا علّی اثر education-num است؛ ازاین‌رو، نتیجه مربوط به تحصیلات در کنار Permutation Importance و SHAP تفسیر می‌شود.

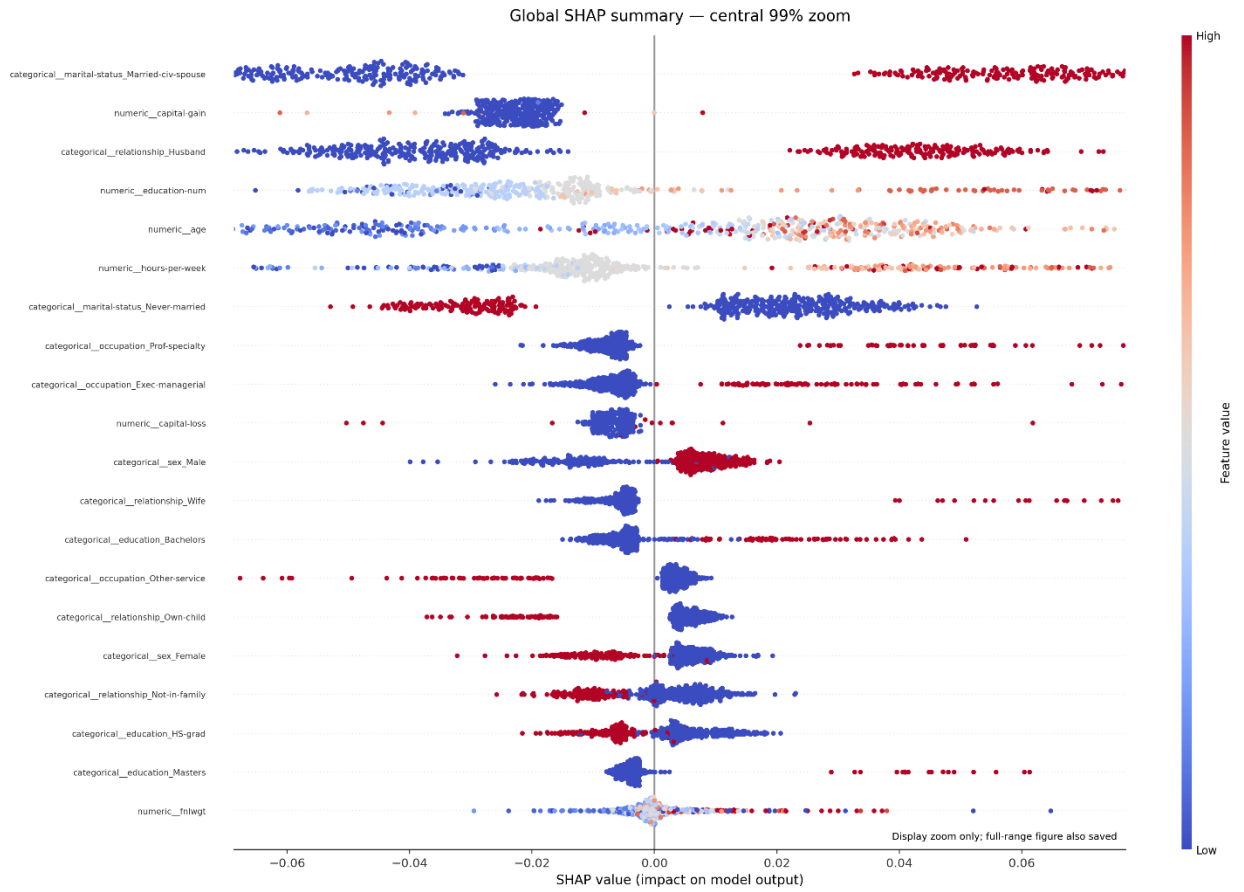
۲-۴-۳- تحلیل سراسری SHAP

روش SHAP سهم هر ویژگی را در انتقال خروجی مدل از مقدار پایه به پیش‌بینی هر نمونه محاسبه می‌کند. مقدار مثبت SHAP پیش‌بینی مدل را به سمت طبقه درآمد بالا و مقدار منفی آن پیش‌بینی را به سمت طبقه درآمد پایین جابه‌جا می‌کند. در SHAP Summary Plot، ویژگی‌ها بر اساس میانگین قدرمطلق مقادیر SHAP مرتب شده‌اند؛ رنگ قرمز بیانگر مقدار بالاتر ویژگی و رنگ آبی بیانگر مقدار پایین‌تر آن است.

برای محاسبه SHAP، تعداد ۵۰۰ نمونه ثابت از مجموعه آزمون انتخاب شدند. این نمونه‌ها پس از عبور از پیش‌پردازش آموزش‌دیده، با استفاده از TreeSHAP برای طبقه مثبت تحلیل شدند. به‌دلیل وجود چند مقدار بسیار بزرگ در capital-gain، دو نسخه از نمودار ذخیره شد: نسخه کامل که تمام دامنه مقادیر SHAP را حفظ می‌کند و نسخه بزرگ‌نمایی‌شده که محور افقی را به ۹۹ درصد مرکزی مقادیر محدود می‌کند. در نسخه دوم تنها محدوده نمایش تغییر کرده و هیچ نمونه‌ای از محاسبات حذف نشده است.



*شکل ۲–۱۴: **SHAP Summary Plot** سراسری برای طبقه درآمد بیشتر از ۵۰ هزار دلار با نمایش کامل دامنه مقادیر **SHAP***



*شکل ۲–۱۵: **SHAP Summary Plot** سراسری با بزرگ‌نمایی ۹۹ درصد مرکزی مقادیر، به‌منظور مشاهده خواناتر اثر ویژگی‌های غیرحدی.*

نتایج SHAP نشان می‌دهند حضور طبقه Married-civ-spouse در ویژگی marital-status معمولاً خروجی مدل را به سمت طبقه مثبت جابه‌جا می‌کند، درحالی‌که حضور طبقه Never-married عمدتاً اثر منفی دارد. به همین ترتیب، حضور Husband در ویژگی relationship معمولاً سهم مثبت و نبود این وضعیت سهم منفی ایجاد کرده است. این الگو با اهمیت بالای marital-status و relationship در Permutation Importance سازگار است.

مقادیر بالاتر education-num، age و hours-per-week عمدتاً در سمت مثبت محور SHAP قرار دارند، درحالی‌که مقادیر پایین‌تر آن‌ها بیشتر سهم منفی ایجاد کرده‌اند. بااین‌حال، پراکندگی نقاط نشان می‌دهد اثر این ویژگی‌ها برای تمام نمونه‌ها یکسان نیست و برهم‌کنش آن‌ها با سایر ویژگی‌ها می‌تواند اندازه یا حتی جهت اثر را تغییر دهد.

در میان طبقات شغلی، حضور Prof-specialty و Exec-managerial عموماً اثر مثبت و حضور Other-service اثر منفی دارد. همچنین طبقات Bachelors و Masters بیشتر خروجی را به سمت درآمد بالا جابه‌جا می‌کنند، درحالی‌که حضور HS-grad اغلب با سهم منفی همراه است. این نتایج با رفتار PDP تحصیلات و رتبه ویژگی‌های education-num و occupation در Permutation Importance هم‌راستا هستند.

ویژگی حساس جنسیت نیز در نمودار SHAP ظاهر شده است. حضور sex_Male اغلب سهم مثبت و حضور sex_Female اغلب سهم منفی دارد، هرچند دامنه اثر آن‌ها از ویژگی‌های بالای نمودار کوچک‌تر است. این مشاهده با تفاوت نرخ خروجی مثبت و FNR میان زنان و مردان سازگار است، اما رابطه علّی یا تبعیض مستقیم را به‌تنهایی اثبات نمی‌کند؛ زیرا SHAP رفتار مدل را در حضور تمام هم‌بستگی‌های موجود در داده توضیح می‌دهد. ویژگی‌های مرتبط با نژاد نیز در میان ۲۰ ویژگی تبدیل‌شده نخست ظاهر نشده‌اند که با اهمیت نسبتاً کم race در Permutation Importance سازگار است.

۲-۴-۴- جمع‌بندی توضیح‌های سراسری

سه روش توضیح‌پذیری، تصویر نسبتاً سازگاری از رفتار جنگل تصادفی ارائه می‌کنند. ویژگی‌های capital-gain، وضعیت تأهل، رابطه خانوادگی، سن، تحصیلات، شغل و ساعات کار در بیش از یک روش به‌عنوان عوامل مؤثر شناسایی شده‌اند. PDP جهت متوسط اثر سه ویژگی عددی مهم را نشان داد و SHAP علاوه بر جهت اثر، ناهمگنی سهم ویژگی‌ها میان نمونه‌های مختلف را آشکار کرد.

اهمیت ویژگی‌هایی مانند سود سرمایه، تحصیلات، شغل و ساعات کار با روابط مشاهده‌شده در مجموعه‌داده Adult سازگار است؛ زیرا این متغیرها مستقیماً با وضعیت اقتصادی و شغلی افراد ارتباط دارند. بااین‌حال، این سازگاری نباید به‌عنوان اثبات رابطه علّی یا مطلوب‌بودن استفاده از تمام این ویژگی‌ها تعبیر شود. مدل الگوهای آماری موجود در مجموعه‌داده را بازتولید می‌کند و این الگوها ممکن است بخشی از نابرابری‌های تاریخی یا ساختاری را نیز منعکس کنند.

ویژگی‌های حساس sex و race در مقایسه با عوامل اصلی اهمیت مستقیم کمتری دارند، اما شکاف‌های عدالت پس از حذف آن‌ها از بین نرفتند. در کنار اهمیت زیاد marital-status، relationship، occupation و ویژگی‌های تحصیلی، این نتیجه احتمال انتقال غیرمستقیم اطلاعات گروه حساس از طریق Proxy Featureها را تقویت می‌کند. بااین‌حال، گزارش حاضر این ویژگی‌ها را صرفاً نامزدهای احتمالی Proxy در نظر می‌گیرد و از نسبت‌دادن نقش قطعی یا علّی به آن‌ها خودداری می‌کند.

۲-۵- توضیح‌پذیری محلی و امکان اقدام

در این بخش، تصمیم مدل جنگل تصادفی برای سه نمونه واقعی از مجموعه آزمون بررسی می‌شود: یک زن با خروجی مثبت، یک زن با خروجی منفی و یک مرد با خروجی منفی. برای هر نمونه، SHAP Waterfall Plot به‌منظور شناسایی عوامل مؤثر بر تصمیم تولید شده و سپس یک Counterfactual Explanation در فضای تغییرات محدود و سازگار جست‌وجو شده است. در پایان، عملی‌بودن، اخلاقی‌بودن و میزان کنترل فرد بر تغییر پیشنهادی ارزیابی می‌شود.

۲-۵-۱- روش انتخاب نمونه‌ها و تولید توضیح محلی

برای هر یک از سه حالت خواسته‌شده، ابتدا نمونه‌های واقعی مجموعه آزمون با جنسیت و خروجی پیش‌بینی‌شده مناسب انتخاب شدند. در صورت وجود، نمونه‌هایی در اولویت قرار گرفتند که پیش‌بینی مدل درباره آن‌ها صحیح بود. سپس از میان این نمونه‌ها، موردی انتخاب شد که احتمال پیش‌بینی‌شده آن کمترین فاصله را از آستانه تصمیم ۰.۵ داشت. انتخاب نمونه‌های نزدیک به مرز تصمیم باعث می‌شود تحلیل عوامل مؤثر بر تغییر خروجی و بررسی Recourse معنادارتر باشد.

مشخصات نمونه‌های انتخاب‌شده در جدول ۲-۱۸ ارائه شده‌اند. هر سه پیش‌بینی صحیح هستند و احتمال‌های خروجی آن‌ها در فاصله اندکی از آستانه قرار دارند.

جدول ۲-۱۸: مشخصات سه نمونه منتخب برای توضیح‌پذیری محلی

نمونه	گروه	شاخص آزمون	برچسب واقعی	خروجی مدل	احتمال طبقه مثبت	فاصله از آستانه
گروه اول با خروجی مثبت	زن	۸۸۹۱	۱	۱	۰.۵۰۷۸	۰.۰۰۷۸
گروه اول با خروجی منفی	زن	۴۸۷۶	۰	۰	۰.۴۹۹۵	۰.۰۰۰۵
گروه دوم با خروجی منفی	مرد	۹۶۳۱	۰	۰	۰.۴۹۹۷	۰.۰۰۰۳

برای توضیح محلی، مقادیر SHAP مربوط به طبقه درآمد بیشتر از ۵۰ هزار دلار محاسبه شدند. مقدار SHAP مثبت، احتمال طبقه مثبت را افزایش می‌دهد و مقدار منفی آن را کاهش می‌دهد. خاصیت جمع‌پذیری SHAP نیز برای هر سه نمونه بررسی شد:

$$\hat{p}(Y=1|x) = \phi_0 + \sum_{j=1}^{d} \phi_j\,, \quad \phi_0 = 0.239301$$

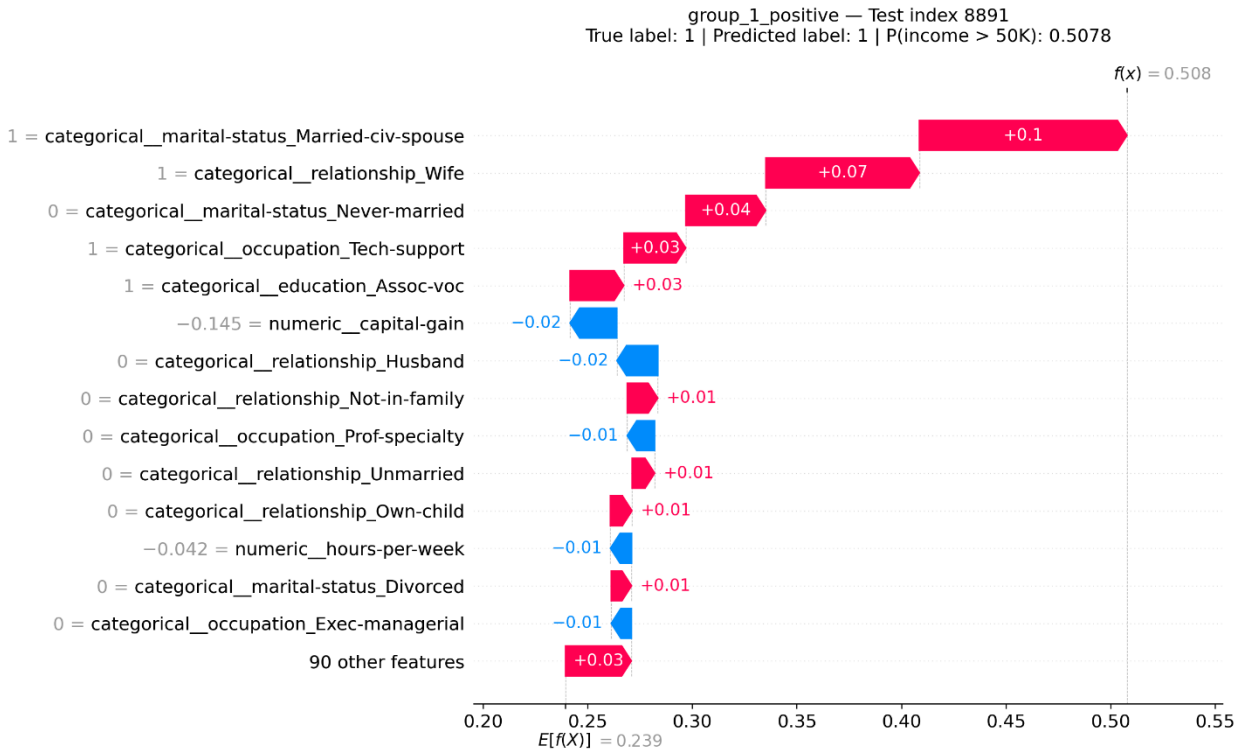
بیشترین اختلاف مطلق میان احتمال بازسازی‌شده از مقادیر SHAP و احتمال واقعی مدل برابر با 6.709×10^{-10} بنابراین توضیح‌های محلی از نظر خاصیت جمع‌پذیری با خروجی مدل سازگار هستند.

در تولید Counterfactual، تنها سطح تحصیلات، ساعات کار هفتگی و سود سرمایه قابل تغییر در نظر گرفته شدند. ویژگی‌های sex، race و age در تمام جست‌وجوها ثابت باقی ماندند. همچنین در صورت تغییر سطح تحصیلات، دو ویژگی education و education-num به‌صورت هم‌زمان تغییر کردند تا ترکیب ناسازگاری ایجاد نشود. از میان گزینه‌هایی که خروجی مدل را تغییر می‌دادند، نمونه دارای کمترین هزینه نرمال‌شده، کمترین تعداد تغییر و سپس کمترین فاصله از آستانه انتخاب شد.

۲-۵-۲- نمونه زن با خروجی مثبت

نمونه نخست مربوط به زنی ۳۳ ساله از گروه نژادی White است که دارای مدرک Assoc-voc، شغل Tech-support، وضعیت تأهل Married-civ-spouse و رابطه خانوادگی Wife است. این فرد ۴۰ ساعت در هفته کار می‌کند و مقادیر capital-gain و capital-loss او صفر هستند. برچسب واقعی و خروجی مدل هر دو مثبت بوده و احتمال پیش‌بینی‌شده برابر با ۰.۵۰۷۸ است.

مهم‌ترین عامل افزاینده خروجی، وضعیت تأهل با مقدار تجمیعی SHAP برابر با ۰.۱۵۰۱ است. پس از آن، ویژگی‌های رابطه خانوادگی با مقدار ۰.۰۹۱۱، شغل با مقدار ۰.۰۲۸۰ و تحصیلات طبقه‌ای با مقدار ۰.۰۲۶۳ قرار دارند. در مقابل، صفر بودن capital-gain با سهم ۰.۰۲۲۴- و ساعات کار هفتگی با سهم ۰.۰۱۰۲- احتمال خروجی مثبت را کاهش داده‌اند.



*شکل ۲–۱۶: **SHAP Waterfall Plot** برای نمونه زن با خروجی مثبت؛ مقادیر قرمز احتمال طبقه درآمد بالا را افزایش و مقادیر آبی آن را کاهش می‌دهند.*

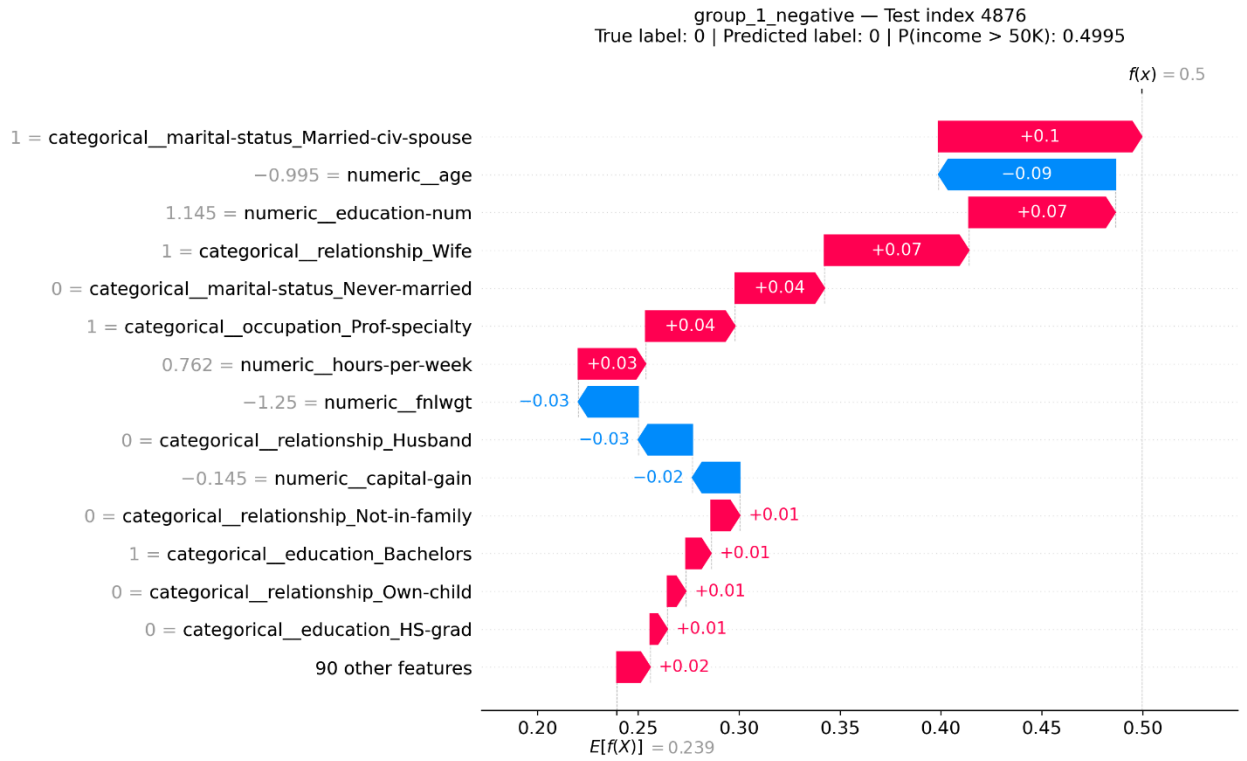
مجموع اثرهای مثبت اندکی از اثرهای منفی بیشتر بوده و احتمال را از مقدار پایه ۰.۲۳۹۳ به ۰.۵۰۷۸ رسانده است. با توجه به نزدیکی این مقدار به آستانه، تصمیم مدل پایدار نیست و یک تغییر محدود در ویژگی‌های مؤثر می‌تواند خروجی را عوض کند.

Counterfactual انتخاب‌شده سطح تحصیلات را از Assoc-voc با education-num=11 به Some-college با education-num=10 کاهش می‌دهد. با این تغییر، احتمال طبقه مثبت از ۰.۵۰۷۸ به ۰.۳۶۰۲ کاهش یافته و خروجی مدل منفی می‌شود. این تغییر فقط برای توضیح مرز تصمیم ارائه شده و Recourse محسوب نمی‌شود؛ زیرا توصیه به کاهش سطح تحصیلات نه عملی و نه اخلاقی است. بنابراین این نتیجه صرفاً نشان می‌دهد مدل تا چه اندازه نسبت به نمایش سطح تحصیلات این نمونه حساس است.

۲-۵-۳- نمونه زن با خروجی منفی

نمونه دوم مربوط به زنی ۲۵ ساله از گروه نژادی White است که دارای مدرک Bachelors، شغل Prof-specialty، وضعیت تأهل Married-civ-spouse و رابطه خانوادگی Wife است. این فرد ۵۰ ساعت در هفته کار می‌کند و مقادیر سود و زیان سرمایه او صفر هستند. برچسب واقعی و خروجی مدل هر دو منفی بوده و احتمال طبقه مثبت برابر با ۰.۴۹۹۵ است؛ بنابراین تنها ۰.۰۰۰۵ با آستانه تصمیم فاصله دارد.

وضعیت تأهل با سهم SHAP برابر با ۰.۱۵۳۵، رابطه خانوادگی با ۰.۰۷۵۴، education-num با ۰.۰۷۲۶، شغل با ۰.۰۴۴۹ و ساعات کار با ۰.۰۳۳۴ خروجی را به سمت طبقه مثبت سوق داده‌اند. مهم‌ترین عامل کاهنده، سن فرد با مقدار ۰.۰۸۷۶- است. fnlwgt و صفر بودن capital-gain نیز به‌ترتیب سهم‌های ۰.۰۲۹۷- و ۰.۰۲۳۵- داشته‌اند.



*شکل ۲–۱۷: **SHAP Waterfall Plot** برای نمونه زن با خروجی منفی و احتمال بسیار نزدیک به آستانه تصمیم.*

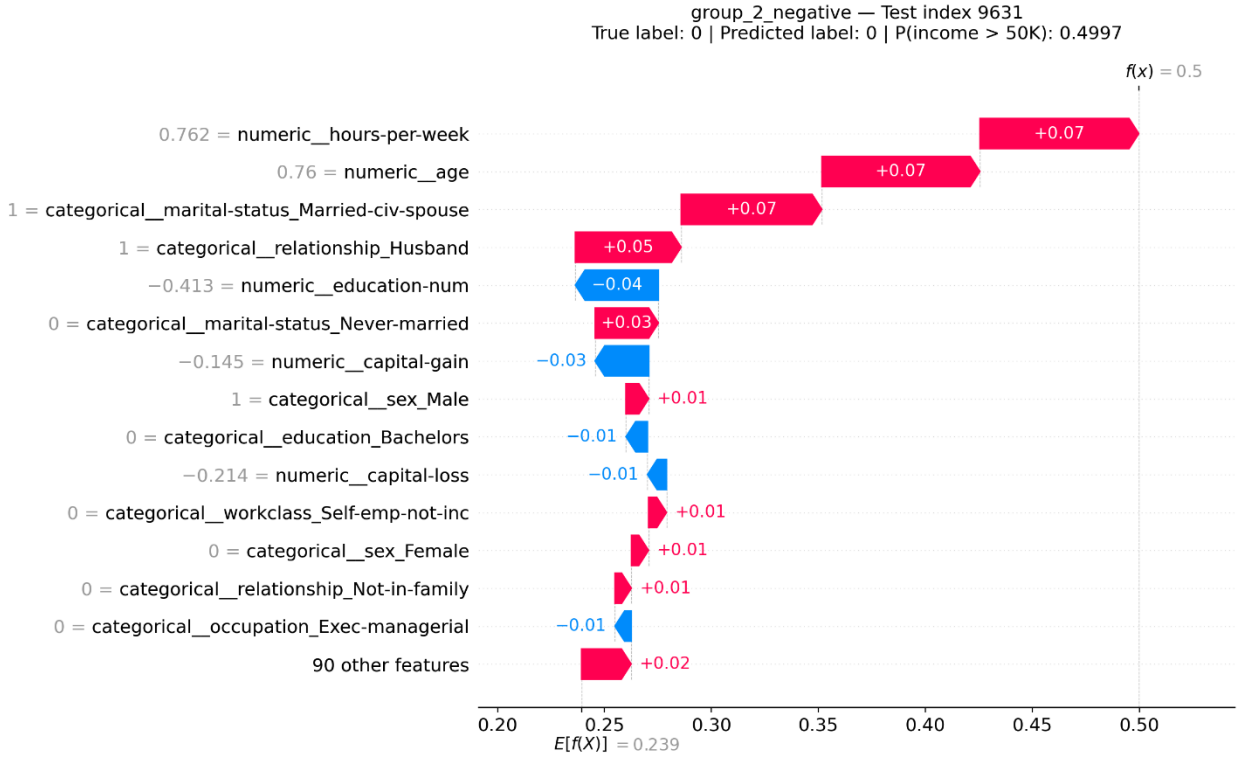
اگرچه چند ویژگی شغلی، تحصیلی و خانوادگی اثر مثبت قابل‌توجهی ایجاد کرده‌اند، اثر منفی سن و سایر ویژگی‌ها سبب شده است احتمال نهایی اندکی کمتر از ۰.۵ باقی بماند. این نمونه نشان می‌دهد تصمیم دودویی مدل می‌تواند حاصل اختلاف بسیار کوچکی میان مجموعه‌ای از اثرهای متضاد باشد.

Counterfactual انتخاب‌شده افزایش سطح تحصیلات از Bachelors با education-num=13 به Masters با education-num=14 است. با این تغییر، احتمال طبقه مثبت از ۰.۴۹۹۵ به ۰.۶۴۵۲ افزایش یافته و خروجی مدل مثبت می‌شود. هرچند این تغییر ویژگی‌های حساس یا سن را دست‌کاری نمی‌کند، اخذ مدرک کارشناسی ارشد به زمان، هزینه، دسترسی آموزشی و شرایط فردی وابسته است. ازاین‌رو، این پیشنهاد کاملاً تحت کنترل فوری فرد نیست و نباید به‌عنوان راهکار ساده یا تضمین‌شده برای تغییر نتیجه واقعی تلقی شود.

۲-۵-۴- نمونه مرد با خروجی منفی

نمونه سوم مربوط به مردی ۴۹ ساله از گروه نژادی White است که دارای مدرک HS-grad، شغل Transport-moving، وضعیت تأهل Married-civ-spouse و رابطه خانوادگی Husband است. این فرد ۵۰ ساعت در هفته کار می‌کند و مقادیر سود و زیان سرمایه او صفر هستند. برچسب واقعی و پیش‌بینی مدل هر دو منفی بوده و احتمال طبقه مثبت برابر با ۰.۴۹۹۷ است.

در این نمونه، وضعیت تأهل با سهم SHAP برابر با ۰.۱۰۱۶، ساعات کار هفتگی با ۰.۰۷۴۲، سن با ۰.۰۷۳۸ و رابطه خانوادگی با ۰.۰۶۴۱ از مهم‌ترین عوامل افزاینده خروجی هستند. ویژگی جنسیت نیز سهم مثبت ۰.۰۱۸۷ دارد، اما اثر آن از عوامل اصلی کمتر است. در مقابل، education-num با سهم ۰.۰۳۸۹-، صفر بودن capital-gain با ۰.۰۲۵۱- و نمایش طبقه‌ای تحصیلات با ۰.۰۱۶۹- احتمال طبقه مثبت را کاهش داده‌اند.



*شکل ۲–۱۸: **SHAP Waterfall Plot** برای نمونه مرد با خروجی منفی و نمایش اثر متضاد ویژگی‌های شغلی، خانوادگی و تحصیلی.*

با وجود اثر مثبت سن، وضعیت تأهل، رابطه خانوادگی و ساعات کار، سطح تحصیلات و نبود سود سرمایه باعث شده‌اند احتمال نهایی اندکی کمتر از آستانه باقی بماند. همانند نمونه دوم، تصمیم مدل درباره این فرد نیز به آستانه بسیار حساس است.

Counterfactual انتخاب‌شده افزایش ساعات کار هفتگی از ۵۰ به ۶۵ ساعت است. این تغییر احتمال طبقه مثبت را از ۰.۴۹۹۷ به ۰.۵۳۹۶ افزایش داده و خروجی را مثبت می‌کند. بااین‌حال، افزایش ۱۵ ساعت کار در هفته ممکن است به موافقت کارفرما، وجود فرصت اضافه‌کاری، وضعیت سلامت و مسئولیت‌های خانوادگی وابسته باشد. همچنین چنین افزایشی می‌تواند از نظر سلامت و تعادل کار و زندگی نامطلوب باشد؛ بنابراین این پیشنهاد کاملاً تحت کنترل فرد و لزوماً اخلاقی یا عملی نیست.

۲-۵-۵- ارزیابی عملی و اخلاقی Recourseها

خلاصه Counterfactualهای به‌دست‌آمده در جدول ۲-۱۹ ارائه شده است. در هر سه مورد تنها یک عمل تغییر کرده و ویژگی‌های sex، race و age ثابت باقی مانده‌اند. همچنین سازگاری میان education و education-num در هر دو تغییر تحصیلی حفظ شده است.

*جدول ۲–۱۹: خلاصه **Counterfactual Explanation** و ارزیابی امکان اقدام*

نمونه	احتمال اولیه	تغییر پیشنهادی	احتمال جدید	خروجی جدید	نوع توضیح	کاملاً تحت کنترل فرد
زن با خروجی مثبت	۰.۵۰۷۸	Assoc-voc → Some-college	۰.۳۶۰۲	منفی	توضیح تقابلی، نه Recourse	خیر
زن با خروجی منفی	۰.۴۹۹۵	Bachelors → Masters	۰.۶۴۵۲	مثبت	Recourse به خروجی مثبت	خیر
مرد با خروجی منفی	۰.۴۹۹۷	۵۰ → ۶۵ ساعت کار در هفته	۰.۵۳۹۶	مثبت	Recourse به خروجی مثبت	خیر

نتایج نشان می‌دهند معتبر بودن ریاضی یک Counterfactual به معنای عملی یا اخلاقی بودن آن نیست. افزایش سطح تحصیلات نیازمند منابع و فرصت‌های بلندمدت است و افزایش ساعات کار نیز ممکن است خارج از اختیار فرد یا برای سلامت او نامطلوب باشد. نمونه نخست نیز تنها یک توضیح تقابلی از مرز تصمیم است و کاهش تحصیلات نباید به‌عنوان توصیه مطرح شود.

علاوه بر این، Counterfactualهای حاضر رابطه علّی را اثبات نمی‌کنند. آن‌ها فقط نشان می‌دهند مدل در فضای ویژگی‌های تعریف‌شده، پس از اعمال چه تغییری خروجی متفاوتی تولید می‌کند. در دنیای واقعی، تغییر یک ویژگی ممکن است سایر ویژگی‌ها را نیز تغییر دهد یا به نتیجه‌ای متفاوت از پیش‌بینی مدل منجر شود. بنابراین Recourse قابل‌اعتماد باید علاوه بر اعتبار مدل، امکان اقدام، هزینه، زمان، محدودیت‌های اجتماعی و پیامدهای اخلاقی را نیز در نظر بگیرد.

۲-۶- کاهش سوگیری و تحلیل مبادله‌ها

در این بخش، اثر دو روش Reweighing و Sex-specific Threshold Adjustment بر مدل جنگل تصادفی بررسی می‌شود. ارزیابی تنها به کاهش یک شکاف عدالت محدود نیست و تغییرات عملکرد پیش‌بینی، عدالت جنسیتی و نژادی، کالیبراسیون و رفتار هر گروه به‌صورت هم‌زمان تحلیل می‌شوند. تمام نتایج نهایی روی مجموعه آزمون مستقل محاسبه شده‌اند و انتخاب آستانه‌های گروهی صرفاً با استفاده از مجموعه اعتبارسنجی انجام شده است.

۲-۶-۱- پروتکل ارزیابی روش‌های کاهش سوگیری

مدل جنگل تصادفی آموزش‌دیده با آستانه ثابت ۰.۵ به‌عنوان حالت پایه در نظر گرفته شد. سپس دو روش کاهش سوگیری اعمال شدند. در روش نخست، وزن نمونه‌های آموزشی بر اساس ترکیب جنسیت و برچسب واقعی تغییر کرد و مدل جدیدی آموزش داده شد. در روش دوم، مدل پایه بدون آموزش مجدد حفظ شد، اما آستانه تصمیم برای زنان و مردان به‌صورت جداگانه و فقط روی مجموعه اعتبارسنجی انتخاب شد.

سه حالت مورد مقایسه در جدول ۲-۲۰ خلاصه شده‌اند.

جدول ۲–۲۰: مشخصات روش‌های مورد استفاده برای کاهش سوگیری

روش	مرحله اعمال	مدل آموزش‌دیده	آستانه زنان	آستانه مردان
جنگل تصادفی پایه	بدون مداخله	مدل پایه	۰.۵۰	۰.۵۰
Reweighted Random Forest	حین آموزش	مدل جدید با وزن نمونه	۰.۵۰	۰.۵۰
Sex-specific Threshold Adjustment	پس از آموزش	همان مدل پایه	۰.۳۲	۰.۵۰

از آنجا که Reweighing فرایند آموزش را تغییر می‌دهد، می‌تواند علاوه بر تصمیم‌های دودویی، رتبه‌بندی نمونه‌ها، احتمال‌های خروجی و کالیبراسیون را نیز تغییر دهد. در مقابل، Threshold Adjustment تنها تبدیل احتمال به برچسب نهایی را تغییر می‌دهد؛ بنابراین ROC-AUC، Brier Score، ECE و منحنی‌های کالیبراسیون آن با مدل پایه یکسان باقی می‌مانند.

۲-۶-۲- روش Reweighing

هدف Reweighing کاهش وابستگی آماری میان ویژگی حساس S و برچسب واقعی Y در فرایند آموزش است. برای هر ترکیب جنسیت و برچسب، وزن نمونه‌ها مطابق رابطه زیر محاسبه شد:

$$w(s,y) = \frac{P(S=s)P(Y=y)}{P(S=s,Y=y)},$$

$$\mathcal{L}_{weighted} = \sum_{i=1}^{n} w(s_i,y_i)\ell\big(y_i, f(x_i)\big)$$

اگر یک ترکیب جنسیت و برچسب در داده کمتر از مقدار مورد انتظار تحت استقلال ظاهر شده باشد، وزن نمونه‌های آن افزایش می‌یابد؛ در مقابل، ترکیب‌های پرتکرارتر وزن کمتری دریافت می‌کنند. وزن‌های محاسبه‌شده در مجموعه آموزش بین ۰.۷۸۵۷ و ۲.۲۳۶۱ قرار داشتند و میانگین آن‌ها برابر با ۱ بود. بنابراین مقیاس کلی وزن‌ها حفظ شد، اما سهم نسبی چهار ترکیب جنسیت و برچسب تغییر کرد.

Reweighing نرخ خروجی مثبت زنان را از ۰.۰۷۴۸ به ۰.۱۰۹۲ و TPR آنان را از ۰.۵۲۰۴ به ۰.۶۴۳۱ افزایش داد. در نتیجه FNR زنان از ۰.۴۷۹۶ به ۰.۳۵۶۹ کاهش یافت. این بهبود با افزایش FPR زنان از ۰.۰۱۸۸ به ۰.۰۴۲۱ و کاهش Precision آنان از ۰.۷۷۶۴ به ۰.۶۵۷۴ همراه بود.

رفتار مدل برای مردان در جهت معکوس تغییر کرد. نرخ خروجی مثبت مردان از ۰.۲۴۸۸ به ۰.۲۱۵۶ و TPR آنان از ۰.۶۳۷۷ به ۰.۵۷۳۸ کاهش یافت؛ در نتیجه FNR از ۰.۳۶۲۳ به ۰.۴۲۶۲ افزایش پیدا کرد. Precision مردان نیز از ۰.۷۷۹۸ به ۰.۸۰۹۶ افزایش یافت. بنابراین کاهش شکاف جنسیتی صرفاً از طریق بهبود وضعیت زنان حاصل نشد و بخشی از آن نتیجه کاهش نرخ شناسایی نمونه‌های مثبت مردان بود.

این روش شکاف Demographic Parity جنسیتی را از ۰.۱۷۴۰ به ۰.۱۰۶۴ و Equalized Odds Difference را از ۰.۱۱۷۳ به ۰.۰۶۹۲ کاهش داد، اما Predictive Parity Difference را از ۰.۰۰۳۴ به ۰.۱۵۲۲ افزایش داد. به بیان دیگر، نرخ خروجی مثبت و توزیع خطاها میان دو جنس به یکدیگر نزدیک‌تر شدند، ولی قابلیت اعتماد خروجی مثبت مدل در دو گروه از یکدیگر فاصله گرفت.

۲-۶-۳- تنظیم آستانه به تفکیک جنسیت

در روش دوم، احتمال‌های مدل پایه ثابت باقی ماندند و تنها آستانه تصمیم برای هر گروه جنسیتی تغییر کرد. تصمیم نهایی برای نمونه i مطابق رابطه زیر تعریف شد:

$$\hat{y}_i = \mathbb{I}[p_i \geq t_{si}]$$

$$J(t_F, t_M) = \Delta_{EOdds} + 0.25\Delta_{DP} + 0.35L_{down} + 0.10\max(0, A_0 - A) + 0.10\max(0, R_0 - R)$$

در این رابطه، t_F و t_M آستانه‌های زنان و مردان، A_0 و R_0، Accuracy و Recall پایه و L_{down} جریمه کاهش TPR گروه‌ها هستند. جست‌وجو روی بازه ۰.۲۰ تا ۰.۸۰ با گام ۰.۰۲ انجام شد. تنها گزینه‌هایی پذیرفته شدند که Accuracy آن‌ها حداکثر ۰.۰۳، Recall کلی حداکثر ۰.۰۵ و TPR هر گروه حداکثر ۰.۰۵ کمتر از حالت پایه باشد.

بهترین زوج آستانه روی مجموعه اعتبارسنجی برابر با ۰.۳۲ برای زنان و ۰.۵۰ برای مردان انتخاب شد. حالت جست‌وجو strict_anti_leveling_down بود؛ بنابراین برای دستیابی به شکاف کمتر، کاهش شدید TPR یک گروه مجاز نبوده است.

کاهش آستانه زنان موجب شد نرخ خروجی مثبت این گروه در مجموعه آزمون از ۰.۰۷۴۸ به ۰.۱۲۰۴ و TPR از ۰.۵۲۰۴ به ۰.۶۷۸۵ افزایش یابد. در نتیجه FNR زنان به ۰.۳۲۱۵ کاهش یافت. هزینه این تغییر، افزایش FPR زنان از ۰.۰۱۸۸ به ۰.۰۵۰۳ و کاهش Precision از ۰.۷۷۶۴ به ۰.۶۲۸۸ بود. چون آستانه مردان تغییر نکرد، تمام معیارهای تصمیمی این گروه با حالت پایه برابر باقی ماندند.

در نتیجه، Equal Opportunity Difference و Equalized Odds Difference جنسیتی هر دو به ۰.۰۴۰۷ کاهش یافتند. بااین‌حال، Predictive Parity Difference به ۰.۱۵۱۰ افزایش پیدا کرد. بنابراین نزدیک‌شدن TPR و نرخ خطاها با کاهش برابری Precision میان زنان و مردان همراه بوده است.

۲-۶-۴- مقایسه عملکرد، عدالت و کالیبراسیون

عملکرد کلی سه روش روی مجموعه آزمون در جدول ۲-۲۱ ارائه شده است.

جدول ۲–۲۱: مقایسه عملکرد مدل پایه و روش‌های کاهش سوگیری روی مجموعه آزمون

روش	Accuracy	Precision	Recall	F1	ROC-AUC	Brier Score	زمان آموزش
جنگل تصادفی پایه	۰.۸۶۶۹	۰.۷۷۹۳	۰.۶۱۹۳	۰.۶۹۰۲	۰.۹۱۷۰	۰.۰۹۵۲	۱.۸۱ ثانیه
Reweighted Random Forest	۰.۸۶۰۸	۰.۷۷۸۵	۰.۵۸۴۷	۰.۶۶۷۸	۰.۹۱۳۷	۰.۰۹۷۳	۲.۰۱ ثانیه
Sex-specific Threshold Adjustment	۰.۸۶۳۴	۰.۷۵۰۰	۰.۶۴۴۱	۰.۶۹۳۱	۰.۹۱۷۰	۰.۰۹۵۲	بدون آموزش مجدد

Reweighing در مقایسه با مدل پایه Accuracy را ۰.۶۱ واحد درصد، Recall را ۳.۴۶ واحد درصد و F1 را ۲.۲۴ واحد درصد کاهش داده است. ROC-AUC نیز ۰.۰۰۳۳ کاهش و Brier Score حدود ۰.۰۰۲۰ افزایش یافته است. بنابراین بهبود برخی معیارهای عدالت جنسیتی با افت عملکرد و کاهش کیفیت کلی احتمال‌ها همراه بوده است.

Threshold Adjustment، Accuracy را ۰.۳۵ واحد درصد و Precision را ۲.۹۳ واحد درصد کاهش داد، اما Recall را ۲.۴۸ واحد درصد و F1 را ۰.۲۹ واحد درصد افزایش داد. ثابت‌ماندن ROC-AUC و Brier Score نتیجه مستقیم ثابت‌بودن احتمال‌های مدل است. عبارت «بدون آموزش مجدد» نیز به این معنا نیست که روش هیچ هزینه‌ای ندارد؛ جست‌وجوی آستانه و نگهداری ویژگی حساس در زمان تصمیم‌گیری همچنان هزینه محاسباتی و عملیاتی ایجاد می‌کند.

تغییر معیارهای جنسیتی در سطح گروه در جدول ۲-۲۲ ارائه شده است.

جدول ۲–۲۲: معیارهای گروهی جنسیت پیش و پس از کاهش سوگیری

روش	گروه	نرخ خروجی مثبت	TPR	FPR	FNR	Precision	Accuracy گروه
مدل پایه	زنان	۰.۰۷۴۸	۰.۵۲۰۴	۰.۰۱۸۸	۰.۴۷۹۶	۰.۷۷۶۴	۰.۹۲۹۸
مدل پایه	مردان	۰.۲۴۸۸	۰.۶۳۷۷	۰.۰۷۸۷	۰.۳۶۲۳	۰.۷۷۹۸	۰.۸۳۵۰
Reweighing	زنان	۰.۱۰۹۲	۰.۶۴۳۱	۰.۰۴۲۱	۰.۳۵۶۹	۰.۶۵۷۴	۰.۹۲۲۸
Reweighing	مردان	۰.۲۱۵۶	۰.۵۷۳۸	۰.۰۵۹۰	۰.۴۲۶۲	۰.۸۰۹۶	۰.۸۲۹۳
Threshold Adjustment	زنان	۰.۱۲۰۴	۰.۶۷۸۵	۰.۰۵۰۳	۰.۳۲۱۵	۰.۶۲۸۸	۰.۹۱۹۴
Threshold Adjustment	مردان	۰.۲۴۸۸	۰.۶۳۷۷	۰.۰۷۸۷	۰.۳۶۲۳	۰.۷۷۹۸	۰.۸۳۵۰

هر دو روش FNR زنان را کاهش داده‌اند، اما از سازوکار یکسانی استفاده نکرده‌اند. Reweighing هم‌زمان TPR زنان را افزایش و TPR مردان را کاهش داده است، درحالی‌که Threshold Adjustment تنها TPR زنان را افزایش داده و مقدار مردان را ثابت نگه داشته است. از منظر حفظ عملکرد گروهی، این تفاوت مهم است.

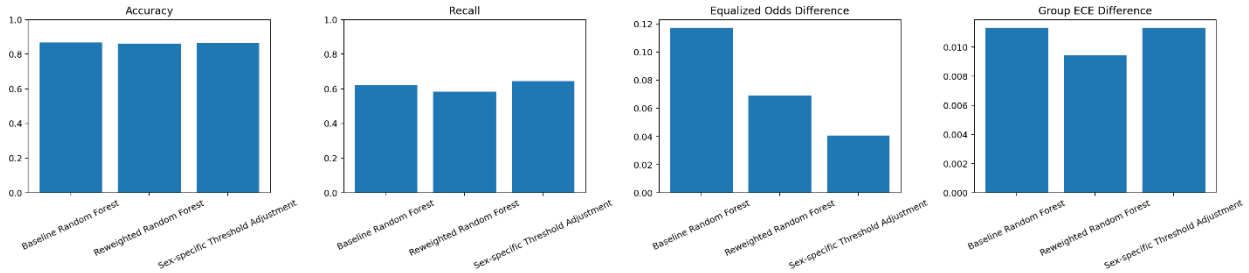
خلاصه شکاف‌های عدالت و کالیبراسیون جنسیتی و نژادی در جدول ۲-۲۳ گزارش شده است.

جدول ۲–۲۳: مقایسه شکاف‌های عدالت و کالیبراسیون پیش و پس از کاهش سوگیری

روش	گروه‌بندی	DP	Equal Opportunity	Equalized Odds	Predictive Parity	شکاف FPR	شکاف Calibration	شکاف ECE
مدل پایه	جنسیت	۰.۱۷۴۰	۰.۱۱۷۳	۰.۱۱۷۳	۰.۰۰۳۴	۰.۰۵۹۹	۰.۰۰۰۸	۰.۰۱۱۳
Reweighing	جنسیت	۰.۱۰۶۴	۰.۰۶۹۲	۰.۰۶۹۲	۰.۱۵۲۲	۰.۰۱۶۹	۰.۰۰۷۶	۰.۰۰۹۴
Threshold Adjustment	جنسیت	۰.۱۲۸۴	۰.۰۴۰۷	۰.۰۴۰۷	۰.۱۵۱۰	۰.۰۲۸۴	۰.۰۰۰۸	۰.۰۱۱۳
مدل پایه	نژاد	۰.۱۶۶۵	۰.۱۹۹۳	۰.۱۹۹۳	۰.۲۰۸۳	۰.۰۸۴۵	۰.۰۷۰۹	۰.۰۶۸۷
Reweighing	نژاد	۰.۱۶۳۲	۰.۳۰۳۰	۰.۳۰۳۰	۰.۱۴۱۸	۰.۰۹۴۰	۰.۰۶۷۲	۰.۰۵۹۶
Threshold Adjustment	نژاد	۰.۱۸۳۲	۰.۲۳۷۸	۰.۲۳۷۸	۰.۰۹۶۴	۰.۰۹۷۲	۰.۰۷۰۹	۰.۰۶۸۷

Reweighing شکاف‌های DP، Equal Opportunity، Equalized Odds و FPR جنسیتی را کاهش داده است، اما شکاف Predictive Parity و شکاف Calibration-in-the-Large را افزایش داده است. کاهش شکاف ECE نیز نباید به‌عنوان بهبود قطعی کالیبراسیون تفسیر شود؛ ECE زنان از ۰.۰۱۱۹ به ۰.۰۳۵۸ و ECE مردان از ۰.۰۲۳۲ به ۰.۰۲۶۴ افزایش یافته است، ولی به دلیل نزدیک‌ترشدن این دو مقدار، شکاف میان گروهی کاهش یافته است. Brier Score کلی نیز بدتر شده است؛ بنابراین کالیبراسیون مطلق مدل پس از Reweighing بهبود نیافته است.

Threshold Adjustment تمام معیارهای مبتنی بر احتمال و کالیبراسیون را بدون تغییر باقی گذاشته است، اما معیارهای تصمیمی را تغییر می‌دهد. این روش بهترین Equalized Odds Difference جنسیتی را به دست آورده است، ولی Predictive Parity را به‌طور محسوس بدتر کرده است.



*شکل ۲–۱۹: مقایسه **Accuracy**، **Recall**، **Equalized Odds Difference** جنسیتی و شکاف **ECE** میان مدل پایه، **Reweighing** و **Sex-specific Threshold Adjustment**.*

این شکل نشان می‌دهد هیچ روش واحدی در تمام محورها برتر نیست. مدل پایه بیشترین Accuracy را دارد، Reweighing شکاف DP جنسیتی کمتری ایجاد می‌کند و Threshold Adjustment کمترین Equalized Odds Difference و بیشترین Recall را به دست می‌آورد.

۲-۶-۵- تحلیل Trade-off و Leveling Down

نتایج نشان می‌دهند کاهش یک معیار عدالت می‌تواند با بدترشدن معیار دیگری همراه باشد. در Reweighing، Equalized Odds Difference جنسیتی از ۰.۱۱۷۳ به ۰.۰۶۹۲ کاهش یافت، اما F1، Recall، ROC-AUC و Brier Score بدتر شدند و شکاف Predictive Parity به ۰.۱۵۲۲ رسید. بنابراین این روش مدل را به‌صورت مطلق «بهتر» نکرده است، بلکه نقطه عملکرد آن را در فضای عملکرد، عدالت و کالیبراسیون جابه‌جا کرده است.

علاوه بر این، Reweighing برای کاهش شکاف جنسیتی، TPR زنان را ۰.۱۲۲۶ افزایش و TPR مردان را ۰.۰۶۳۹ کاهش داد. در نتیجه بخشی از بهبود عدالت از طریق کاهش عملکرد گروه مردان حاصل شده است. هرچند هر دو گروه هم‌زمان آسیب ندیده‌اند و الگوی سخت‌گیرانه Leveling Down رخ نداده است، این جابه‌جایی باید در تصمیم‌گیری نهایی صریحاً گزارش شود.

Threshold Adjustment، TPR زنان را ۰.۱۵۸۰ افزایش داد و TPR مردان را بدون تغییر حفظ کرد. نرخ خروجی مثبت زنان نیز ۰.۰۴۵۶ افزایش یافت، درحالی‌که مقدار مردان ثابت ماند. به همین دلیل، آزمون Leveling Down روی مجموعه آزمون مقدار False تولید کرد و الگوی بهبود ظاهری عدالت از طریق کاهش هم‌زمان فرصت هر دو گروه مشاهده نشد.

بااین‌حال، این روش نیز بدون هزینه نیست. Precision زنان از ۰.۷۷۶۴ به ۰.۶۲۸۸ کاهش یافته و FPR آنان افزایش یافته است. همچنین استفاده از آستانه متفاوت برای گروه‌های جنسیتی مستلزم دسترسی به ویژگی حساس در زمان تصمیم‌گیری است و ممکن است در برخی حوزه‌های کاربردی با محدودیت‌های حقوقی، اخلاقی یا سیاست‌گذاری مواجه باشد.

اثر روش‌ها بر عدالت نژادی نیز نشان می‌دهد بهینه‌سازی بر اساس یک ویژگی حساس می‌تواند پیامدهای ناخواسته‌ای برای ویژگی حساس دیگر داشته باشد. Reweighing، Equalized Odds Difference نژادی را از ۰.۱۹۹۳ به ۰.۳۰۳۰ و Threshold Adjustment آن را به ۰.۲۳۷۸ افزایش داد. در مقابل، هر دو روش Predictive Parity Difference نژادی را کاهش دادند. بنابراین هیچ‌یک از روش‌ها عدالت نژادی را در تمام معیارها بهبود نداده‌اند.

در مجموع، اگر کاهش FNR زنان و نزدیک‌کردن TPR دو گروه اولویت اصلی باشد، Threshold Adjustment در نتایج حاضر Trade-off مطلوب‌تری از Reweighing نشان می‌دهد؛ زیرا Equalized Odds Difference را بیشتر کاهش داده، Recall و F1 کلی را نیز اندکی افزایش داده و Leveling Down سخت‌گیرانه ایجاد نکرده است. بااین‌حال، این نتیجه به معنای انتخاب بدون قید این روش نیست. کاهش Precision زنان، افزایش FPR، بدترشدن برخی معیارهای نژادی و ملاحظات استفاده از جنسیت در زمان تصمیم‌گیری باید پیش از کاربرد عملی بررسی شوند. بنابراین انتخاب نهایی روش کاهش سوگیری به هزینه واقعی FP و FN، معیار عدالت اولویت‌دار، الزامات قانونی و گروه‌های ذی‌نفع وابسته است.

۲-۷- نکات پیاده‌سازی و ملاحظات عملی

در این بخش، توابع منتخب پیاده‌سازی از نظر ساختار ورودی و خروجی، مراحل اصلی پردازش و کنترل‌هایی که برای جلوگیری از خطاهای روش‌شناختی در آن‌ها در نظر گرفته شده است بررسی می‌شوند. این توابع بخش‌های اصلی جریان آزمایش، شامل پیش‌پردازش یکنواخت مدل‌ها، تولید Counterfactual سازگار و اعمال دو روش کاهش سوگیری را پوشش می‌دهند.

۲-۷-۱- ساخت پیش‌پردازش و Pipeline مدل‌ها

تابع build_preprocessor یک DataFrame شامل ویژگی‌های خام را دریافت می‌کند و ستون‌ها را بر اساس نوع داده تفکیک می‌کند. ستون‌هایی که نوع عددی دارند با (["number"]=select_dtypes(include انتخاب می‌شوند و سایر ستون‌ها در گروه ویژگی‌های طبقه‌ای قرار می‌گیرند. سپس برای هر گروه یک Pipeline مستقل ساخته می‌شود.

در Pipeline عددی، SimpleImputer با راهبرد median مقادیر گمشده را جای‌گذاری می‌کند و خروجی آن به StandardScaler داده می‌شود. استانداردسازی به‌طور ویژه برای رگرسیون لجستیک اهمیت دارد؛ زیرا مانع آن می‌شود که اختلاف مقیاس ویژگی‌هایی مانند age، fnlwgt و capital-gain بر فرایند بهینه‌سازی و اندازه ضرایب اثر نامتناسب بگذارد.

در Pipeline طبقه‌ای، مقادیر گمشده با پرتکرارترین مقدار هر ستون جایگزین می‌شوند و سپس One-Hot Encoding اعمال می‌شود. کدگذار با handle_unknown="ignore" ساخته شده است؛ بنابراین اگر در داده اعتبارسنجی یا آزمون طبقه‌ای مشاهده شود که در مجموعه آموزش وجود نداشته است، تبدیل داده متوقف نمی‌شود و برای آن طبقه بردار صفر تولید می‌شود. دو Pipeline در نهایت توسط ColumnTransformer روی ستون‌های متناظر اعمال می‌شوند. تابع علاوه بر مبدل نهایی، فهرست ستون‌های عددی و طبقه‌ای را نیز برمی‌گرداند.

```python
def build_preprocessor(feature_frame: pd.DataFrame):
    numeric_columns = feature_frame.select_dtypes(include=["number"]).columns.tolist()
    categorical_columns = [column for column in feature_frame.columns if column not in numeric_columns]

    numeric_pipeline = Pipeline([("imputer", SimpleImputer(strategy="median")), ("scaler", StandardScaler())])
    categorical_pipeline = Pipeline([("imputer", SimpleImputer(strategy="most_frequent")), ("onehot", make_one_hot_encoder())])

    preprocessor = ColumnTransformer([("numeric", numeric_pipeline, numeric_columns), ("categorical", categorical_pipeline, categorical_columns)])
    return preprocessor, numeric_columns, categorical_columns
```

*شکل ۲–۲۰: پیاده‌سازی تفکیک خودکار ویژگی‌ها و ساخت **Pipeline**های عددی و طبقه‌ای در تابع پیش‌پردازش.*

نکته اصلی این پیاده‌سازی آن است که عملیات Imputation، Scaling و Encoding بخشی از شیء آموزش‌پذیر مدل هستند. در نتیجه، آمار لازم برای جای‌گذاری و استانداردسازی فقط هنگام فراخوانی fit و از داده آموزش محاسبه می‌شوند. همچنین تشخیص نوع ستون‌ها درون تابع، احتمال ناسازگاری میان فهرست ویژگی‌ها و تبدیل‌های اعمال‌شده را کاهش می‌دهد.

تابع build_model_pipeline ابتدا با فراخوانی build_preprocessor یک پیش‌پردازش جدید ایجاد می‌کند و سپس بر اساس مقدار model_name تخمین‌گر مناسب را می‌سازد. برای رگرسیون لجستیک از حل‌گر lbfgs و max_iter=2000 استفاده شده است تا با توجه به تعداد ویژگی‌های حاصل از One-Hot Encoding، فرصت کافی برای همگرایی مدل وجود داشته باشد.

در حالت جنگل تصادفی، تعداد درخت‌ها از CONFIG["rf_estimators"] خوانده می‌شود که در اجرای کامل برابر با ۳۰۰ است. پارامتر min_samples_leaf=2 از تشکیل برگ‌های تک‌نمونه‌ای جلوگیری می‌کند، max_features="sqrt" در هر انشعاب تنها زیرمجموعه‌ای از ویژگی‌ها را در اختیار درخت قرار می‌دهد و n_jobs=-1 آموزش درخت‌ها را روی هسته‌های پردازنده موازی می‌کند. برای هر دو مدل نیز random_state=SEED در نظر گرفته شده است.

در انتها، پیش‌پردازش و تخمین‌گر در یک Pipeline با دو مرحله نام‌گذاری‌شده preprocessor و model قرار می‌گیرند. اگر نام مدل خارج از دو مقدار پشتیبانی‌شده باشد، تابع به‌جای انتخاب ضمنی یک مدل، خطای ValueError ایجاد می‌کند.

```python
def build_model_pipeline(feature_frame: pd.DataFrame, model_name: str) -> Pipeline:
    preprocessor, _, _ = build_preprocessor(feature_frame)

    if model_name == "Logistic Regression":
        estimator = LogisticRegression(max_iter=2000, solver="lbfgs", random_state=SEED)
    elif model_name == "Random Forest":
        estimator = RandomForestClassifier(n_estimators=CONFIG["rf_estimators"], min_samples_leaf=2, max_features="sqrt", n_jobs=-1, random_state=SEED)
    else:
        raise ValueError(f"Unsupported model: {model_name}")

    return Pipeline([("preprocessor", preprocessor), ("model", estimator)])
```

*شکل ۲–۲۱: پیاده‌سازی ساخت **Pipeline** یکپارچه برای رگرسیون لجستیک و جنگل تصادفی.*

استفاده از این تابع باعث می‌شود دو مدل دقیقاً با یک منطق پیش‌پردازش آموزش ببینند و تفاوت نتایج به انتخاب مدل مربوط باشد، نه به تفاوت در آماده‌سازی داده. همچنین در زمان پیش‌بینی، داده خام مستقیماً به Pipeline داده می‌شود و احتمال فراموش‌شدن یا جابه‌جایی یکی از مراحل تبدیل کاهش می‌یابد.

۲-۷-۲- حفظ سازگاری و تولید Counterfactual

در مجموعه‌داده Adult، education و education-num دو متغیر مستقل از نظر معنایی نیستند؛ بلکه یک سطح تحصیلات را به شکل طبقه‌ای و ترتیبی نمایش می‌دهند. تابع synchronized_education برای اعمال یک تغییر مشترک روی این دو ستون تعریف شده است. تابع مقدار پیشنهادی education-num را دریافت می‌کند، وجود آن را در نگاشت EDUCATION_NUM_TO_LABEL بررسی کرده و سپس مقدار عددی و برچسب طبقه‌ای متناظر را در نمونه جایگزین می‌کند.

```python
def synchronized_education(candidate: pd.Series, education_number: int) -> pd.Series:
    education_number = int(education_number)
    if education_number not in EDUCATION_NUM_TO_LABEL:
        raise ValueError(f"Invalid education-num: {education_number}")
    candidate["education-num"] = education_number
    candidate["education"] = EDUCATION_NUM_TO_LABEL[education_number]
    return candidate
```

*شکل ۲–۲۲: پیاده‌سازی تغییر هماهنگ **education** و **education-num** بر اساس نگاشت سطوح تحصیلات.*

این تابع به این دلیل به‌صورت مجزا در گزارش آورده شده است که یک قید سازگاری دامنه را پیاده‌سازی می‌کند. بدون این کنترل، جست‌وجوی Counterfactual می‌توانست نمونه‌هایی مانند education=HS-grad و education-num=14 تولید کند. چنین نمونه‌ای ممکن است از نظر ساختار DataFrame معتبر و برای مدل قابل‌پیش‌بینی باشد، اما در دامنه واقعی داده معنای معتبری ندارد. بنابراین همگام‌سازی این دو ستون مانع انتخاب Counterfactualهایی می‌شود که تغییر تصمیم آن‌ها ناشی از یک ترکیب مصنوعی و ناسازگار است.

تابع generate_counterfactual یک ردیف واقعی، Pipeline آموزش‌دیده و آستانه تصمیم را دریافت می‌کند. ابتدا احتمال اولیه توسط predict_proba محاسبه و برچسب دودویی بر اساس آستانه تعیین می‌شود. اگر خروجی اولیه منفی باشد، جست‌وجو به دنبال نمونه‌ای با احتمال حداقل آستانه انجام می‌شود؛ در مقابل، برای خروجی مثبت، هدف یافتن یک نمونه با احتمال کمتر از آستانه و تولید توضیح تقابلی است.

فضای جست‌وجو توسط تابع کمکی candidate_values برای سه عمل قابل تغییر ساخته می‌شود: سطح تحصیلات، ساعات کار هفتگی و capital-gain. سپس حاصل‌ضرب دکارتی مقادیر مجاز این سه ویژگی با itertools.product تولید می‌شود. برای هر ترکیب، یک نسخه از نمونه اصلی ساخته شده، تحصیلات با synchronized_education تغییر می‌کند و مقادیر ساعات کار و سود سرمایه نیز جایگزین می‌شوند. این ساختار سبب می‌شود تمام ترکیب‌های تعریف‌شده در فضای محدود جست‌وجو به‌صورت نظام‌مند ارزیابی شوند.

```python
def generate_counterfactual(row: pd.Series, model: Pipeline, threshold: float = 0.5) -> dict[str, Any]:
    original_frame = row.to_frame().T
    original_probability = float(model.predict_proba(original_frame)[0, 1])
    original_prediction = int(original_probability >= threshold)
    target_positive = original_prediction == 0
    grids = candidate_values(row, target_positive)

    candidates = []
    for education_number, hours, capital_gain in itertools.product(grids["education-num"], grids["hours-per-week"], grids["capital-gain"]):
        candidate = row.copy()
        candidate = synchronized_education(candidate, education_number)
        candidate["hours-per-week"] = int(hours)
        candidate["capital-gain"] = int(capital_gain)
        candidates.append(candidate)

    frame = pd.DataFrame(candidates)
    probabilities = model.predict_proba(frame)[:, 1]
    valid_mask = probabilities >= threshold if target_positive else probabilities < threshold
    counterfactual_type = "recourse_to_positive" if target_positive else "contrastive_to_negative"

    if not np.any(valid_mask):
        return {
            "found": False,
            "counterfactual_type": counterfactual_type,
            "original_probability": original_probability,
            "original_prediction": original_prediction,
            "candidate_count": int(len(frame)),
            "reason": "No valid counterfactual was found in the restricted and internally consistent search space.",
        }

    valid_indices = np.where(valid_mask)[0]
    scored_candidates = []
    for candidate_index in valid_indices:
        candidate = frame.iloc[candidate_index]
        changes = changed_actions(row, candidate)
        scored_candidates.append((counterfactual_cost(row, candidate), len(changes), abs(float(probabilities[candidate_index]) - threshold), int(candidate_index)))

    _, _, _, best_index = min(scored_candidates)
    best = frame.iloc[best_index]
    changes = changed_actions(row, best)

    immutable_unchanged = all(str(row[feature]) == str(best[feature]) for feature in IMMUTABLE_FEATURES)
    consistency_passed = education_is_consistent(best)
    assessment = assess_counterfactual(row, best, counterfactual_type, changes)

    return {
        "found": True,
        "counterfactual_type": counterfactual_type,
        "original_probability": original_probability,
        "original_prediction": original_prediction,
        "counterfactual_probability": float(probabilities[best_index]),
        "counterfactual_prediction": int(probabilities[best_index] >= threshold),
        "normalized_cost": float(counterfactual_cost(row, best)),
        "number_of_changed_actions": int(len(changes)),
        "candidate_count": int(len(frame)),
        "changes": json.dumps(changes, ensure_ascii=False),
        "immutable_features_unchanged": bool(immutable_unchanged),
        "education_consistency_passed": bool(consistency_passed),
        **assessment,
    }
```

*شکل ۲–۲۳: پیاده‌سازی تولید، ارزیابی و رتبه‌بندی گزینه‌های **Counterfactual** در فضای جست‌وجوی محدود.*

پس از تشکیل DataFrame گزینه‌ها، احتمال تمام نمونه‌ها در یک فراخوانی برداری predict_proba محاسبه می‌شود. سپس با استفاده از یک ماسک منطقی فقط گزینه‌هایی نگه داشته می‌شوند که واقعاً از آستانه عبور کرده و تصمیم مدل را تغییر داده

باشند. اگر هیچ گزینه معتبری وجود نداشته باشد، تابع وضعیت found=False، تعداد گزینه‌های بررسی‌شده و دلیل شکست را برمی‌گرداند و یک نتیجه ساختگی تولید نمی‌کند.

گزینه‌های معتبر با یک Tuple چهارعضوی رتبه‌بندی می‌شوند: هزینه نرمال‌شده تغییرات، تعداد اعمال تغییریافته، فاصله احتمال جدید از آستانه و شاخص گزینه. استفاده از ترتیب لغوی Tuple در تابع min باعث می‌شود ابتدا کم‌هزینه‌ترین گزینه انتخاب شود؛ در صورت برابری هزینه، گزینه دارای تعداد تغییر کمتر و سپس گزینه نزدیک‌تر به مرز تصمیم ترجیح داده می‌شود.

در خروجی نهایی، علاوه بر احتمال و تصمیم جدید، تغییرات اعمال‌شده، هزینه، تعداد اعمال و تعداد کل گزینه‌های بررسی‌شده ثبت می‌شوند. سپس ثابت‌ماندن sex، race و age و سازگاری دو ستون تحصیلات به‌صورت مستقل کنترل می‌شود. این کنترل‌ها اعتبار ساختاری Counterfactual را بررسی می‌کنند، هرچند عملی یا اخلاقی بودن پیشنهاد همچنان نیازمند تحلیل جداگانه است.

۲-۷-۳- محاسبه وزن‌های Reweighing

تابع compute_reweighing_weights ویژگی حساس و برچسب‌های مجموعه آموزش را دریافت و هر دو را به آرایه‌های یک‌بعدی تبدیل می‌کند. سپس سه توزیع تجربی از داده آموزش محاسبه می‌شوند: احتمال هر گروه حساس $P(S = s)$، احتمال هر برچسب $P(Y = y)$ و احتمال مشترک هر ترکیب گروه و برچسب $P(S = s, Y = y)$.

وزن اختصاص‌یافته به هر نمونه از رابطه زیر به دست می‌آید:

$$w(s, y) = \frac{P(S = s)P(Y = y)}{P(S = s, Y = y)}$$

اگر جنسیت و برچسب مستقل باشند، صورت و مخرج این رابطه برابر شده و وزن آن ترکیب به یک نزدیک می‌شود. اگر یک ترکیب کمتر از مقدار مورد انتظار تحت استقلال مشاهده شده باشد، مخرج کوچک‌تر و وزن آن بیشتر از یک خواهد شد؛ ترکیب‌های بیش‌نمایش‌یافته نیز وزن کمتر از یک دریافت می‌کنند.

```python
def compute_reweighing_weights(sensitive_values: pd.Series, labels: pd.Series) -> np.ndarray:
    sensitive_array = sensitive_values.astype(str).to_numpy()
    label_array = labels.astype(int).to_numpy()

    p_sensitive = {group: float(np.mean(sensitive_array == group)) for group in pd.unique(sensitive_array)}
    p_label = {label: float(np.mean(label_array == label)) for label in pd.unique(label_array)}
    p_joint = {(group, label): float(np.mean((sensitive_array == group) & (label_array == label))) for group in pd.unique(sensitive_array) for label in pd.unique(label_array)}

    zero_cells = [key for key, probability in p_joint.items() if probability == 0]
    if zero_cells:
        raise ValueError(f"Reweighing is undefined for empty sensitive-label cells: {zero_cells}")

    return np.array([p_sensitive[group] * p_label[label] / p_joint[(group, label)] for group, label in zip(sensitive_array, label_array)])
```

شکل ۲–۲۴: پیاده‌سازی برآورد توزیع‌های حاشیه‌ای و مشترک و محاسبه وزن هر نمونه در روش ***Reweighing***

پیش از محاسبه وزن‌ها، تابع تمام سلول‌های حاصل از ترکیب مقادیر حساس و برچسب را بررسی می‌کند. اگر احتمال مشترک یک سلول صفر باشد، تقسیم در رابطه وزن تعریف‌پذیر نیست؛ در این حالت تابع با ValueError متوقف می‌شود. خروجی نهایی آرایه‌ای هم‌اندازه مجموعه آموزش است که هنگام برازش Pipeline از طریق پارامتر وزن نمونه مرحله مدل به جنگل تصادفی منتقل می‌شود.

این روش توزیع داده را با حذف یا تکثیر فیزیکی نمونه‌ها تغییر نمی‌دهد، بلکه سهم هر مشاهده را در تابع هدف آموزش اصلاح می‌کند. در اجرای انجام‌شده، وزن‌ها در بازه ۰.۷۸۵۷ تا ۲.۲۳۶۱ قرار داشتند و میانگین آن‌ها تقریباً برابر با یک بود.

۲-۷-۴- اعمال و انتخاب آستانه‌های گروهی

تابع apply_group_thresholds آرایه احتمال‌های طبقه مثبت، مقادیر ویژگی حساس و یک دیکشنری از آستانه‌ها را دریافت می‌کند. احتمال‌ها به آرایه عددی و نام گروه‌ها به رشته تبدیل می‌شوند تا مقایسه‌ها مستقل از نوع اولیه Series یا آرایه باشند. سپس برای هر زوج احتمال و گروه، آستانه متناظر از دیکشنری خوانده می‌شود.

دیکشنری آستانه‌ها می‌تواند کلید ویژه __default__ داشته باشد. اگر برای یک گروه آستانه مستقلی تعریف نشده باشد، مقدار این کلید و در نبود آن مقدار ۰.۵ استفاده می‌شود. خروجی تابع یک آرایه دودویی است که در آن شرط تصمیم برای هر نمونه به‌صورت $p_i \geq t_{s_i}$ ارزیابی شده است.

```python
def apply_group_thresholds(probabilities: np.ndarray, sensitive_values: pd.Series | np.ndarray, thresholds: dict[str, float]) -> np.ndarray:
    probability_array = np.asarray(probabilities).astype(float)
    sensitive_array = np.asarray(sensitive_values).astype(str)
    default_threshold = thresholds.get("__default__", 0.5)
    return np.array([int(probability >= thresholds.get(group, default_threshold)) for probability, group in zip(probability_array, sensitive_array)])
```

شکل ۲–۲۵: پیاده‌سازی تبدیل احتمال‌ها به برچسب با آستانه اختصاصی گروه و آستانه پیش‌فرض.

تفکیک این منطق از تابع جست‌وجو باعث می‌شود همان قاعده آستانه‌گذاری هم در مرحله اعتبارسنجی و هم در ارزیابی نهایی استفاده شود. این تابع احتمال‌های مدل را بازتنظیم نمی‌کند؛ بنابراین ROC-AUC، Brier Score و معیارهای Calibration ثابت می‌مانند، اما ماتریس درهم‌ریختگی و معیارهایی مانند TPR، FPR و Precision تغییر می‌کنند.

تابع search_binary_group_thresholds آستانه دو گروه را تنها با استفاده از داده اعتبارسنجی انتخاب می‌کند. ابتدا بررسی می‌شود که ویژگی حساس دقیقاً دو مقدار متمایز داشته باشد. سپس پیش‌بینی‌های پایه با آستانه عمومی ۰.۵ تولید و Accuracy، Recall کلی و جدول معیارهای هر گروه به‌عنوان خط مبنا ذخیره می‌شوند.

شبکه جست‌وجو شامل مقادیر ۰.۲۰ تا ۰.۸۰ با گام ۰.۰۲ است؛ بنابراین ۳۱ مقدار برای هر گروه و در مجموع ۹۶۱ زوج آستانه بررسی می‌شود. برای هر زوج، تصمیم‌ها با apply_group_thresholds تولید و ابتدا قیود عملکرد کلی اعمال می‌شوند. گزینه‌ای که Accuracy آن بیش از ۰.۰۳ یا Recall آن بیش از ۰.۰۵ نسبت به خط مبنا افت کرده باشد، از ادامه ارزیابی حذف می‌شود. این مقادیر از تنظیمات اجرای کامل نوت‌بوک دریافت شده‌اند.

```python
def search_binary_group_thresholds(y_true: pd.Series, probabilities: np.ndarray, sensitive_values: pd.Series, accuracy_tolerance: float = 0.03, recall_tolerance: float = 0.05, group_tpr_tolerance: float = 0.05):
    """Select thresholds on validation data with explicit anti-leveling-down constraints."""
    groups = sorted(sensitive_values.astype(str).unique())
    if len(groups) != 2:
        raise ValueError("This threshold search expects exactly two groups.")

    baseline_predictions = (np.asarray(probabilities) >= 0.5).astype(int)
    baseline_accuracy = accuracy_score(y_true, baseline_predictions)
    baseline_recall = recall_score(y_true, baseline_predictions, zero_division=0)
    baseline_group_table = group_metric_table(y_true, probabilities, sensitive_values, predictions=baseline_predictions).set_index("group")

    grid = np.round(np.arange(0.20, 0.81, 0.02), 2)

    def enumerate_candidates(enforce_group_tpr_constraint: bool) -> pd.DataFrame:
        records = []
        for threshold_0, threshold_1 in itertools.product(grid, grid):
            thresholds = {groups[0]: float(threshold_0), groups[1]: float(threshold_1), "__default__": 0.5}
            predictions = apply_group_thresholds(probabilities, sensitive_values, thresholds)
            accuracy = accuracy_score(y_true, predictions)
            recall = recall_score(y_true, predictions, zero_division=0)

            if accuracy < baseline_accuracy - accuracy_tolerance:
                continue
            if recall < baseline_recall - recall_tolerance:
                continue

            table = group_metric_table(y_true, probabilities, sensitive_values, predictions=predictions).set_index("group")

            group_tpr_drops = {group: float(baseline_group_table.loc[group, "tpr_recall"] - table.loc[group, "tpr_recall"]) for group in groups}
            if enforce_group_tpr_constraint and any(drop > group_tpr_tolerance for drop in group_tpr_drops.values()):
                continue

            table_reset = table.reset_index()
            gaps = fairness_gap_summary(table_reset)
            positive_rate_drops = {group: float(baseline_group_table.loc[group, "positive_prediction_rate"] - table.loc[group, "positive_prediction_rate"]) for group in groups}
            leveling_down_penalty = sum(max(0.0, drop) for drop in group_tpr_drops.values())

            objective = gaps["equalized_odds_difference"] + 0.25 * gaps["demographic_parity_difference"] + 0.35 * leveling_down_penalty + 0.10 * max(0.0, baseline_accuracy - accuracy) + 0.10 * max(0.0, baseline_recall - recall)

            records.append({
                f"threshold_{groups[0]}": threshold_0,
                f"threshold_{groups[1]}": threshold_1,
                "accuracy": accuracy,
                "recall": recall,
                "objective": objective,
                "leveling_down_penalty": leveling_down_penalty,
                f"tpr_drop_{groups[0]}": group_tpr_drops[groups[0]],
                f"tpr_drop_{groups[1]}": group_tpr_drops[groups[1]],
                f"positive_rate_drop_{groups[0]}": positive_rate_drops[groups[0]],
                f"positive_rate_drop_{groups[1]}": positive_rate_drops[groups[1]],
                **gaps,
            })

        return pd.DataFrame(records)

    search_mode = "strict_anti_leveling_down"
    table = enumerate_candidates(enforce_group_tpr_constraint=True)

    if table.empty:
        warnings.warn("No threshold pair satisfied the strict per-group TPR constraint. Using the relaxed search and flagging the result for explicit discussion.")
        search_mode = "relaxed_fallback"
        table = enumerate_candidates(enforce_group_tpr_constraint=False)

    if table.empty:
        raise RuntimeError("No threshold pair satisfied the performance constraints.")

    table = table.sort_values(["objective", "equalized_odds_difference", "accuracy", "recall"], ascending=[True, True, False, False])
    best = table.iloc[0]
    thresholds = {groups[0]: float(best[f"threshold_{groups[0]}"]), groups[1]: float(best[f"threshold_{groups[1]}"]), "__default__": 0.5}

    search_metadata = {
        "search_mode": search_mode,
        "baseline_accuracy": float(baseline_accuracy),
        "baseline_recall": float(baseline_recall),
        "accuracy_tolerance": float(accuracy_tolerance),
        "recall_tolerance": float(recall_tolerance),
        "group_tpr_tolerance": float(group_tpr_tolerance),
    }
    return thresholds, table, search_metadata
```

شکل ۲–۲۶: پیاده‌سازی جست‌وجوی شبکه‌ای آستانه‌های گروهی همراه با قیود عملکرد و ***Anti-leveling-down***

برای گزینه‌های باقی‌مانده، TPR هر گروه با مقدار پایه همان گروه مقایسه می‌شود. در حالت strict_anti_leveling_down، افت TPR هیچ گروهی نباید بیشتر از ۰.۰۵ باشد. این قید مانع آن می‌شود که شکاف TPR صرفاً از طریق کاهش شدید عملکرد گروهی که وضعیت بهتری داشته است کوچک شود.

تابع برای هر زوج معتبر، معیارهای عدالت، افت TPR گروه‌ها، کاهش نرخ خروجی مثبت، جریمه Leveling Down، Accuracy و Recall را ثبت می‌کند. سپس یک تابع هدف ترکیبی با اولویت Equalized Odds Difference و در نظر گرفتن Demographic Parity Difference، جریمه Leveling Down و افت عملکرد محاسبه می‌شود. گزینه‌ها ابتدا بر اساس کمترین مقدار تابع هدف و Equalized Odds Difference و سپس با ترجیح Accuracy و Recall بیشتر مرتب می‌شوند.

اگر هیچ زوجی قید سخت‌گیرانه TPR گروه‌ها را تأمین نکند، تابع هشدار تولید کرده و جست‌وجو را در حالت relaxed_fallback بدون قید افت TPR گروهی تکرار می‌کند. اگر حتی در این حالت نیز هیچ گزینه‌ای قیود Accuracy و Recall را رعایت نکند، خطای RuntimeError ایجاد می‌شود. این رفتار باعث می‌شود کنارگذاشتن قید Anti-leveling-down به‌صورت صریح و قابل‌ردیابی انجام شود، نه به شکل پنهان.

خروجی تابع شامل دیکشنری آستانه‌های منتخب، جدول مرتب‌شده تمام گزینه‌های معتبر و Metadata جست‌وجو است. Metadata مقدارهای پایه، حدود مجاز افت و حالت جست‌وجو را نگه می‌دارد؛ بنابراین می‌توان بعداً بررسی کرد که آستانه‌ها با چه قیودی انتخاب شده‌اند. انتخاب آستانه روی مجموعه اعتبارسنجی و اعمال نهایی آن روی مجموعه آزمون نیز از نشت اطلاعات آزمون به فرایند تنظیم روش کاهش سوگیری جلوگیری می‌کند.

۲-۸- نتیجه‌گیری

در این فصل، مسئله طبقه‌بندی درآمد در مجموعه‌داده Adult از منظر عملکرد پیش‌بینی، عدالت گروهی، کالیبراسیون، توضیح‌پذیری و کاهش سوگیری بررسی شد. ویژگی‌های sex و race به‌عنوان ویژگی‌های حساس انتخاب شدند و علاوه بر تحلیل جداگانه آن‌ها، ترکیب تقاطعی جنسیت و نژاد نیز بررسی شد. تحلیل اولیه داده نشان داد که توزیع نمونه‌ها و نرخ برچسب مثبت در گروه‌های مختلف یکسان نیست؛ بنابراین ارزیابی مدل صرفاً بر اساس معیارهای کلی نمی‌تواند تصویری کامل از رفتار آن ارائه دهد.

در مقایسه مدل‌ها، جنگل تصادفی نسبت به رگرسیون لجستیک عملکرد پیش‌بینی بهتری داشت، اما این برتری لزوماً به معنای عادلانه‌تر بودن تصمیم‌ها نبود. ارزیابی گروهی نشان داد که نرخ خروجی مثبت، نرخ شناسایی نمونه‌های مثبت و انواع خطاها میان گروه‌ها متفاوت‌اند. به‌طور مشخص، زنان بیش از مردان در معرض خطای منفی کاذب قرار داشتند. تحلیل نژادی و تقاطعی نیز نشان داد که بررسی یک ویژگی حساس به‌تنهایی کافی نیست و بعضی تفاوت‌ها فقط در ترکیب چند ویژگی حساس آشکار می‌شوند. البته نتایج گروه‌های کم‌نمونه باید با احتیاط بیشتری تفسیر شوند.

بررسی کالیبراسیون نشان داد که نزدیک‌بودن احتمال‌های پیش‌بینی‌شده به نرخ واقعی هر گروه، برابری در تصمیم‌های نهایی را تضمین نمی‌کند. مدل می‌تواند از نظر برآورد احتمال عملکرد مناسبی داشته باشد، اما پس از اعمال آستانه تصمیم همچنان

نرخ‌های متفاوتی از TPR، FPR یا FNR برای گروه‌ها ایجاد کند. بنابراین کالیبراسیون و عدالت تصمیمی دو جنبه مستقل از ارزیابی مدل هستند.

حذف مستقیم ویژگی‌های sex و race نیز نتوانست اختلاف‌های عدالت را از بین ببرد. این نتیجه نشان داد که ویژگی‌های دیگری مانند وضعیت تأهل، رابطه خانوادگی، شغل و تحصیلات می‌توانند بخشی از اطلاعات مرتبط با ویژگی‌های حساس را به‌صورت غیرمستقیم منتقل کنند. در نتیجه، حذف ویژگی حساس یا Fairness Through Unawareness به‌تنهایی راه‌حل کافی برای کاهش سوگیری نیست.

در بخش توضیح‌پذیری سراسری، روش‌های Permutation Feature Importance، Partial Dependence Plot و SHAP نشان دادند که ویژگی‌هایی مانند سود سرمایه، وضعیت تأهل، رابطه خانوادگی، سن، تحصیلات، شغل و ساعات کار در تصمیم‌های مدل نقش مهمی دارند. حضور جنسیت و برخی ویژگی‌های خانوادگی در توضیحات نیز نشان داد که مدل ممکن است از اطلاعات حساس یا جانشین‌های احتمالی آن استفاده کند. بااین‌حال، اهمیت یک ویژگی یا همبستگی آن با ویژگی حساس برای اثبات Proxy بودن یا رابطه علّی کافی نیست و به تحلیل‌های تکمیلی نیاز دارد.

توضیح‌های محلی نیز نشان دادند که تصمیم هر نمونه تحت تأثیر ترکیب خاصی از ویژگی‌ها قرار می‌گیرد و نتایج سراسری را نمی‌توان بدون بررسی مستقیم به همه نمونه‌ها تعمیم داد. Counterfactualهای تولیدشده توانستند با تغییر محدود بعضی ویژگی‌ها خروجی مدل را تغییر دهند و در عین حال ویژگی‌های حساس و تغییرناپذیر را ثابت نگه دارند. همگام‌سازی education و education-num نیز مانع ایجاد نمونه‌های ناسازگار شد. بااین‌حال، تغییر موفق خروجی مدل الزاماً به معنای ارائه توصیه‌ای عملی یا اخلاقی نیست؛ زیرا برخی تغییرها ممکن است پرهزینه، زمان‌بر یا خارج از کنترل کامل فرد باشند.

در بخش کاهش سوگیری، روش Reweighing بعضی شکاف‌های جنسیتی را کاهش داد، اما این بهبود با افت بخشی از عملکرد کلی و بدترشدن بعضی معیارهای دیگر همراه شد. تنظیم آستانه گروهی نیز توانست نرخ شناسایی زنان دارای برچسب مثبت و Equalized Odds را بهبود دهد، اما در مقابل مثبت‌های کاذب را افزایش داد و Precision زنان را کاهش داد. همچنین بهینه‌سازی بر اساس جنسیت موجب بهبود هم‌زمان تمام معیارهای نژادی نشد. بنابراین کاهش یک شکاف عدالت می‌تواند با ایجاد Trade-off در عملکرد، کالیبراسیون یا عدالت یک ویژگی حساس دیگر همراه باشد.

از نظر پیاده‌سازی، استفاده از Pipeline مشترک باعث شد پیش‌پردازش دو مدل به‌صورت یکسان انجام شود و اطلاعات مجموعه آزمون وارد فرایند آموزش نشود. توابع مجزای همگام‌سازی تحصیلات، تولید Counterfactual، محاسبه وزن‌های Reweighing و جست‌وجوی آستانه‌های گروهی نیز امکان بازتولید و بررسی دقیق‌تر مراحل آزمایش را فراهم کردند. انتخاب آستانه‌ها فقط روی مجموعه اعتبارسنجی انجام شد و قیود عملکرد و Anti-leveling-down نیز در فرایند جست‌وجو در نظر گرفته شدند.

در جمع‌بندی کلی، نتایج نشان دادند که عملکرد بالا، کالیبراسیون مناسب، توضیح‌پذیری و عدالت گروهی مفاهیمی متفاوت و گاهی متعارض هستند. هیچ مدل یا روش کاهش سوگیری در تمام معیارها به‌طور هم‌زمان برتر نبود و هر مداخله هزینه‌ها و پیامدهای خاص خود را داشت. بنابراین انتخاب مدل نهایی باید بر اساس هزینه واقعی خطاها، تعریف عدالت مورد نظر،

محدودیت‌های کاربردی و الزامات حقوقی و اخلاقی انجام شود. ارزیابی مسئولانه مدل نیز باید به‌صورت هم‌زمان عملکرد، عدالت، کالیبراسیون، توضیح‌پذیری و پیامدهای تصمیم برای گروه‌های مختلف را در نظر بگیرد.